



ΔΗΜΟΚΡΙΤΕΙΟ ΠΑΝΕΠΙΣΤΗΜΙΟ ΘΡΑΚΗΣ
DEMOCRITUS UNIVERSITY OF THRACE

Δημοκρίτειο Πανεπιστήμιο Θράκης

Πολυτεχνική Σχολή

Τμήμα Ηλεκτρολόγων Μηχανικών & Μηχανικών Υπολογιστών

Τομέας Ηλεκτρονικής & Τεχνολογίας Συστημάτων Πληροφορικής

Αξιολόγηση τεχνικών βαθιάς μάθησης για την
πρόβλεψη προθέσεων και κίνησης πεζών από αυ-
τόνομα οχήματα (Evaluation of deep learning
techniques for pedestrian intention and motion
prediction in autonomous driving)

Διπλωματική Εργασία

Τσιτσιρίγκος Ιωάννης ΑΕΜ : 58475

Επιβλέπων καθηγητής : Θεοδορακόπουλος Ηλίας , Καθηγητής, ΔΠΘ

Ιούνιος 2026, ΞΑΝΘΗ

Περίληψη

Η αξιόπιστη πρόβλεψη της πρόθεσης διάσχισης πεζών αποτελεί κρίσιμο πρόβλημα για την αυτόνομη οδήγηση, καθώς οι πεζοί μπορούν να αλλάξουν συμπεριφορά γρήγορα και συχνά αμφίσημα. Η έγκαιρη εκτίμηση του αν ένας πεζός πρόκειται να διασχίσει τον δρόμο επιτρέπει σε ένα όχημα να αντιδράσει προληπτικά και ομαλά, αντί να βασίζεται σε καθυστερημένες αντιδράσεις. Οι πρώτες προσεγγίσεις βασίστηκαν κυρίως σε τροχιές bounding boxes και στη δυναμική του οχήματος, όμως τέτοια χαρακτηριστικά δεν επαρκούν πάντα για να περιγράψουν σύνθετες σκηνές, όπου η στάση σώματος, η τοπική εμφάνιση, η κίνηση και η σημασιολογική δομή του περιβάλλοντος παίζουν σημαντικό ρόλο.

Στην παρούσα διπλωματική εργασία προτείνεται και αξιολογείται το PIPN, μια πολυτροπική και πολυκλαδική αρχιτεκτονική για δυαδική πρόβλεψη πρόθεσης διάσχισης. Το μοντέλο συνδυάζει τρεις συμπληρωματικούς κλάδους: κινηματικό κλάδο, με bounding boxes, στάση σώματος και ταχύτητα οχήματος· τοπικό οπτικό κλάδο, με εμφάνιση και optical flow γύρω από τον πεζό· και καθολικό κλάδο σκηνής, με panoptic segmentation και instance-aware categorical depth. Οι κλάδοι συγχωνεύονται μέσω attention-based late fusion. Το σύστημα προεπεξεργασίας αναβαθμίζεται με σύγχρονα perception modules για segmentation, optical flow και εκτίμηση βάθους, ενώ εφαρμόζεται καταστολή της περιοχής του οχήματος (ego-vehicle suppression) για μείωση θορύβου στους χάρτες σκηνής. Επιπλέον, με βάση το εύρημα ότι η κινηματική πληροφορία αποτελεί ιδιαίτερα ισχυρό σήμα, διερευνάται η KinFormer-GRU, μια ελαφριά παραλλαγή που διατηρεί τον κινηματικό κλάδο ως anchor και εισάγει επιλεγμένο scene context ως gated contextual tokens μέσω ενός Transformer.

Τα πειράματα πραγματοποιήθηκαν κυρίως στο σύνολο δεδομένων PIE, με συμπληρωματική αξιολόγηση γενίκευσης στο JAAD. Το PIPN πέτυχε μέσο ROC-AUC 0.8917 σε πέντε χρονικούς ορίζοντες, με μέγιστη τιμή περίπου 0.908 στα δύο δευτερόλεπτα πριν από τη διάσχιση, και παρουσίασε σταθερή συμπεριφορά σε πέντε ανεξάρτητες εκπαιδεύσεις. Η ανάλυση των επιμέρους κλάδων έδειξε σαφή χρονική εξειδίκευση: ο κινηματικός κλάδος είναι ισχυρότερος σε κοντινούς χρονικούς ορίζοντες, ενώ ο καθολικός κλάδος σκηνής αποκτά μεγαλύτερη σημασία σε πιο πρώιμες προβλέψεις. Στην αξιολόγηση μεταφοράς μεταξύ συνόλων δεδομένων, η κοινή (Combined) εκπαίδευση σε PIE και JAAD βελτίωσε τη γενίκευση στο JAAD, με τον καθολικό κλάδο να εμφανίζει τη μεγαλύτερη μεταφερσιμότητα. Τέλος, η KinFormer-GRU προσέγγισε την απόδοση του PIPN με περίπου 6.8 φορές λιγότερες εκπαιδευσιμες παραμέτρους, αναδεικνύοντας έναν ευνοϊκό συμβιβασμό μεταξύ απόδοσης και υπολογιστικής αποδοτικότητας.

Ο κώδικας, το pipeline προεπεξεργασίας και τα scripts εκπαίδευσης/αξιολόγησης είναι δημόσια διαθέσιμα στο:

https://github.com/nisgias/Pedestrian_Intention_Estimation_Network_PIE_n

Λέξεις-κλειδιά: αυτόνομη οδήγηση, πρόβλεψη πρόθεσης πεζού, πρόθεση διάσχισης, πολυτροπική σύντηξη, panoptic segmentation, optical flow, depth estimation, attention-based fusion, Transformers, ελαφριές αρχιτεκτονικές, PIE dataset.

Abstract

The reliable prediction of pedestrian crossing intention is a critical problem for autonomous driving, as pedestrians can change their behavior quickly and often ambiguously. Early estimation of whether a pedestrian is about to cross the road allows a vehicle to react proactively and smoothly, rather than relying on delayed reactions. Early approaches were based mainly on bounding-box trajectories and ego-vehicle dynamics, but such features are not always sufficient to describe complex scenes, where body pose, local appearance, motion, and the semantic structure of the environment play an important role.

This thesis proposes and evaluates PIPN, a multimodal, multi-branch architecture for binary pedestrian crossing-intention prediction. The model combines three complementary branches: a kinematic branch, using bounding boxes, body pose, and ego-vehicle speed; a local visual branch, using appearance and optical flow around the pedestrian; and a global context branch, using panoptic segmentation and instance-aware categorical depth. The branches are fused through attention-based late fusion. The preprocessing pipeline is upgraded with modern perception modules for segmentation, optical flow, and depth estimation, while an ego-vehicle suppression step is applied to reduce noise in the scene maps. In addition, motivated by the finding that the kinematic signal is a particularly strong cue, KinFormer-GRU is investigated — a lightweight variant that keeps the kinematic branch as an anchor and injects selected scene context as gated contextual tokens through a Transformer.

Experiments were conducted primarily on the PIE dataset, with complementary generalization evaluation on JAAD. PIPN achieved a mean ROC-AUC of 0.8917 across five prediction horizons, with a peak of approximately 0.908 at two seconds before the crossing event, and exhibited stable behavior across five independent runs. The per-branch analysis revealed a clear temporal specialization: the kinematic branch is stronger at short horizons, while the global context branch becomes more important for earlier predictions. In the cross-dataset transfer evaluation, Combined training on PIE and JAAD improved generalization to JAAD, with the global context branch exhibiting the highest transferability. Finally, KinFormer-GRU approached the performance of PIPN with approximately $6.8\times$ fewer trainable parameters, demonstrating a favorable trade-off between performance and computational efficiency.

The code, preprocessing pipeline, and training/evaluation scripts are publicly available at:

https://github.com/nisgias/Pedestrian_Intention_Estimation_Network_PIE_n

Keywords: autonomous driving, pedestrian intention prediction, crossing intention, multimodal fusion, panoptic segmentation, optical flow, depth estimation, attention-based fusion, Transformers, lightweight architectures, PIE dataset.

Ευχαριστίες

Με την ολοκλήρωση της παρούσας διπλωματικής εργασίας, θα ήθελα να ευχαριστήσω όσους με βοήθησαν και με στήριξαν σε αυτή τη διαδρομή. Αρχικά, ευχαριστώ θερμά τον επιβλέποντα καθηγητή μου, Ηλία Θεοδωρακόπουλο, για την καθοδήγηση και την υποστήριξή του καθ' όλη τη διάρκεια της εκπόνησης της εργασίας καθώς και την εμπιστοσύνη του στην επιλογή ενός απαιτητικού και σύγχρονου θέματος μου έδωσε το κίνητρο να το προσεγγίσω σε βάθος. Θέλω επίσης να ευχαριστήσω την οικογένειά μου, που με εμπιστεύτηκε σε όλη μου την πορεία. Η στήριξη και η υπομονή τους ήταν αυτό που με κράτησε όρθιο στις πιο δύσκολες στιγμές των σπουδών και της εργασίας αυτής. Τους ευχαριστώ από καρδιάς. Τέλος, ευχαριστώ τους φίλους μου για την παρέα και την εμψύχωση σε όλη αυτή τη διαδρομή.

Περιεχόμενα

ΚΕΦΑΛΑΙΟ 1 ΕΙΣΑΓΩΓΗ	12
1.1 ΣΗΜΑΣΙΑ ΤΗΣ ΠΡΟΒΛΕΨΗΣ ΠΡΟΘΕΣΗΣ ΠΕΖΟΥ	12
1.2 ΠΕΡΙΟΡΙΣΜΟΙ ΚΑΙ ΠΡΟΚΛΗΣΕΙΣ ΣΤΗΝ ΠΡΟΒΛΕΨΗ ΠΡΟΘΕΣΗΣ	12
1.3 ΒΑΘΙΑ ΜΑΘΗΣΗ ΓΙΑ ΠΡΟΒΛΕΨΗ ΠΡΟΘΕΣΗΣ ΠΕΖΟΥ	13
1.4 ΠΟΛΥΤΡΟΠΙΚΗ ΜΟΝΤΕΛΟΠΟΙΗΣΗ ΚΑΙ ΣΥΝΤΗΞΗ ΧΑΡΑΚΤΗΡΙΣΤΙΚΩΝ	14
1.5 ΕΡΕΥΝΗΤΙΚΟΙ ΣΤΟΧΟΙ ΚΑΙ ΔΟΜΗ ΤΗΣ ΕΡΓΑΣΙΑΣ	14
ΚΕΦΑΛΑΙΟ 2 ΒΙΒΛΙΟΓΡΑΦΙΚΗ ΑΝΑΣΚΟΠΗΣΗ	17
2.1 ΕΙΣΑΓΩΓΗ ΣΤΟ ΚΕΦΑΛΑΙΟ	17
2.2 ΣΥΝΟΛΑ ΔΕΔΟΜΕΝΩΝ	17
2.2.1 JAAD (<i>Joint Attention in Autonomous Driving</i>)	18
2.2.2 PIE (<i>Pedestrian Intention Estimation</i>)	19
2.2.3 TITAN (<i>Future Forecast Using Action Priors</i>)	21
2.2.4 Urban-PIP	22
2.3 ΚΑΤΗΓΟΡΙΟΠΟΙΗΣΗ ΤΩΝ ΥΦΙΣΤΑΜΕΝΩΝ ΠΡΟΣΕΓΓΙΣΕΩΝ	23
2.3.1 Βάσει Χρονικού Ορίζοντα Πρόβλεψης	24
2.3.2 Βάσει Χαρακτηριστικών (<i>Features</i>)	25
2.3.3 Βάσει Αρχιτεκτονικής Μοντέλου	26
2.4 ΤΕΧΝΟΛΟΓΙΚΟ ΥΠΟΒΑΘΡΟ ΒΑΣΙΚΩΝ MODULES	27
2.4.1 <i>Semantic και Panoptic Segmentation</i>	27
2.4.2 <i>Optical Flow</i>	28
2.4.3 <i>Monocular Depth Estimation και Categorical Depth</i>	29
2.4.4 <i>Pose Estimation</i>	30
2.4.5 <i>Temporal και Spatio-Temporal Encoders (GRU, Conv3D)</i>	31
2.4.6 <i>Vision Transformers (ViT) και Μηχανισμοί Προσοχής (Self-Attention)</i>	32
2.5 ΑΝΤΙΠΡΟΣΩΠΕΥΤΙΚΑ ΠΟΛΥΤΡΟΠΙΚΑ ΠΛΑΙΣΙΑ	33
2.5.1 <i>PIE Baseline και Human Intention Experiment</i>	33
2.5.2 <i>CIPF (Crossing Intention Prediction with Feature Fusion)</i>	34
2.5.3 <i>Transformer-based Προσεγγίσεις</i>	35
2.5.4 <i>PIP-Net (Pedestrian Intention Prediction in the Wild)</i>	36
2.6 ΣΥΝΟΨΗ, ΚΕΝΑ ΤΗΣ ΒΙΒΛΙΟΓΡΑΦΙΑΣ ΚΑΙ ΤΟΠΟΘΕΤΗΣΗ ΤΗΣ ΠΑΡΟΥΣΑΣ ΕΡΓΑΣΙΑΣ	38
2.6.1 Σύνοψη	38
2.6.2 Κενά της Βιβλιογραφίας	38
2.6.3 Τοποθέτηση της Παρούσας Εργασίας	39
ΚΕΦΑΛΑΙΟ 3 ΜΕΘΟΔΟΛΟΓΙΑ	42
3.1 ΔΙΑΤΥΠΩΣΗ ΠΡΟΒΛΗΜΑΤΟΣ ΚΑΙ ΚΑΤΑΣΚΕΥΗ ΔΕΙΓΜΑΤΩΝ	42
3.1.1 Επιχειρησιακός ορισμός του <i>crossing intention</i>	42
3.1.2 Χρονικό παράθυρο παρατήρησης και <i>Time-to-Event</i>	43
3.1.3 Θετικά και αρνητικά δείγματα	43
3.2 OFFLINE PREPROCESSING PIPELINE	44
3.2.1 Στάδιο 1 — Κινηματικά χαρακτηριστικά πεζού και οχήματος	44
3.2.2 Στάδιο 2 — Τοπική οπτική εμφάνιση και κίνηση	45
3.2.3 Στάδιο 3 — <i>Global scene context</i> και <i>categorical depth</i>	47
3.2.4 Κανονικοποίηση και φόρτωση δεδομένων	49
3.3 ΑΡΧΙΤΕΚΤΟΝΙΚΗ PIPN	50
3.3.1 Επισκόπηση	50

3.3.2 Kinematic branch	51
3.3.3 Local visual branch	52
3.3.4 Global context branch	52
3.3.5 Attention-based fusion	54
3.3.6 Auxiliary heads και branch-level ανάλυση.....	55
3.4 ΠΕΙΡΑΜΑΤΙΚΕΣ TRANSFORMER-BASED ΠΑΡΑΛΛΑΓΕΣ	55
3.4.1 Spatial-Patch Transformer ως αντικατάσταση του Conv3D global branch	55
3.4.2 Transformer-only κινηματικός encoder	55
3.4.3 KinFormer-GRU: kinematic anchor με gated contextual tokens.....	56
3.4.4 Διατήρηση χωρικής πληροφορίας μέσω patch tokens.....	57
3.4.5 Semantic mask channels και modality gates	57
3.4.6 Στρατηγική εκπαίδευσης των παραλλαγών	57
3.5 ΣΤΡΑΤΗΓΙΚΗ ΕΚΠΑΙΔΕΥΣΗΣ.....	58
3.5.1 Loss function.....	58
3.5.2 Training setups	58
3.5.3 Model selection και αποφυγή test leakage	59
3.5.4 Optimizer και πρακτικές σταθερότητας	59
3.6 ΠΕΙΡΑΜΑΤΙΚΕΣ ΠΑΡΑΛΛΑΓΕΣ ΚΑΙ ABLATIONS.....	59
3.7 ΣΧΕΔΙΑΣΤΙΚΕΣ ΑΠΟΦΑΣΕΙΣ ΚΑΙ ΑΠΟΚΛΙΣΕΙΣ ΑΠΟ ΤΟ PIP-NET.....	60
3.8 ΣΥΝΟΨΗ ΚΕΦΑΛΑΙΟΥ.....	61
ΚΕΦΑΛΑΙΟ 4 ΠΕΙΡΑΜΑΤΑ ΚΑΙ ΑΠΟΤΕΛΕΣΜΑΤΑ.....	62
4.1 ΠΕΙΡΑΜΑΤΙΚΗ ΡΥΘΜΙΣΗ	62
4.1.1 Υποδομή και Πλαίσιο Εκπαίδευσης.....	62
4.1.2 Πειραματική Διαμόρφωση Datasets	63
4.1.3 Μετρικές Αξιολόγησης.....	63
4.1.4 Στρατηγικές Εκπαίδευσης και Υπερπαράμετροι	64
4.1.5 Πρωτόκολλο Multi-horizon Evaluation	67
4.2 ΚΥΡΙΑ ΑΠΟΤΕΛΕΣΜΑΤΑ ΣΤΟ PIE BENCHMARK.....	67
4.2.1 Σταθερότητα Εκπαίδευσης και Επιλογή Βέλτιστου Μοντέλου	68
4.2.2 Αξιολόγηση σε πολλαπλούς χρονικούς ορίζοντες	69
4.2.3 Σύγκριση με τη Βιβλιογραφία	71
4.2.4 Ποιοτική ανάλυση προβλέψεων.....	75
4.3 ΑΝΑΛΥΣΗ ΑΡΧΙΤΕΚΤΟΝΙΚΗΣ ΚΑΙ ΣΤΑΘΕΡΟΤΗΤΑΣ.....	77
4.3.1 Συμπληρωματικότητα Κλάδων (Pearson Error Correlation)	77
4.3.2 Χρονική Σταθερότητα (Temporal Jitter Analysis).....	78
4.4 ΜΕΛΕΤΗ ΑΦΑΙΡΕΣΗΣ ΚΑΙ ΣΥΝΕΙΣΦΟΡΑΣ ΚΛΑΔΩΝ (ABLATION STUDY)	79
4.4.1 Αξιολόγηση Ανεξάρτητων Κλάδων.....	80
4.4.2 Πείραμα Αφαίρεσης Κλάδων (Branch-Zeroing Ablation)	82
4.4.3 Post-hoc Logit Fusion: Συνολική Βελτίωση και Περιορισμοί	85
4.5 ΙΚΑΝΟΤΗΤΑ ΓΕΝΙΚΕΥΣΗΣ (CROSS-DATASET TRANSFERABILITY)	86
4.5.1 Σύγκριση Στρατηγικών Εκπαίδευσης	86
4.5.2 Per-branch Cross-Dataset Transferability	87
4.5.3 Περιορισμοί στο JAAD Evaluation	88
4.6 ΑΠΟΤΕΛΕΣΜΑΤΑ ΤΩΝ TRANSFORMER-BASED ΠΑΡΑΛΛΑΓΩΝ.....	89
4.6.1 Αντικατάσταση του Conv3D global branch με Transformer.....	90
4.6.2 KinFormer-GRU: anchor-only έλεγχος και σταδιακή προσθήκη contextual modalities	91
4.6.3 Επίδραση της αρχικοποίησης των gates	93
4.6.4 Αξιολόγηση σε πολλαπλούς χρονικούς ορίζοντες	93
4.6.5 PIPN mask-channel ablation	95
4.7 ΣΥΝΟΨΗ ΑΠΟΤΕΛΕΣΜΑΤΩΝ	95
ΚΕΦΑΛΑΙΟ 5 ΣΥΜΠΕΡΑΣΜΑΤΑ ΚΑΙ ΜΕΛΛΟΝΤΙΚΕΣ ΕΠΕΚΤΑΣΕΙΣ.....	99

5.1 ΑΝΑΚΕΦΑΛΑΙΩΣΗ ΤΗΣ ΕΡΓΑΣΙΑΣ	99
5.2 ΚΥΡΙΑ ΠΕΙΡΑΜΑΤΙΚΑ ΕΥΡΗΜΑΤΑ.....	99
5.3 ΕΡΜΗΝΕΙΑ ΤΗΣ ΠΟΛΥΚΛΑΔΙΚΗΣ ΑΡΧΙΤΕΚΤΟΝΙΚΗΣ	100
5.4 ΓΕΝΙΚΕΥΣΗ ΜΕΤΑΞΥ DATASETS.....	101
5.5 ΣΥΝΕΙΣΦΟΡΕΣ ΤΗΣ ΕΡΓΑΣΙΑΣ	101
5.6 ΠΕΡΙΟΡΙΣΜΟΙ	102
5.7 ΜΕΛΛΟΝΤΙΚΕΣ ΕΠΕΚΤΑΣΕΙΣ.....	102
5.8 ΤΕΛΙΚΟ ΣΥΜΠΕΡΑΣΜΑ	103
ΒΙΒΛΙΟΓΡΑΦΙΑ.....	105

Κατάλογος Πινάκων

Πίνακας 2.1: Βασικά στατιστικά του JAAD dataset.	18
Πίνακας 2.2: Σύγκριση βασικών χαρακτηριστικών των PIE και JAAD datasets.	20
Πίνακας 2.3: Σύγκριση της παρούσας εργασίας με τα αντιπροσωπευτικά frameworks	41
Πίνακας 3.1: Βασικές εισοδοί του μοντέλου.....	50
Πίνακας 3.2: Συνολικά ablations και συγκρίσεις.	60
Πίνακας 4.1: Υπερπαράμετροι εκπαίδευσης ανά στρατηγική.....	66
Πίνακας 4.2: Test sets πολλαπλών χρονικών οριζόντων.....	67
Πίνακας 4.3: Επιδόσεις πέντε ανεξάρτητων εκπαιδεύσεων στο PIE test set	68
Πίνακας 4.4: Επιδόσεις του best model σε πέντε χρονικούς ορίζοντες.....	70
Πίνακας 4.5: Συγκριτική αξιολόγηση στο PIE benchmark. Αποτελέσματα σημειωμένα με * αναφέρονται από τα πρωτότυπα papers λόγω μη διαθεσιμότητας κώδικα. Για το προτεινόμενο μοντέλο παρουσιάζονται δύο χρονικοί ορίζοντες: TTE ≈ 0.5 s, ως εκτός κατανομής αξιολόγηση, και TTE ≈ 2.0 s, ως εντός του κύριου εύρους σχεδιασμού.	73
Πίνακας 4.6: Συσχέτιση κατά Pearson μεταξύ σφαλμάτων ζευγών κλάδων στο PIE test set (Οι τιμές αναφέρονται ως μέσοι όροι των πέντε seeds και χρησιμοποιούνται κυρίως για ποιοτική ερμηνεία της συμπληρωματικότητας των κλάδων.	77
Πίνακας 4.7: Ποιοτική κατάταξη χρονικής σταθερότητας προβλέψεων.	79
Πίνακας 4.8: Per-branch ROC-AUC σε όλους τους χρονικούς ορίζοντες (best model). ...	80
Πίνακας 4.9: Μείωση ROC-AUC μετά τον μηδενισμό κάθε κλάδου ανά χρονικό ορίζοντα	82
Πίνακας 4.10: Επίδραση του post-hoc logit fusion στο κύριο test set $TTE \in [1.0, 2.0]$ s. Μέσος όρος από όλα τα seeds.	85
Πίνακας 4.11: Βέλτιστα βάρη post-hoc fusion.	85
Πίνακας 4.12: Σύγκριση στρατηγικών εκπαίδευσης σε PIE και JAAD test sets.	86
Πίνακας 4.13: Per-branch ROC-AUC στο JAAD test set ανά στρατηγική εκπαίδευσης. .	88
Πίνακας 4.14: Trade-off παραμέτρων και απόδοσης για τις αρχικές Transformer-based παραλλαγές.....	91
Πίνακας 4.15: Modality ablation στο KinFormer-GRU.....	92
Πίνακας 4.16: Επίδραση της αρχικοποίησης των gates στο KinFormer-GRU seg+depth. 93	
Πίνακας 4.17: Horizon evaluation του KinFormer-GRU seg+depth με conservative gates.	94
Πίνακας 4.18: Horizon evaluation του KinFormer-GRU seg+depth με open gates.	94
Πίνακας 4.19: PIPN mask channel ablation.	95

Κατάλογος Σχημάτων

Σχήμα 2.1: TITAN Data Distribution	21
Σχήμα 2.2: Γενικευμένο πλαίσιο πρόβλεψης πρόθεσης πεζού.....	23
Σχήμα 2.3: Ταξινόμηση των προσεγγίσεων πρόβλεψης πρόθεσης πεζού	24
Σχήμα 2.4: Χρονικό μοντέλο της έγκαιρης πρόβλεψης πρόθεσης.....	25
Σχήμα 2.5: Επισκόπηση της αρχιτεκτονικής CIPF, η οποία οργανώνεται σε τρία modules (observational, contextual, convolutional)[13].	34
Σχήμα 2.6: Επισκόπηση της αρχιτεκτονικής PIP-Net. (Pedestrian Intention Prediction in the Wild)[8].	37
Σχήμα 3.1: Παράδειγμα εξαγωγής κινηματικών χαρακτηριστικών από frame του PIE dataset. Ο target pedestrian επισημαίνεται με bounding box, ενώ η στάση σώματος αναπαρίσταται με 17 COCO keypoints.	45
Σχήμα 3.2: Παράδειγμα τοπικής οπτικής εισόδου. Από το πλήρες RGB frame εξάγεται crop γύρω από τον target pedestrian, με μικρή επέκταση του bounding box ώστε να διατηρείται μέρος του άμεσου περιβάλλοντος. Το crop αναδιαστασιολογείται σε 224×224 και χρησιμοποιείται για την εξαγωγή local appearance features.	46
Σχήμα 3.3: Παράδειγμα local motion representation. Το pedestrian crop χρησιμοποιείται για την εκτίμηση πυκνού optical flow με RAFT, το οποίο αποτυπώνει την τοπική κίνηση του πεζού και του άμεσου περιβάλλοντος. Η κωδικοποίηση της κίνησης περιορίζεται στην περιοχή ενδιαφέροντος, μειώνοντας την επίδραση άσχετης κίνησης από την υπόλοιπη σκηνή.	47
Σχήμα 3.4: Καταστολή του ego-vehicle (ego-suppression). (a) Αρχικό RGB frame. (b) Panoptic segmentation πριν την καταστολή το καπό του οχήματος στο κάτω μέρος ταξινομείται εσφαλμένα ως όχημα. (c) Μετά την καταστολή, η περιοχή κάτω από το όριο $y \geq 0.88 \cdot H$ αντικαθίσταται με την κατηγορία road. (d) Επισημάνση της περιοχής καταστολής.	48
Σχήμα 3.5: Κατασκευή categorical depth από raw monocular depth και instance masks. Τα κανάλια πεζών και οχημάτων διατηρούν μόνο τις αντίστοιχες κατηγορίες road users, αποδίδοντας σε κάθε instance σταθερή τιμή σχετικής εγγύτητας.....	48
Σχήμα 3.6: Παράδειγμα categorical depth πεζών και οχημάτων σε μία εικόνα.....	49
Σχήμα 3.7: Επισκόπηση της αρχιτεκτονικής PIPN. Οι τρεις κλάδοι (kinematic, local visual, global context) επεξεργάζονται ανεξάρτητα τα αντίστοιχα modalities και συντήκονται μέσω attention-based late fusion. Τα auxiliary heads (Aux) χρησιμοποιούνται μόνο κατά την εκπαίδευση.	51
Σχήμα 3.8: Αρχιτεκτονικό διάγραμμα KinFormer-GRU.....	56
Σχήμα 4.1: Bar plot Test AUC ανά seed.....	68
Σχήμα 4.2: Καμπύλη ROC-AUC συναρτήσεως του χρονικού ορίζοντα TTE.....	70
Σχήμα 4.3: Multi-horizon σύγκριση ROC-AUC, F1-score και Accuracy έναντι MCIP, CIPF και PIP-Net-α στο εύρος TTE = 1–4 s.	74
Σχήμα 4.4: Ποιοτικά παραδείγματα προβλέψεων του PIPN στο PIE test set για TTE ≈ 0.5 s. Παρουσιάζονται ενδεικτικές περιπτώσεις true positive, true negative, false positive και false negative. Για κάθε παράδειγμα εμφανίζονται τρία χρονικά σημεία του observation window, το target bounding box και η προβλεπόμενη πιθανότητα crossing.....	76
Σχήμα 4.5: Per-branch ROC-AUC συναρτήσεως του χρονικού ορίζοντα TTE, με σκιαγραφημένη την out-of-distribution περιοχή (TTE ≥ 2.5 s). Σταδιακή σύγκλιση των kinematic και global branches γύρω από το TTE ≈ 2.0 s.	81

Σχήμα 4.6: Bar plot της μείωσης ROC-AUC (ΔAUC) μετά την εξάλειψη κάθε κλάδου, ανά χρονικό ορίζοντα TTE. Σημειώνονται οι δύο αντίθετες τάσεις: αύξηση της σημασίας του global κλάδου και μείωση της σημασίας των kin/local κλάδων με την αύξηση του TTE..... 83

Σχήμα 4.7: Multi-horizon σύγκριση ROC-AUC, F1 και Accuracy μεταξύ του PIPN και της ελαφριάς KinFormer-GRU (open gate) στο εύρος TTE = 0.5–4 s..... 94

Κεφάλαιο 1 Εισαγωγή

1.1 Σημασία της πρόβλεψης πρόθεσης πεζού

Σύμφωνα με τον Παγκόσμιο Οργανισμό Υγείας, περίπου 1,35 εκατομμύρια άνθρωποι χάνουν τη ζωή τους κάθε χρόνο σε τροχαία δυστυχήματα παγκοσμίως, με τους πεζούς να αντιστοιχούν στο 23% των θανάτων αυτών. Το υψηλό αυτό ποσοστό αναδεικνύει την ιδιαίτερη έκθεση των πεζών σε κίνδυνο και τους καθιστά μία από τις πιο ευάλωτες ομάδες χρηστών του οδικού δικτύου [1].

Ένα σημαντικό μέρος των τροχαίων συμβάντων οφείλεται σε ανθρώπινο σφάλμα, γεγονός που έχει επιταχύνει την ανάπτυξη συστημάτων υποβοήθησης οδηγού και τεχνολογιών αυτόνομης οδήγησης. Ωστόσο, η ασφαλής λειτουργία τέτοιων συστημάτων σε δυναμικά αστικά περιβάλλοντα παραμένει ιδιαίτερα απαιτητική. Πέρα από την αντίληψη και την κατανόηση της σκηνής, ένα αυτόνομο όχημα οφείλει να εκτιμά έγκαιρα τη συμπεριφορά και κυρίως την πρόθεση των πεζών, προβλέποντας πιθανές μελλοντικές κινήσεις τους.

Η ακριβής πρόβλεψη της πρόθεσης διάσχισης του οδοστρώματος αποτελεί καθοριστικό παράγοντα για τη λήψη προληπτικών αποφάσεων, όπως η έγκαιρη επιβράδυνση ή η προσαρμογή πορείας. Η δυνατότητα αυτή ενισχύει την ασφάλεια της αλληλεπίδρασης ανθρώπου-οχήματος και είναι ιδιαίτερα σημαντική σε περιπτώσεις περιορισμένης ορατότητας, όπως η μερική απόκρυψη πεζών από σταθμευμένα οχήματα ή άλλα εμπόδια. Σε τέτοιες συνθήκες, η απλή ανίχνευση αντικειμένων δεν επαρκεί· απαιτείται πρόβλεψη της πιθανής μελλοντικής συμπεριφοράς [2].

Κρίσιμη παράμετρος σε αυτό το πλαίσιο είναι ο χρονικός ορίζοντας της πρόβλεψης. Μια πρόβλεψη πολύ κοντά στη στιγμή της διάσχισης μπορεί να είναι ευκολότερη, αλλά αφήνει περιορισμένο χρόνο αντίδρασης στο όχημα. Αντίθετα, μια πιο πρώιμη πρόβλεψη είναι δυσκολότερη, επειδή η πρόθεση του πεζού δεν έχει ακόμη εκδηλωθεί πλήρως, αλλά είναι περισσότερο χρήσιμη για ένα σύστημα έγκαιρης προειδοποίησης. Για τον λόγο αυτό, η παρούσα εργασία δίνει έμφαση όχι μόνο στη συνολική ακρίβεια πρόβλεψης, αλλά και στη συμπεριφορά του μοντέλου σε πολλαπλούς χρονικούς ορίζοντες.

1.2 Περιορισμοί και προκλήσεις στην πρόβλεψη πρόθεσης

Παρά τη σημαντική πρόοδο στη βαθιά μάθηση και στην υπολογιστική όραση, η αξιόπιστη πρόβλεψη πρόθεσης πεζού σε ρεαλιστικά αστικά σενάρια παραμένει ιδιαίτερα απαιτητική. Οι βασικές προκλήσεις σχετίζονται με την πολυπλοκότητα της ανθρώπινης συμπεριφοράς, την αβεβαιότητα του οδικού περιβάλλοντος, την ανάγκη έγκαιρης πρόβλεψης και τη δυσκολία γενίκευσης σε διαφορετικά datasets.

Η πρόθεση διάσχισης επηρεάζεται από πλήθος παραγόντων, όπως η ύπαρξη διάβασης, η σήμανση, τα φανάρια, η πυκνότητα κυκλοφορίας, η συμπεριφορά των οδηγών, οι κοινωνικές αλληλεπιδράσεις και η γεωμετρία του δρόμου. Η ίδια κίνηση ενός πεζού μπορεί να έχει διαφορετική σημασία ανάλογα με το πλαίσιο της σκηνής. Για παράδειγμα, ένας πεζός που στέκεται κοντά σε διάβαση έχει διαφορετική πιθανότητα διάσχισης από έναν

πεζό που βρίσκεται σε παρόμοια θέση αλλά χωρίς διαθέσιμο σημείο διάβασης. Επιπλέον, η εγγενής αβεβαιότητα της ανθρώπινης συμπεριφοράς καθιστά την πρόβλεψη πολυτροπική, καθώς ένας πεζός μπορεί να ακολουθήσει πολλαπλές πιθανές τροχιές σε μια δεδομένη κατάσταση [3], [4].

Μοντέλα που βασίζονται κυρίως στην ιστορική τροχιά ή στην κίνηση του πεζού μπορούν να αποδώσουν ικανοποιητικά όταν η διάσχιση έχει ήδη ξεκινήσει ή όταν η κινηματική συμπεριφορά είναι σαφής. Ωστόσο, δυσκολεύονται σε αμφίσημες καταστάσεις, όπως η αναμονή στο κράσπεδο, η παράλληλη κίνηση προς την οδό ή η σταδιακή προσέγγιση σε σημείο διάβασης. Σε αυτές τις περιπτώσεις, η τροχιά από μόνη της δεν επαρκεί για αξιόπιστη πρόβλεψη πρόθεσης [5].

Πολλές προσεγγίσεις επικεντρώνονται κυρίως στον ίδιο τον πεζό, αξιοποιώντας cropped εικόνες, bounding boxes ή pose information. Αν και αυτές οι πληροφορίες είναι σημαντικές, δεν αποτυπώνουν πλήρως το ευρύτερο σκηνικό πλαίσιο. Στοιχεία όπως η ύπαρξη διάβασης, η θέση των γύρω οχημάτων, η δομή του οδοστρώματος και οι περιοχές αναμονής μπορούν να επηρεάσουν καθοριστικά την πρόθεση διάσχισης, ειδικά σε πιο πρώιμους χρονικούς ορίζοντες [6].

Τα περισσότερα μοντέλα εκπαιδεύονται και αξιολογούνται σε συγκεκριμένα datasets, τα οποία διαφέρουν ως προς την πόλη, την κάμερα, τις συνθήκες λήψης, την πλευρά κυκλοφορίας, τη διαθεσιμότητα αισθητηριακών δεδομένων και τις συμβάσεις annotation. Ως αποτέλεσμα, ένα μοντέλο που αποδίδει καλά σε ένα dataset μπορεί να παρουσιάζει σημαντική πτώση απόδοσης σε άλλο. Η δυνατότητα cross-dataset γενίκευσης αποτελεί επομένως κρίσιμο ζητούμενο για πραγματικά συστήματα αυτόνομης οδήγησης [7].

Οι παραπάνω προκλήσεις δείχνουν ότι ένα ισχυρό σύστημα πρόβλεψης πρόθεσης πεζού πρέπει να συνδυάζει πολλαπλές πηγές πληροφορίας: κινηματικά χαρακτηριστικά, τοπική οπτική πληροφορία γύρω από τον πεζό και παγκόσμιο σημασιολογικό ή γεωμετρικό πλαίσιο της σκηνής. Παράλληλα, πρέπει να αξιολογείται όχι μόνο σε ένα μεμονωμένο χρονικό σημείο, αλλά σε πολλαπλούς χρονικούς ορίζοντες και, όπου είναι δυνατόν, σε διαφορετικά datasets [8], [9].

1.3 Βαθιά μάθηση για πρόβλεψη πρόθεσης πεζού

Η βαθιά μάθηση έχει αναδειχθεί ως κυρίαρχη προσέγγιση για την πρόβλεψη πρόθεσης πεζού, καθώς μπορεί να μοντελοποιήσει σύνθετες μη γραμμικές σχέσεις μεταξύ εμφάνισης, κίνησης και συμφραζομένων. Σε αντίθεση με παραδοσιακές μεθόδους που βασίζονται σε χειροποίητα χαρακτηριστικά, τα νευρωνικά δίκτυα μπορούν να αξιοποιήσουν πλούσια οπτική πληροφορία από εικόνες και βίντεο, ενσωματώνοντας παράλληλα στοιχεία της κίνησης του πεζού, του ego-vehicle και της ευρύτερης σκηνής [10], [11].

Η πρόβλεψη πρόθεσης είναι εγγενώς χωροχρονικό πρόβλημα. Η απόφαση ενός πεζού να διασχίσει δεν αποτυπώνεται απαραίτητα σε ένα μεμονωμένο καρέ, αλλά προκύπτει από την εξέλιξη της στάσης, της θέσης, της κίνησης και του περιβάλλοντος μέσα στον χρόνο. Για τον λόγο αυτό, οι σύγχρονες προσεγγίσεις συνδυάζουν χωρικούς encoders, όπως CNNs ή Vision Transformers, με χρονική μοντελοποίηση μέσω recurrent units, Conv3D ή attention mechanisms [5], [12].

Η επιλογή του χωροχρονικού encoder επηρεάζει τόσο την ακρίβεια όσο και το υπολογιστικό κόστος του μοντέλου. Conv3D-based προσεγγίσεις διαθέτουν ισχυρή τοπική χωροχρονική επαγωγική μεροληψία, ενώ Transformer-based προσεγγίσεις μπορούν να μοντελοποιήσουν πιο ευέλικτα μακρινές σχέσεις μεταξύ περιοχών της σκηνής. Ωστόσο, οι Transformer-based λύσεις συχνά απαιτούν προσεκτικότερο σχεδιασμό και ισχυρότερη κανονικοποίηση, ιδιαίτερα όταν τα διαθέσιμα datasets είναι περιορισμένα.

Στην παρούσα εργασία, η βαθιά μάθηση αξιοποιείται μέσα από μια πολυκλαδική αρχιτεκτονική που συνδυάζει διαφορετικές πηγές πληροφορίας και επιτρέπει συστηματική ανάλυση της συνεισφοράς τους. Παράλληλα, διερευνάται μια εναλλακτική υλοποίηση του global context branch, βασισμένη σε Spatial-Patch Transformer, με στόχο να εξεταστεί αν η patch-based attention μοντελοποίηση μπορεί να αποτυπώσει αποτελεσματικά τις χωρικές σχέσεις της σκηνής. Η σύγκριση με την Conv3D-based υλοποίηση επιτρέπει την αξιολόγηση του trade-off μεταξύ ακρίβειας, παραμετρικού μεγέθους και σταθερότητας εκπαίδευσης.

1.4 Πολυτροπική μοντελοποίηση και σύντηξη χαρακτηριστικών

Η πολυτροπική μοντελοποίηση είναι ιδιαίτερα σημαντική στην πρόβλεψη πρόθεσης πεζού, επειδή η πρόθεση σπάνια μπορεί να εκτιμηθεί αξιόπιστα από μία μόνο πηγή πληροφορίας. Η κίνηση του πεζού μπορεί να είναι αμφίσημη, η στάση σώματος μπορεί να επηρεάζεται από απόκρυψη ή θόρυβο, ενώ το περιβάλλον μπορεί να παρέχει ισχυρές ενδείξεις για πιθανή μελλοντική διάσχιση. Η σύντηξη πολλαπλών modalities επιτρέπει στο μοντέλο να συνδυάζει συμπληρωματικά σήματα και να περιορίζει την εξάρτηση από μία μόνο πηγή πληροφορίας [6], [13].

Στην παρούσα εργασία, η πληροφορία οργανώνεται σε τρεις βασικές κατηγορίες. Τα κινηματικά χαρακτηριστικά περιλαμβάνουν πληροφορία θέσης, κίνησης, bounding boxes, pose χαρακτηριστικά και, όπου είναι διαθέσιμη, ταχύτητα του ego-vehicle. Οι τοπικές οπτικές ενδείξεις περιλαμβάνουν πληροφορία εμφάνισης και τοπικής κίνησης γύρω από τον πεζό, με στόχο την κατανόηση στάσης σώματος, προσανατολισμού και άμεσου οπτικού περιβάλλοντος. Το παγκόσμιο πλαίσιο σκηνής περιλαμβάνει σημασιολογική και γεωμετρική πληροφορία από τη συνολική σκηνή, όπως semantic context, εκτιμώμενη πληροφορία βάθους και χωρικές ενδείξεις που σχετίζονται με το οδόστρωμα, τις διαβάσεις, τα οχήματα, τους πεζούς και τις περιοχές αναμονής.

1.5 Ερευνητικοί στόχοι και δομή της εργασίας

Με βάση τις παραπάνω παρατηρήσεις, η παρούσα εργασία αναπτύσσει ένα πολυτροπικό σύστημα πρόβλεψης πρόθεσης διάσχισης πεζού, με την ονομασία PIPN. Συγκεκριμένα, επιδιώκονται οι εξής στόχοι:

1. Έγκαιρη πρόβλεψη σε πολλαπλούς χρονικούς ορίζοντες. Ανάπτυξη μοντέλου ικανού να προβλέπει την πρόθεση διάσχισης πεζού σε πολλαπλούς χρονικούς ορίζοντες, με ιδιαίτερη έμφαση στο εύρος $TTE \in [1.0, 2.0]$ s, το οποίο αντιστοιχεί σε σενάριο έγκαιρης προειδοποίησης. Η αξιολόγηση επεκτείνεται και σε οριζο-

ντες εκτός του εύρους εκπαίδευσης, ώστε να εξεταστεί η χρονική γενίκευση του μοντέλου.

2. Πολυτροπική σύντηξη μέσω multi-branch αρχιτεκτονικής. Σχεδιασμός αρχιτεκτονικής τριών κλάδων, οι οποίοι επεξεργάζονται κινηματική πληροφορία, τοπικά οπτικά χαρακτηριστικά και global scene context. Η σύντηξη των κλάδων πραγματοποιείται μέσω attention-based late fusion, με στόχο την αξιοποίηση συμπληρωματικών πηγών πληροφορίας.
3. Συστηματική ανάλυση της συνεισφοράς κάθε κλάδου. Διερεύνηση του ρόλου κάθε κλάδου μέσω αξιολόγησης των auxiliary heads, branch-zeroing ablation και ανάλυσης συσχέτισης σφαλμάτων. Στόχος είναι να τεκμηριωθεί η συμπληρωματικότητα των επιμέρους πηγών πληροφορίας και η μεταβολή της συνεισφοράς τους ανάλογα με τον χρονικό ορίζοντα πρόβλεψης.
4. Αξιολόγηση χρονικής σταθερότητας των προβλέψεων. Μελέτη της χρονικής συνοχής των προβλέψεων σε διαδοχικά παράθυρα παρατήρησης του ίδιου πεζού. Η σταθερότητα αυτή είναι σημαντική για εφαρμογές αυτόνομης οδήγησης, όπου οι απότομες διακυμάνσεις στις προβλέψεις μπορούν να οδηγήσουν σε ασυνεπείς downstream αποφάσεις.
5. Διερεύνηση cross-dataset γενίκευσης. Αξιολόγηση της δυνατότητας μεταφοράς του μοντέλου μεταξύ διαφορετικών datasets, και συγκεκριμένα μεταξύ PIE και JAAD. Για τον σκοπό αυτό εξετάζονται τρεις στρατηγικές εκπαίδευσης: PIE-only, JAAD→PIE transfer learning και Combined JAAD+PIE training. Επιπλέον, αναλύεται η μεταφερσιμότητα των επιμέρους κλάδων της αρχιτεκτονικής.
6. Διερεύνηση εναλλακτικού global context encoder. Σύγκριση της κύριας Conv3D-based υλοποίησης του global context branch με μια εναλλακτική παραλλαγή βασισμένη σε Spatial-Patch Transformer. Στόχος είναι να διερευνηθεί αν η patch-based attention μοντελοποίηση μπορεί να αποτυπώσει αποτελεσματικότερα τις χωρικές σχέσεις της σκηνής, όπως η θέση του πεζού σε σχέση με το οδόστρωμα, τις διαβάσεις, τα οχήματα και τις περιοχές αναμονής.
7. Ανάπτυξη ελαφριάς kinematic-anchored παραλλαγής. Με βάση το εύρημα ότι το κινηματικό σήμα αποτελεί ιδιαίτερα ισχυρή πηγή πληροφορίας, σχεδιάζεται και αξιολογείται η KinFormer-GRU, μια ελαφριά παραλλαγή που διατηρεί τον GRU-based κινηματικό κλάδο ως anchor και εισάγει επιλεγμένο scene context ως gated contextual tokens μέσω per-frame Transformer. Στόχος είναι να διερευνηθεί αν η πληροφορία σκηνής μπορεί να αξιοποιηθεί συμπληρωματικά, χωρίς να αποκτά ανεξάρτητη late-fusion ψήφο, και να αξιολογηθεί το trade-off μεταξύ απόδοσης και παραμετρικής αποδοτικότητας.

Η Δομή της εργασίας είναι η παρακάτω:

- Στο Κεφάλαιο 2 παρουσιάζεται η βιβλιογραφική ανασκόπηση των υφιστάμενων μεθόδων πρόβλεψης πρόθεσης πεζού. Η ανασκόπηση περιλαμβάνει βασικά datasets, κατηγοριοποίηση των προσεγγίσεων βάσει χρονικού ορίζοντα, χαρα-

κτηριστικών και αρχιτεκτονικής, καθώς και ανάλυση αντιπροσωπευτικών πολυτροπικών Transformer-based πλαισίων.

- Στο Κεφάλαιο 3 παρουσιάζεται η μεθοδολογία της εργασίας. Περιγράφονται το offline preprocessing pipeline, η κατασκευή των δειγμάτων, η προτεινόμενη πολυκλαδική αρχιτεκτονική PIPN, ο μηχανισμός σύντηξης μέσω προσοχής, οι στρατηγικές εκπαίδευσης πολλαπλών datasets, η εναλλακτική Spatial-Patch Transformer υλοποίηση του global context branch και η ελαφριά KinFormer-GRU παραλλαγή, η οποία εισάγει το scene context ως gated contextual tokens γύρω από έναν κινηματικό anchor.
- Στο Κεφάλαιο 4 παρουσιάζονται τα πειραματικά αποτελέσματα. Αρχικά αξιολογείται η κύρια Conv3D-based αρχιτεκτονική στο PIE benchmark και σε πολλαπλούς χρονικούς ορίζοντες. Στη συνέχεια πραγματοποιείται σύγκριση με τη βιβλιογραφία, ανάλυση σταθερότητας, μελέτη αφαίρεσης και συνεισφοράς των κλάδων, αξιολόγηση cross-dataset γενίκευσης και σύγκριση με τις Transformer-based παραλλαγές. Ιδιαίτερη έμφαση δίνεται στην αξιολόγηση της KinFormer-GRU μέσω modality ablations, gate experiments και multi-horizon σύγκρισης με το PIPN.
- Στο Κεφάλαιο 5 συνοψίζονται τα βασικά συμπεράσματα της εργασίας, παρουσιάζονται οι κύριες συνεισφορές και συζητούνται οι περιορισμοί και οι πιθανές μελλοντικές ερευνητικές κατευθύνσεις.

Κεφάλαιο 2 Βιβλιογραφική Ανασκόπηση

2.1 Εισαγωγή στο Κεφάλαιο

Η βιβλιογραφία στο πεδίο της πρόβλεψης πρόθεσης πεζού έχει εξελιχθεί από πρώιμες προσεγγίσεις που βασίζονταν κυρίως στην τροχιά ή στη θέση του πεζού προς σύγχρονες πολυτροπικές αρχιτεκτονικές, οι οποίες συνδυάζουν πληροφορίες εμφάνισης, κίνησης, στάσης σώματος, δυναμικής οχήματος και συμφραζομένων σκηνης. Η εξέλιξη αυτή αντανακλά τη φύση του προβλήματος: η πρόθεση διάσχισης δεν μπορεί να εκτιμηθεί πάντα αξιόπιστα από μία μόνο πηγή πληροφορίας, αλλά απαιτεί συνδυασμό pedestrian-centric και scene-level ενδείξεων.

Στο παρόν κεφάλαιο παρουσιάζονται αρχικά τα βασικά σύνολα δεδομένων που χρησιμοποιούνται στη βιβλιογραφία για pedestrian intention και crossing prediction. Στη συνέχεια, οι υφιστάμενες προσεγγίσεις κατηγοριοποιούνται βάσει χρονικού ορίζοντα πρόβλεψης, τύπου χαρακτηριστικών και αρχιτεκτονικής μοντέλου. Ακολούθως, παρουσιάζεται το τεχνολογικό υπόβαθρο βασικών modules που χρησιμοποιούνται σε σύγχρονα πολυτροπικά pipelines, όπως semantic/panoptic segmentation, optical flow, monocular depth estimation, pose estimation και attention-based μοντελοποίηση. Τέλος, αναλύονται αντιπροσωπευτικά πολυτροπικά πλαίσια και συνοψίζονται τα ερευνητικά κενά στα οποία τοποθετείται η παρούσα εργασία.

2.2 Σύνολα Δεδομένων

Η ανάπτυξη και αξιολόγηση μεθόδων πρόβλεψης πρόθεσης πεζού εξαρτάται σε μεγάλο βαθμό από την ποιότητα, την ποικιλομορφία και τον τύπο των διαθέσιμων annotations. Τα datasets του πεδίου διαφέρουν ως προς το μέγεθος, τις συνθήκες λήψης, τη γεωγραφική κατανομή, τη διαθεσιμότητα πληροφορίας ego-vehicle, τον ορισμό της ετικέτας crossing/intention και τη μορφή των χωρικών ή συμπεριφορικών επισημάνσεων. Οι διαφορές αυτές επηρεάζουν άμεσα τη συγκρισιμότητα μεταξύ μεθόδων και τη δυνατότητα γενίκευσης ενός μοντέλου σε διαφορετικά domains.

Στην ενότητα αυτή παρουσιάζονται τέσσερα αντιπροσωπευτικά datasets της βιβλιογραφίας: JAAD, PIE, TITAN και Urban-PIP. Ιδιαίτερη έμφαση δίνεται στα JAAD και PIE, καθώς αποτελούν τα βασικά datasets που σχετίζονται άμεσα με την παρούσα εργασία. Τα TITAN και Urban-PIP παρουσιάζονται συμπληρωματικά, καθώς επεκτείνουν τη βιβλιογραφική εικόνα προς πιο γενικές μορφές ανθρώπινης συμπεριφοράς, action priors και πραγματικά AV-based σενάρια με διαφορετικές πηγές domain bias.

Στην παρούσα εργασία, ο όρος «πρόβλεψη πρόθεσης πεζού» χρησιμοποιείται με την επιχειρησιακή έννοια που υιοθετείται στη σχετική βιβλιογραφία: το μοντέλο καλείται, με βάση ένα χρονικό παράθυρο παρατήρησης πριν από τη διάσχιση, να προβλέψει αν ο πεζός θα ανήκει σε crossing ή non-crossing περίπτωση. Επομένως, το training target διατυπώνεται ως δυαδική ταξινόμηση crossing/non-crossing. Η χρονική τοποθέτηση των δειγμάτων πριν από την ενέργεια διάσχισης, σε συνδυασμό με τη χρήση hard-negative non-crossing περιπτώσεων, καθιστά το πρόβλημα εκτίμηση πρόθεσης και όχι απλή ανα-

γνώριση ήδη εκτελεσμένης δράσης. Για τον λόγο αυτό, ιδιαίτερη σημασία δίνεται στη διαθεσιμότητα αξιόπιστων crossing/non-crossing labels και στην ποιότητα των non-crossing δειγμάτων κάθε dataset.

2.2.1 JAAD (Joint Attention in Autonomous Driving)

Το JAAD (Joint Attention in Autonomous Driving) αποτελεί ένα από τα πρώτα σημαντικά datasets για τη μελέτη της συμπεριφοράς πεζών από onboard κάμερα στο πλαίσιο της αυτόνομης οδήγησης. Σχεδιάστηκε με στόχο τη μελέτη της αλληλεπίδρασης μεταξύ πεζών και οχημάτων, δίνοντας έμφαση όχι μόνο στη χωρική θέση του πεζού, αλλά και σε συμπεριφορικά στοιχεία που σχετίζονται με τη διάσχιση, όπως η κίνηση, η στάση, η οπτική επαφή και η ενέργεια crossing/non-crossing [14].

Το dataset αποτελείται από 346 σύντομα video clips, τα οποία απεικονίζουν πεζούς σε αστικά οδικά σενάρια πριν ή κατά τη διάρκεια πιθανών crossing events. Τα δεδομένα έχουν συλλεχθεί σε περιοχές της Βόρειας Αμερικής και της Ευρώπης, υπό ποικίλες συνθήκες φωτισμού και περιβάλλοντος. Η ποικιλομορφία αυτή καθιστά το JAAD χρήσιμο για τη μελέτη pedestrian behavior σε διαφορετικά αστικά περιβάλλοντα, αν και η κατανομή των σκηνών εξακολουθεί να εισάγει συγκεκριμένο domain bias.

Ένα βασικό πλεονέκτημα του JAAD είναι η ύπαρξη πλούσιων χωρικών και συμπεριφορικών annotations. Περιλαμβάνει bounding boxes πεζών, καθώς και ετικέτες συμπεριφοράς όπως crossing, not crossing, walking, standing, looking και not looking. Με αυτόν τον τρόπο, το dataset υπερβαίνει την απλή ανίχνευση πεζών και επιτρέπει τη μελέτη της συμπεριφοράς τους σε σχέση με πιθανή διάσχιση.

Χαρακτηριστικό	Τιμή
Video clips	346
Annotated frames	82,032
Pedestrians with behavior annotations	686
Total pedestrians	2,786
Pedestrian bounding boxes	378,643
Average pedestrian track length	121 frames
Crossing pedestrians	495
Non-crossing pedestrians	191

Πίνακας 2.1: Βασικά στατιστικά του JAAD dataset.

Παρά την αξία του, το JAAD παρουσιάζει ορισμένους περιορισμούς ως προς τη χρήση του στο συγκεκριμένο πειραματικό πρωτόκολλο της παρούσας εργασίας. Οι ετικέτες crossing/non-crossing του dataset βασίζονται κυρίως στην παρατηρούμενη συμπεριφορά του πεζού και όχι σε ξεχωριστό ανθρώπινο πείραμα εκτίμησης πρόθεσης, όπως στο PIE. Αυτό δεν μειώνει τη χρησιμότητα του JAAD ως dataset για τη μελέτη pedestrian behavior, transfer learning και cross-dataset αξιολόγηση. Ωστόσο, σημαίνει ότι η διάκριση crossing/non-crossing δεν μπορεί πάντα να ερμηνευθεί με τον ίδιο τρόπο όπως στο PIE, όπου το task συνδέεται πιο άμεσα με το pedestrian crossing intention estimation.

Για παράδειγμα, ένας πεζός που βρίσκεται κοντά στο οδόστρωμα και αναμένει το

πέραςμα ενός οχήματος μπορεί προσωρινά να εμφανίζεται ως non-crossing, παρότι ενδέχεται να διασχίσει αργότερα. Αντίστοιχα, οι πρόσθετοι non-crossing μπορεί να βρίσκονται κυρίως στο πεζοδρόμιο ή να μην συμμετέχουν άμεσα σε αμφίσημα crossing scenarios. Επομένως, το JAAD δεν επιτρέπει πάντα την ίδια καθαρή κατασκευή hard-negative δειγμάτων, δηλαδή non-crossing περιπτώσεων που είναι χωρικά και συμπεριφορικά κοντά σε πραγματικές crossing περιπτώσεις.

Ένας δεύτερος περιορισμός αφορά τη διαθέσιμη πληροφορία κίνησης του οχήματος. Το JAAD δεν παρέχει ισοδύναμη πληροφορία ego-vehicle speed. Αντίθετα, η πληροφορία κίνησης του οχήματος περιγράφεται πιο αφαιρετικά μέσω κατηγοριών ή ετικετών οδηγικής συμπεριφοράς. Ο περιορισμός αυτός είναι σημαντικός για πολυτροπικά μοντέλα που αξιοποιούν τη δυναμική του ego-vehicle ως μέρος του κινηματικού κλάδου.

Συνολικά, το JAAD αποτελεί σημαντικό dataset για τη μελέτη pedestrian-vehicle interaction και pedestrian crossing behavior. Η γεωγραφική και περιβαλλοντική ποικιλιομορφία του το καθιστά χρήσιμο για προεκπαίδευση, transfer learning και cross-dataset αξιολόγηση. Ωστόσο, η απουσία human intention reference data, η διαφορετική φύση των crossing/non-crossing labels και η έλλειψη συνεχούς ego-vehicle speed πρέπει να λαμβάνονται υπόψη κατά τη σύγκρισή του με το PIE και κατά την ερμηνεία των αποτελεσμάτων στο JAAD.

2.2.2 PIE (Pedestrian Intention Estimation)

Το PIE (Pedestrian Intention Estimation) δημιουργήθηκε με στόχο να επεκτείνει τη μελέτη της συμπεριφοράς πεζών πέρα από την απλή αναγνώριση δράσης διάσχισης, εισάγοντας ένα πιο συστηματικό πλαίσιο για το πρόβλημα της πρόβλεψης πρόθεσης διάσχισης. Σε αντίθεση με datasets όπως το JAAD, τα οποία βασίζονται κυρίως σε παρατηρούμενες συμπεριφορικές ετικέτες, το PIE υποστηρίζει τη διατύπωση του προβλήματος ως δυαδική πρόβλεψη crossing/non-crossing στο πλαίσιο του pedestrian crossing intention estimation. Στην παρούσα εργασία, το training target διατυπώνεται ως δυαδική ταξινόμηση crossing/non-crossing, ενώ η έννοια της πρόθεσης προκύπτει από το γεγονός ότι η πρόβλεψη πραγματοποιείται πριν από την ολοκλήρωση της διάσχισης και σε χρονικούς ορίζοντες που προηγούνται της τελικής ενέργειας. Για τον λόγο αυτό, το PIE αποτελεί το κύριο dataset αξιολόγησης της παρούσας εργασίας [5].

Το dataset περιλαμβάνει περίπου 6 ώρες βίντεο από onboard κάμερα, καταγεγραμμένες σε αστικές σκηνές στο Τορόντο του Καναδά. Τα βίντεο είναι οργανωμένα σε περίπου δεκάλεπτα τμήματα και συνολικά περιλαμβάνουν περίπου 911K frames, από τα οποία περίπου 293K είναι annotated frames. Το PIE περιλαμβάνει 1.842 pedestrian samples, περίπου 740K pedestrian bounding boxes και μέσο μήκος pedestrian track περίπου 401 frames. Τα χαρακτηριστικά αυτά το καθιστούν σημαντικά πλουσιότερο από το JAAD ως προς τη διάρκεια και τη λεπτομέρεια των διαθέσιμων annotations ανά pedestrian track.

Ένα από τα βασικά πλεονεκτήματα του PIE είναι ότι συνοδεύεται από human intention reference data, τα οποία προέκυψαν μέσω ανθρώπινου πειράματος. Οι συμμετέχοντες παρακολουθούσαν σύντομα βίντεο στα οποία επισημαινόταν ένας πεζός ενδιαφέροντος και απαντούσαν στο ερώτημα αν ο πεζός επιθυμεί να διασχίσει τον δρόμο. Το πείραμα πραγματοποιήθηκε τόσο σε εργαστηριακό περιβάλλον όσο και μέσω Amazon Mechanical Turk, συγκεντρώνοντας συνολικά 27.630 απαντήσεις από περισσότερους από

700 συμμετέχοντες. Η ύπαρξη αυτών των human reference data ενισχύει τη σύνδεση του PIE με το πρόβλημα της εκτίμησης πρόθεσης διάσχισης, χωρίς όμως να αναιρεί ότι, στο πειραματικό πρωτόκολλο της παρούσας εργασίας, το μοντέλο εκπαιδεύεται τελικά σε δυαδικές crossing/non-crossing ετικέτες.

Επιπλέον, το PIE παρέχει πλούσια πληροφορία για το πλαίσιο της σκηνής και τη δυναμική του ego-vehicle. Μέσω συγχρονισμένου OBD-II sensor καταγράφονται στοιχεία όπως η ταχύτητα του οχήματος, το heading angle και οι GPS συντεταγμένες. Παράλληλα, παρέχονται spatial annotations για πεζούς, οχήματα και στοιχεία υποδομής, όπως σηματοδότες, πινακίδες, διαβάσεις και όρια δρόμου. Αυτά τα χαρακτηριστικά καθιστούν το PIE ιδιαίτερα κατάλληλο για πολυτροπικά μοντέλα που αξιοποιούν όχι μόνο την κίνηση και την εμφάνιση του πεζού, αλλά και τη δυναμική του οχήματος και το ευρύτερο περιβάλλον της σκηνής.

Ο Πίνακας 2.2 συνοψίζει τις βασικές διαφορές μεταξύ PIE και JAAD, με έμφαση όχι μόνο στο μέγεθος των datasets, αλλά και στη φύση των crossing/non-crossing labels και στη διαθεσιμότητα ego-vehicle πληροφορίας.

Χαρακτηριστικό	PIE	JAAD
Frames	911K	82K
Annotated frames	293K	75K
Pedestrians	1.8K	2.8K
Pedestrians with behavior annotations	1.8K	686
Pedestrian bounding boxes	740K	391K
Average pedestrian track length	401 frames	140 frames
Crossing pedestrians	519	495
Non-crossing pedestrians	1,323	191
Pedestrian intention labels	Yes	No
Ego-vehicle sensor information	Yes	No

Πίνακας 2.2: Σύγκριση βασικών χαρακτηριστικών των PIE και JAAD datasets.

Σε σύγκριση με το JAAD, το PIE προσφέρει δύο κρίσιμα πλεονεκτήματα για την παρούσα εργασία. Πρώτον, επιτρέπει πιο καθαρή διατύπωση του προβλήματος ως crossing intention estimation, καθώς το δυαδικό crossing/non-crossing target συνδέεται με χρονική πρόβλεψη πριν από την τελική ενέργεια και υποστηρίζεται από human intention reference data. Δεύτερον, περιλαμβάνει συγχρονισμένη πληροφορία ego-vehicle, στοιχείο ιδιαίτερα σημαντικό για τον κινηματικό κλάδο της προτεινόμενης αρχιτεκτονικής. Η ταχύτητα και η κατεύθυνση του οχήματος επηρεάζουν άμεσα τη σχετική δυναμική πεζού-οχήματος και το διαθέσιμο χρονικό περιθώριο αντίδρασης.

Παρά τα πλεονεκτήματά του, το PIE παρουσιάζει και ορισμένους περιορισμούς. Τα δεδομένα έχουν συλλεχθεί σε μία πόλη και κυρίως υπό σχετικά καλές συνθήκες λήψης, γεγονός που μπορεί να εισάγει domain bias. Επιπλέον, η ύπαρξη πλούσιων annotations και ego-vehicle sensor data καθιστά το dataset πολύ χρήσιμο για ανάπτυξη πολυτροπικών μοντέλων, αλλά μπορεί να δυσχεραίνει την άμεση μεταφορά των ίδιων εισόδων σε datasets που δεν παρέχουν αντίστοιχη πληροφορία, όπως το JAAD. Για τον λόγο αυτό, στην παρούσα εργασία το PIE χρησιμοποιείται ως κύριο benchmark, ενώ το JAAD αξιοποιείται


συμπληρωματικά για transfer learning, Combined training και cross-dataset αξιολόγηση.

Συνολικά, το PIE αποτελεί το καταλληλότερο dataset για την κύρια αξιολόγηση της παρούσας εργασίας, καθώς συνδυάζει δυαδική crossing/non-crossing διατύπωση, human intention reference data, πλούσιες χωρικές επισημάνσεις και ego-vehicle δυναμική πληροφορία. Τα χαρακτηριστικά αυτά το καθιστούν ιδιαίτερα συμβατό με τον σχεδιασμό της προτεινόμενης πολυκλαδικής αρχιτεκτονικής PIPN, η οποία συνδυάζει κινηματικές, τοπικές οπτικές και καθολικές πληροφορίες σκηνής.

2.2.3 TITAN (Future Forecast Using Action Priors)

Το TITAN (Trajectory Inference using Targeted Action priors Network) ένα μεγάλο egocentric driving dataset για πρόβλεψη μελλοντικής τροχιάς και συμπεριφοράς πρακτόρων σε αστικά περιβάλλοντα. Σε αντίθεση με datasets όπως το PIE και το JAAD, τα οποία χρησιμοποιούνται κυρίως για pedestrian crossing ή intention prediction, το TITAN σχεδιάστηκε πρωτίστως για future trajectory forecasting από οπτική κινούμενου οχήματος, αξιοποιώντας προηγούμενες θέσεις, actions και context ως priors. Το dataset περιλαμβάνει περίπου 700 labeled video clips, καταγεγραμμένα από κινούμενο όχημα σε αστικές σκηνές υψηλής αλληλεπίδρασης στο Tokyo, με χρήση κάμερας GoPro Hero 7 και συγχρονισμένης πληροφορίας από IMU sensor [15].

Κύριο χαρακτηριστικό του TITAN είναι το πλούσιο σύστημα επισημείωσης ενεργειών. Το dataset περιλαμβάνει περίπου 50 labels, τα οποία καλύπτουν vehicle states/actions, pedestrian age groups και targeted pedestrian action attributes. Οι ενέργειες



Σχήμα 2.1: TITAN Data Distribution

οργανώνονται ιεραρχικά σε κατηγορίες όπως atomic actions, simple/complex contextual actions, transportive actions και communicative actions. Παραδείγματα τέτοιων ετικετών είναι ενέργειες όπως standing, running, waiting to cross, jaywalking, pushing cart, looking at driver ή using phone. Η λεπτομερής αυτή επισημείωση καθιστά το TITAN ιδιαίτερα χρήσιμο για μοντέλα που αξιοποιούν action priors για την πρόβλεψη μελλοντικής τροχιάς και ego-motion.

Στο πλαίσιο της παρούσας εργασίας, διερευνήθηκε η πιθανότητα αξιοποίησης του TITAN ως πρόσθετης πηγής δεδομένων. Η πρόσβαση στο dataset ζητήθηκε και αποκτήθηκε μέσω της Honda Research Institute, καθώς το TITAN διατίθεται σε ερευνητές μέσω επίσημης διαδικασίας πρόσβασης. Ωστόσο, κατά την αρχική διερεύνηση διαπιστώθηκε ότι

το dataset δεν είναι πλήρως ευθυγραμμισμένο με το συγκεκριμένο πρόβλημα της παρούσας εργασίας, δηλαδή τη δυαδική πρόβλεψη πρόθεσης διάσχισης πεζού. Το TITAN εστιάζει κυρίως σε action priors και trajectory forecasting, και όχι σε ρητή crossing/non-crossing intention ετικέτα αντίστοιχη με αυτή του PIE. Ακόμη και αν ετικέτες όπως jaywalking συνυπολογιστούν ως πιθανές crossing περιπτώσεις, το διαθέσιμο πλήθος άμεσα αξιοποιήσιμων crossing samples παραμένει περιορισμένο για το συγκεκριμένο πειραματικό πρωτόκολλο.

Ένας επιπλέον περιορισμός αφορά τη διαθέσιμη πληροφορία κίνησης του οχήματος. Το TITAN περιλαμβάνει συγχρονισμένη ego-motion πληροφορία μέσω IMU sensor και labels που σχετίζονται με vehicle states/actions, όμως η πληροφορία αυτή δεν είναι άμεσα ισοδύναμη με την αριθμητική ταχύτητα ego-vehicle που παρέχει το PIE μέσω OBD-II. Για την παρούσα εργασία, όπου ο kinematic branch αξιοποιεί συνεχή δυναμική πληροφορία οχήματος, η απουσία άμεσα συγκρίσιμου σήματος ταχύτητας δυσχεραίνει την ένταξη του TITAN στο ίδιο pipeline χωρίς πρόσθετες μετατροπές ή αναπροσαρμογές των features. Το PIE, αντίθετα, παρέχει ρητά vehicle speed, heading direction και GPS συγχρονισμένα με το video footage.

Επιπλέον, το TITAN έχει συλλεχθεί σε αστικό περιβάλλον της Ιαπωνίας, όπου η κυκλοφορία πραγματοποιείται στην αριστερή πλευρά του δρόμου. Η διαφορά αυτή δημιουργεί πιθανό spatial domain bias σε σχέση με datasets όπως το PIE, το οποίο έχει συλλεχθεί στον Καναδά, σε περιβάλλον δεξιάς κυκλοφορίας. Θεωρητικά, η χωρική αυτή ασυμμετρία θα μπορούσε να αντιμετωπιστεί μέσω mirror augmentation, ώστε να μειωθεί η εξάρτηση του μοντέλου από τη διάταξη κυκλοφορίας. Ωστόσο, στο πλαίσιο της παρούσας εργασίας η χρήση mirror augmentation για το TITAN εξετάστηκε μόνο ως θεωρητική δυνατότητα και δεν ενσωματώθηκε στα κύρια πειράματα.

Συνολικά, το TITAN αποτελεί σημαντικό dataset για future trajectory forecasting και action-prior learning σε αστικές σκηνές. Παρόλα αυτά, δεν επιλέχθηκε ως βασικό dataset εκπαίδευσης στην παρούσα εργασία, καθώς ο σχεδιασμός του δεν αντιστοιχεί πλήρως στο πρόβλημα crossing intention prediction. Οι περιορισμοί ως προς το πλήθος άμεσα αξιοποιήσιμων crossing samples, τη μη ισοδύναμη πληροφορία ego-vehicle speed και το διαφορετικό domain συλλογής καθιστούν τη χρήση του λιγότερο κατάλληλη για το συγκεκριμένο πειραματικό πρωτόκολλο. Για τον λόγο αυτό, η παρούσα εργασία επικεντρώνεται στα PIE και JAAD για την κύρια πειραματική αξιολόγηση, ενώ το TITAN διατηρείται στη βιβλιογραφική ανασκόπηση ως σημαντικό παράδειγμα dataset με πλούσια action-prior annotations.

2.2.4 Urban-PIP

Το Urban-PIP παρουσιάστηκε στο πλαίσιο του PIP-Net [8] και αποτελεί ένα πρόσφατο dataset προσαρμοσμένο στο πρόβλημα της πρόβλεψης πρόθεσης διάσχισης πεζού σε πραγματικά σενάρια αυτόνομης οδήγησης. Σε αντίθεση με datasets όπως το JAAD και το PIE, βασίζεται σε δεδομένα του Waymo Open Dataset, αξιοποιώντας πραγματικές σκηνές από αυτόνομα οχήματα και επεκτείνοντάς τις με ειδικές επισημάνσεις pedestrian crossing intention.

Κύριο χαρακτηριστικό του Urban-PIP είναι η αξιοποίηση multi-camera πληροφορίας. Συγκεκριμένα, οι συγγραφείς χρησιμοποίησαν τρεις εμπρόσθιες κάμερες — front-


left, front και front-right — και επισημείωσαν συνολικά 1.481 crossing intentions. Η χρήση πλευρικών εμπρόσθιων καμερών είναι ιδιαίτερα σημαντική για πραγματικά συστήματα πρόβλεψης πρόθεσης, καθώς οι πεζοί συχνά εμφανίζονται αρχικά στα όρια του οπτικού πεδίου και όχι αποκλειστικά στην κεντρική κάμερα.

Παρότι το Urban-PIP αποτελεί ενδιαφέρουσα κατεύθυνση για μελλοντικά multi-camera pedestrian intention μοντέλα, δεν χρησιμοποιήθηκε στην παρούσα εργασία. Ο βασικός λόγος είναι ότι οι πρόσθετες crossing-intention επισημάνσεις του Urban-PIP δεν αποτελούν καθιερωμένο και άμεσα διαθέσιμο benchmark με τη μορφή των JAAD και PIE. Για τον λόγο αυτό, το Urban-PIP παρουσιάζεται στη βιβλιογραφική ανασκόπηση ως ένδειξη της μετάβασης του πεδίου προς multi-camera, AV-based και context-rich datasets, αλλά δεν ενσωματώνεται στο πειραματικό pipeline της παρούσας εργασίας λόγω μην ελεύθερης πρόσβασης στο συγκεκριμένο dataset.

Στη σύγκριση που ακολουθεί, ιδιαίτερη σημασία δίνεται όχι απλώς στην ύπαρξη γενικών action ή behavior labels, αλλά στη διαθεσιμότητα άμεσα αξιοποιήσιμων crossing/non-crossing ετικετών. Η διάκριση αυτή είναι κρίσιμη για την παρούσα εργασία, καθώς το πρόβλημα διατυπώνεται ως δυαδική ταξινόμηση πρόθεσης διάσχισης και η ποιότητα των non-crossing ή hard-negative δειγμάτων επηρεάζει άμεσα την εκπαίδευση και αξιολόγηση του μοντέλου


2.3 Κατηγοριοποίηση των Υφιστάμενων Προσεγγίσεων

Σε γενικές γραμμές, ένα σύστημα πρόβλεψης πρόθεσης πεζού ακολουθεί τρία διαδοχικά στάδια: το στάδιο εισόδου (ακολουθίες frames από onboard κάμερα), το στάδιο εξαγωγής και κωδικοποίησης χαρακτηριστικών, όπου εξάγονται και συντίθενται χωροχρονικά cues όπως pose, trajectory, head orientation, ego-vehicle dynamics και scene knowledge, και το στάδιο ταξινόμησης/αποκωδικοποίησης, το οποίο παράγει την τελική crossing/non-crossing πρόβλεψη [10]. Το γενικευμένο αυτό πλαίσιο απεικονίζεται στο Σχήμα 2.2 [16]. Σημειώνεται ότι το ίδιο πλαίσιο καλύπτει και τη συγγενή εργασία της εκτίμησης τροχιάς (trajectory estimation): στην παρούσα εργασία, ωστόσο, το ενδιαφέρον επικεντρώνεται αποκλειστικά στον κλάδο της crossing prediction γεγονός που καθοδηγεί σχεδιασμό της προτεινόμενης αρχιτεκτονικής. Με βάση το πλαίσιο αυτό, οι υφιστάμενες



Σχήμα 2.2: Γενικευμένο πλαίσιο πρόβλεψης πρόθεσης πεζού

προσεγγίσεις μπορούν να ταξινομηθούν συστηματικά γύρω από τρεις θεμελιώδεις άξονες: τον χρονικό ορίζοντα της πρόβλεψης, το είδος των χαρακτηριστικών που αξιοποιούνται και τον τύπο/αρχιτεκτονική του μοντέλου. Η τριμερής αυτή ταξινόμηση αποτυπώνεται στο Σχήμα 2.3 και ακολουθεί τη δομή της ανασκόπησης των Mirzabagheri et al. (2025) [10]. Όπως φαίνεται στο σχήμα, ο πρώτος άξονας διάρκειας πρόβλεψης και ο τρίτος επιλεγμένα χαρακτηριστικά αντιστοιχούν άμεσα στις Ενότητες 2.3.1 και 2.3.2. Ο δεύτερος άξονας, ο οποίος στην αρχική ανασκόπηση διακρίνει knowledge-based, deep learning και ensemble προσεγγίσεις, εξειδικεύεται στην παρούσα εργασία στο επίπεδο της νευρωνικής αρχιτεκτονικής (Ενότητα 2.3.3). Η εξειδίκευση αυτή είναι σκόπιμη: καθώς το σύγχρονο πεδίο έχει ουσιαστικά συγκλίνει στις deep learning προσεγγίσεις ενώ οι knowledge-based μέθοδοι έχουν πλέον κυρίως ιστορική αξία και τα ensembles αποτελούν στρατηγική συνδυασμού παρά διακριτή οικογένεια μοντέλων η ανάλυση εστιάζει στις επιμέρους αρχιτεκτονικές οικογένειες (RNN/LSTM/GRU, CNN, Transformer, Graph-based, Hybrid) που σχετίζονται άμεσα με τον σχεδιασμό της προτεινόμενης αρχιτεκτονικής.



Σχήμα 2.3: Ταξινόμηση των προσεγγίσεων πρόβλεψης πρόθεσης πεζού


2.3.1 Βάσει Χρονικού Ορίζοντα Πρόβλεψης

Ο χρονικός ορίζοντας αποτελεί θεμελιώδη παράμετρο, καθώς επηρεάζει ταυτόχρονα το είδος των χαρακτηριστικών που απαιτούνται και την πρακτική χρησιμότητα του συστήματος.

- Βραχυπρόθεσμη πρόβλεψη (short-term, 0–2 s). Οι προσεγγίσεις αυτές εστιάζουν στην αναγνώριση της άμεσης ενέργειας του πεζού walking, stopping, crossing, waiting αξιοποιώντας κυρίως άμεσα παρατηρήσιμα cues, όπως ο προσανατολισμός του κεφαλιού και οι μεταβολές του bounding box. Είναι υπολογιστικά αποδοτικές και κατάλληλες για real-time εφαρμογές, ωστόσο το εξαιρετικά μικρό χρονικό περιθώριο που προσφέρουν περιορίζει σημαντικά το εύρος ασφαλών ελιγμών του οχήματος σε αστικές ταχύτητες.
- Μακροπρόθεσμη πρόβλεψη (long-term, >3–4 s). Οι προσεγγίσεις αυτές είναι περισσότερο goal-oriented και συνήθως σχετίζονται με εκτίμηση μελλοντικής τροχιάς ή τελικού προορισμού. Απαιτούν πλουσιότερο περιβαλλοντικό context

(δομή δρόμου, κοινωνικές αλληλεπιδράσεις), αλλά είναι ευάλωτες σε ξαφνικές μεταβολές της απόφασης του πεζού, καθώς σε μεγαλύτερο χρονικό παράθυρο οι συνθήκες της σκηνής μεταβάλλονται διαρκώς.

Λαμβάνοντας υπόψη τους περιορισμούς και των δύο κατηγοριών, η παρούσα εργασία υιοθετεί έγκαιρη πρόβλεψη (early prediction) σε ορίζοντα 0,5–4 s πριν το συμβάν διάσχισης. Το διάστημα αυτό ευθυγραμμίζεται τόσο με την «κρίσιμη περίοδο» (critical period) που ορίζει το CIPF [13], όσο και με τη φιλοσοφία της «decisive moment» του PIP-Net [8], ενώ είναι συμβατό και με το καθιερωμένο πρωτόκολλο PIE/JAAD, στο οποίο τα δείγματα τοποθετούνται περίπου στα 2 s πριν τη διάσχιση το ελάχιστο διάστημα εντός του οποίου ο πεζός λαμβάνει συνήθως την απόφασή του. Η επιλογή αυτή παρέχει επαρκή χρόνο αντίδρασης για ομαλή επιβράδυνση, διατηρώντας ταυτόχρονα υψηλή ακρίβεια σε αμφίσημες καταστάσεις, όπως η αναμονή στο κράσπεδο.



Σχήμα 2.4: Χρονικό μοντέλο της έγκαιρης πρόβλεψης πρόθεσης.

Το παράθυρο παρατήρησης ορίζεται τυπικά στα ~0.5 s, ενώ ο χρονικός ορίζοντας πρόβλεψης (Time-To-Event) κυμαίνεται από 1 έως 4 s πριν από το κρίσιμο καρέ της διάσχισης.

2.3.2 Βάσει Χαρακτηριστικών (Features)

Η εξέλιξη των μεθόδων ως προς τα χαρακτηριστικά ακολουθεί μια σαφή πορεία: από την απλή κινηματική παρακολούθηση του πεζού, στη λεπτομερή ανάλυση της στάσης του, στη συνέχεια στην ενσωμάτωση του περιβάλλοντος και, τελικά, στις πολυτροπικές προσεγγίσεις. Κάθε βήμα δικαιολογείται από τους περιορισμούς του προηγούμενου [10].

- 1. Κινηματικές προσεγγίσεις (Kinematic / Trajectory-based):** Τα πρώτα συστήματα αντιμετώπιζαν τον πεζό ως ένα άκαμπτο αντικείμενο στον χώρο, βασιζόμενα αποκλειστικά στην ιστορική κίνηση του bounding box. Η ακολουθία θέσεων κωδικοποιείται χρονικά (συνήθως με LSTM/GRU) για την πρόβλεψη της διάσχισης. Είναι απλές και αποδοτικές μέθοδοι, αλλά αποτυγχάνουν σε σκηνές όπου η διάσχιση δεν έχει ξεκινήσει ή η κίνηση είναι παράλληλη προς τον δρόμο· σε αυτές τις περιπτώσεις γίνονται αντιδραστικές και χάνουν την υποκείμενη πρόθεση [5].
- 2. Προσεγγίσεις λεπτομερούς ανάλυσης πεζού (Fine-grained Pedestrian-centric / Appearance):** Για να ξεπεραστεί η παραπάνω αδυναμία, η επόμενη γενιά μοντέλων εμπλουτίζει την αναπαράσταση με χαρακτηριστικά που προέρχονται απευθείας από τον πεζό:

- **Body pose / joints:** Η στάση σώματος (skeleton keypoints) παρέχει σαφώς λεπτομερέστερη πληροφορία από το bounding box, καθιστώντας α-

νιχνεύσιμες μικρο-κινήσεις όπως η κλίση του κορμού ή η άρση ποδιού [17].

- **Head orientation:** Ο προσανατολισμός του κεφαλιού λειτουργεί ως ισχυρό cue προσοχής· στο ανθρώπινο πείραμα του PIE αναδείχθηκε ως ένας από τους πιο καθοριστικούς δείκτες για γρήγορη εκτίμηση πρόθεσης [5].

3. Περιβαλλοντικές προσεγγίσεις (Contextual): Η απόφαση του πεζού διαμορφώνεται σε μεγάλο βαθμό από το περιβάλλον.

- **Ego-vehicle information:** Ταχύτητα και heading του οχήματος που επηρεάζουν άμεσα την αλληλεπίδραση πεζού–οχήματος [5].
- **Scene / road infrastructure:** Διαβάσεις, πεζοδρόμια, φανάρια, εξαγόμενα μέσω semantic/panoptic segmentation.
- **Social interaction:** Επίδραση γειτονικών πεζών και οχημάτων, η οποία μοντελοποιείται με graph-based μεθόδους [18].
- **Depth / distance:** Το βάθος της σκηνής σε σχέση με την απόσταση του αμαξιού [8].

4. Πολυτροπικές προσεγγίσεις (Hybrid / Multimodal): Η σύγχρονη βιβλιογραφία δείχνει ότι τα κινηματικά χαρακτηριστικά μπορούν να είναι ιδιαίτερα ισχυρά, αλλά σε αμφίσημες σκηνές η προσθήκη pedestrian-centric και contextual cues μπορεί να προσφέρει συμπληρωματική πληροφορία [10]. Η σύντηξη pedestrian-centric και contextual cues επιτρέπει την επιβεβαίωση ή διόρθωση ενδείξεων, μειώνοντας δραστικά τα σφάλματα σε αμφίσημες σκηνές. Αυτή η πολυτροπική φιλοσοφία αποτελεί τον πυρήνα του PIP-Net [8], [13] και της παρούσας εργασίας.

2.3.3 Βάσει Αρχιτεκτονικής Μοντέλου

- 1. Recurrent Networks (RNN/LSTM/GRU).** Αποτελούν το θεμελιώδες εργαλείο χρονικής κωδικοποίησης ακολουθιών (bbox, pose, ego-speed). Σε encoder-decoder pipelines, κωδικοποιούν την ιστορική πληροφορία σε ένα διανυσματικό context που τροφοδοτεί τον classifier.
- 2. Convolutional Networks (2D/3D CNN).** Τα 2D CNN εξάγουν χωρικά χαρακτηριστικά appearance ανά frame (backbones όπως VGG19, ResNet). Τα 3D CNN και τα Conv3D επεκτείνουν τη δυνατότητα αυτή στον χρόνο, μαθαίνοντας χωροχρονικά μοτίβα άμεσα από clips (π.χ. optical flow ή segmentation ακολουθίες). Το PIP-Net [8], [13] χρησιμοποιεί Conv3D για τους visual branches.
- 3. Transformer-based Models.** Αξιοποιούν self-attention για την ανίχνευση long-range dependencies στον χώρο και τον χρόνο, διευκολύνοντας τη σύντηξη πολλαπλών modalities. Αξιοσημείωτο αποτέλεσμα αποτελεί η εργασία των Achaji et al. (2022)[19]: ένα transformer μοντέλο τροφοδοτούμενο αποκλειστικά με bounding box πληροφορία επιτυγχάνει ακρίβεια 91% στο PIE, υπερτερώντας

baselines που αξιοποιούν πρόσθετα pose, ego-speed και RGB χαρακτηριστικά εύρημα που αναδεικνύει την κρισιμότητα της χρονικής μοντελοποίησης.

4. **Graph-based Models (GCN/GAT).** Αναπαριστούν τη σκηνή ως γράφο, όπου οι κόμβοι αντιστοιχούν σε agents/objects και οι ακμές σε χωρικές ή κοινωνικές σχέσεις. Είναι ιδιαίτερα ισχυρά για interaction modeling σε πυκνές σκηνές· χαρακτηριστικό παράδειγμα είναι το spatiotemporal relationship reasoning των Liu et al. (2020)[20], το οποίο κατασκευάζει pedestrian-centric και location-centric γράφους που τροφοδοτούν GRU για την πρόβλεψη πρόθεσης.
5. **Hybrid Architectures.** Ο κυρίαρχος συνδυασμός στα SOTA μοντέλα: CNN για χωρική εξαγωγή ανά frame, GRU ή Conv3D για χρονική κωδικοποίηση και attention mechanism για weighted fusion. Αυτή την αρχιτεκτονική κατεύθυνση ακολουθούν τόσο το PIP-Net [8] όσο και η παρούσα εργασία.

2.4 Τεχνολογικό Υπόβαθρο Βασικών Modules

Η προτεινόμενη αρχιτεκτονική PIPN βασίζεται σε έναν πολυτροπικό σχεδιασμό, όπου διαφορετικές πηγές πληροφορίας συνεισφέρουν συμπληρωματικά στην πρόβλεψη πρόθεσης διάσχισης πεζού. Η βασική υπόθεση της μεθοδολογίας είναι ότι η μελλοντική συμπεριφορά ενός πεζού δεν μπορεί να εκτιμηθεί αξιόπιστα μόνο από μία κατηγορία χαρακτηριστικών, όπως για παράδειγμα τη θέση του bounding box ή την εμφάνιση του πεζού. Αντίθετα, απαιτείται συνδυασμός κινηματικής πληροφορίας, τοπικής οπτικής πληροφορίας, κίνησης, σημασιολογικής κατανόησης της σκηνής και γεωμετρικών ενδείξεων βάθους.

Για τον λόγο αυτό, το preprocessing pipeline της εργασίας αξιοποιεί μια σειρά από προεκπαιδευμένα perception modules, τα οποία εφαρμόζονται offline στα αρχικά βίντεο και παράγουν τις εισόδους του μοντέλου. Τα modules αυτά δεν εκπαιδεύονται εκ νέου στο πλαίσιο της παρούσας εργασίας, αλλά χρησιμοποιούνται ως frozen feature extractors. Συγκεκριμένα, χρησιμοποιούνται τεχνικές panoptic segmentation, optical flow, monocular depth estimation και pose estimation. Οι αναπαραστάσεις που προκύπτουν τροφοδοτούνται στη συνέχεια στους αντίστοιχους κλάδους του PIPN, όπου εκπαιδευσιμα recurrent, convolutional και attention-based δομικά στοιχεία αναλαμβάνουν τη χρονική μοντελοποίηση και τη σύντηξη των πληροφοριών.

Η παρούσα ενότητα δεν έχει ως στόχο να παρουσιάσει όλη την ιστορική εξέλιξη των παραπάνω πεδίων. Αντίθετα, εστιάζει στα τεχνολογικά στοιχεία που είναι απαραίτητα για την κατανόηση της μεθοδολογίας της εργασίας: γιατί επιλέγεται κάθε module, τι είδους πληροφορία παράγει, και με ποιον τρόπο η πληροφορία αυτή αξιοποιείται από την αρχιτεκτονική PIPN.

2.4.1 Semantic και Panoptic Segmentation

Η κατανόηση της σκηνής σε επίπεδο pixel αποτελεί βασικό στοιχείο του παγκόσμιου κλάδου της προτεινόμενης αρχιτεκτονικής. Στο πρόβλημα της πρόβλεψης πρόθεσης διάσχισης, ο πεζός δεν εξετάζεται απομονωμένα, αλλά μέσα στο ευρύτερο οδικό περιβάλλον. Η ύπαρξη πεζοδρομίου, οδοστρώματος, διάβασης, οχημάτων, σηματοδοτών ή άλλων πε-

ζών μπορεί να επηρεάσει άμεσα την πιθανότητα διάσχισης. Για τον λόγο αυτό, η αρχιτεκτονική δεν περιορίζεται σε χαρακτηριστικά που προέρχονται μόνο από το bounding box του πεζού, αλλά αξιοποιεί και σημασιολογική πληροφορία ολόκληρης της σκηνής.

Το semantic segmentation αποδίδει σε κάθε pixel μία κατηγορία, όπως road, sidewalk, person, car ή sky. Με αυτόν τον τρόπο παρέχει μια πυκνή σημασιολογική περιγραφή του περιβάλλοντος. Ωστόσο, δεν διακρίνει διαφορετικά αντικείμενα της ίδιας κατηγορίας. Για παράδειγμα, δύο διαφορετικοί πεζοί στην ίδια εικόνα λαμβάνουν την ίδια ετικέτα person, χωρίς να διαχωρίζονται ως ξεχωριστά instances. Αυτή η πληροφορία είναι ανεπαρκής όταν χρειάζεται να υπολογιστεί η απόσταση ή η χωρική σχέση κάθε συγκεκριμένου πεζού ή οχήματος.

Το instance segmentation αντιμετωπίζει αυτό το πρόβλημα παρέχοντας ξεχωριστή μάσκα για κάθε αντικείμενο, αλλά συνήθως εφαρμόζεται μόνο σε μετρήσιμες κατηγορίες αντικειμένων, όπως πεζοί, οχήματα ή ποδήλατα. Το panoptic segmentation ενοποιεί τις δύο παραπάνω προσεγγίσεις. Κάθε pixel λαμβάνει μία σημασιολογική κατηγορία, ενώ ταυτόχρονα τα αντικείμενα τύπου things, όπως pedestrians και vehicles, διαχωρίζονται σε ξεχωριστά instances. Έτσι, το panoptic segmentation είναι ιδιαίτερα κατάλληλο για εφαρμογές αυτόνομης οδήγησης, όπου απαιτείται ταυτόχρονα κατανόηση της δομής της σκηνής και διαχωρισμός των επιμέρους road users.

Στην παρούσα εργασία, το panoptic segmentation χρησιμοποιείται για δύο λόγους. Πρώτον, παράγει τα semantic maps που τροφοδοτούν τον παγκόσμιο context κλάδο. Τα maps αυτά επιτρέπουν στο μοντέλο να επεξεργάζεται τη γεωμετρική και σημασιολογική διάταξη του περιβάλλοντος, διατηρώντας τη χωρική δομή της σκηνής. Δεύτερον, οι instance masks πεζών και οχημάτων χρησιμοποιούνται για την κατασκευή του categorical depth, δηλαδή μιας πιο σταθερής αναπαράστασης βάθους που βασίζεται σε συγκεκριμένα αντικείμενα και όχι σε θορυβώδεις pixel-level εκτιμήσεις.

Σε προηγούμενες πολυτροπικές προσεγγίσεις, όπως το CIPF, η πληροφορία σκηνής βασιζόταν κυρίως σε semantic segmentation, χωρίς ρητή αξιοποίηση instance-level πληροφορίας. Το PIP-Net εισήγαγε μια πιο πλούσια instance-aware αναπαράσταση μέσω panoptic segmentation και categorical depth. Η παρούσα εργασία διατηρεί αυτή τη βασική ιδέα, αλλά χρησιμοποιεί Mask2Former με Cityscapes panoptic προεκπαίδευση [21], [22] για την εξαγωγή semantic και instance masks. Η επιλογή αυτή δεν παρουσιάζεται ως ανεξάρτητη συνεισφορά στον χώρο του segmentation, αλλά ως αναβάθμιση του preprocessing pipeline με στόχο πιο συνεπή αναπαράσταση του global scene context.

Επομένως, ο ρόλος του segmentation στο PIPN είναι διπλός: παρέχει αφενός μια σημασιολογική περιγραφή του οδικού περιβάλλοντος και αφετέρου τις instance masks που απαιτούνται για τη σταθεροποίηση της γεωμετρικής πληροφορίας βάθους.

2.4.2 Optical Flow

Το optical flow περιγράφει τη φαινόμενη κίνηση των pixels μεταξύ δύο διαδοχικών frames. Το αποτέλεσμά του είναι ένα dense vector field, όπου κάθε pixel λαμβάνει ένα διάνυσμα μετατόπισης (u, v) . Η οριζόντια συνιστώσα u περιγράφει μετακίνηση αριστερά ή δεξιά, ενώ η κατακόρυφη συνιστώσα v περιγράφει μετακίνηση πάνω ή κάτω. Σε αντίθεση με τα στατικά RGB χαρακτηριστικά, το optical flow κωδικοποιεί άμεσα τη δυναμική της εικόνας.

Η βασική υπόθεση πίσω από τον κλασικό υπολογισμό optical flow είναι η σταθερότητα φωτεινότητας. Αν ένα σημείο της σκηνής μετακινείται από τη θέση (x, y) στη θέση $(x + u, y + v)$, τότε η φωτεινότητά του θεωρείται περίπου σταθερή μεταξύ των δύο frames:

$$I(x, y, t) = I(x + u, y + v, t + 1)$$

Με ανάπτυγμα Taylor πρώτης τάξης προκύπτει η εξίσωση optical flow constraint:

$$I_x u + I_y v + I_t = 0$$

όπου I_x και I_y είναι οι χωρικές παράγωγοι της εικόνας και I_t η χρονική παράγωγος. Η εξίσωση αυτή έχει δύο αγνώστους και μόνο έναν περιορισμό, γεγονός που καθιστά το πρόβλημα εγγενώς ill-posed. Για τον λόγο αυτό, οι σύγχρονες μέθοδοι optical flow βασίζονται σε πρόσθετους περιορισμούς ή σε learned priors που μαθαίνονται από μεγάλα σύνολα δεδομένων.

Στο πλαίσιο της παρούσας εργασίας, το optical flow χρησιμοποιείται για την εξαγωγή local motion χαρακτηριστικών γύρω από τον πεζό. Η επιλογή τοπικού και όχι global optical flow είναι σημαντική. Το optical flow ολόκληρης της σκηνής επηρεάζεται έντονα από την κίνηση της ego-camera και μπορεί να περιέχει μεγάλες μετατοπίσεις που οφείλονται στην κίνηση του οχήματος και όχι στη συμπεριφορά του πεζού. Αντίθετα, όταν το optical flow υπολογίζεται εντός του crop του πεζού, επικεντρώνεται περισσότερο σε κινήσεις του σώματος, αλλαγές στάσης, κατεύθυνση βηματισμού και μικρομετακινήσεις που είναι πιο άμεσα σχετικές με την πρόθεση διάσχισης.

Η παρούσα εργασία χρησιμοποιεί RAFT-large [23] με weights εξειδικευμένα σε driving-related datasets. Το RAFT βασίζεται σε all-pairs correlation volume μεταξύ των δύο frames και σε recurrent μηχανισμό επαναληπτικής βελτίωσης του flow field. Σε αντίθεση με παλαιότερες single-pass μεθόδους, η επαναληπτική φύση του RAFT επιτρέπει λεπτομερέστερη εκτίμηση μετατοπίσεων, κάτι που είναι χρήσιμο για την ανίχνευση μικρών κινήσεων του πεζού.

Τα παραγόμενα optical flow maps δεν χρησιμοποιούνται απευθείας για την τελική πρόβλεψη. Αντίθετα, τροφοδοτούνται στον local visual branch, όπου κωδικοποιούνται με συνελκτικά και recurrent layers. Έτσι, η πληροφορία κίνησης ενσωματώνεται ως συμπληρωματικό σήμα δίπλα στην τοπική οπτική εμφάνιση του πεζού.

2.4.3 Monocular Depth Estimation και Categorical Depth

Η εκτίμηση βάθους από μία μόνο κάμερα είναι ιδιαίτερα σημαντική για την πρόβλεψη πρόθεσης διάσχισης, επειδή η απόσταση του πεζού από το ego-vehicle και η σχετική του θέση ως προς άλλα οχήματα επηρεάζουν την απόφαση διάσχισης. Ωστόσο, το monocular depth estimation είναι εγγενώς αμφίσημο πρόβλημα. Μία 2D εικόνα μπορεί να αντιστοιχεί σε πολλές διαφορετικές 3D σκηνές, και επομένως η κάμερα δεν παρέχει άμεση μέτρηση βάθους όπως ένα LiDAR ή ένα stereo σύστημα.

Τα σύγχρονα learning-based μοντέλα αντιμετωπίζουν αυτή την αμφισημία μαθαίνοντας οπτικά και γεωμετρικά cues από μεγάλα datasets. Τέτοια cues περιλαμβάνουν τη σχετική κλίμακα των αντικειμένων, την προοπτική, την υφή, την επικάλυψη αντικειμένων

και τη γεωμετρική διάταξη της σκηνής. Στην παρούσα εργασία χρησιμοποιείται ManyDepth [24], ένα self-supervised μοντέλο που αξιοποιεί χρονική πληροφορία από διαδοχικά frames. Η χρήση πολλαπλών frames είναι ιδιαίτερα κατάλληλη για driving scenarios, καθώς η κίνηση της κάμερας παρέχει έμμεσο γεωμετρικό σήμα για την εκτίμηση βάθους.

Παρά τη χρησιμότητά του, ο raw depth map δεν αποτελεί ιδανική είσοδο για το μοντέλο. Οι monocular depth εκτιμήσεις συχνά παρουσιάζουν θόρυβο, ασυνέπειες στα object boundaries και αμφισημία κλίμακας. Επιπλέον, οι τιμές βάθους μέσα στο ίδιο αντικείμενο μπορεί να μην είναι ομοιόμορφες. Αυτό είναι προβληματικό όταν το ζητούμενο δεν είναι η ακριβής πυκνή ανακατασκευή της σκηνής, αλλά μια σταθερή αναπαράσταση της σχετικής εγγύτητας πεζών και οχημάτων.

Για τον λόγο αυτό, η παρούσα εργασία υιοθετεί την έννοια του categorical depth, η οποία εισήχθη στο PIP-Net. Αντί ο raw depth map να χρησιμοποιείται αυτούσιος, φιλτράρεται μέσω των instance masks που προκύπτουν από το panoptic segmentation. Για κάθε pedestrian ή vehicle instance, οι τιμές βάθους μέσα στη μάσκα συνοψίζονται σε μια πιο σταθερή τιμή, συνήθως μέσω averaging. Στη συνέχεια, η τιμή αυτή αποδίδεται στα pixels του αντίστοιχου instance.

Το τελικό categorical depth έχει δύο κανάλια: ένα για pedestrians και ένα για vehicles. Τα pixels που δεν ανήκουν σε κάποια από αυτές τις κατηγορίες λαμβάνουν μηδενική τιμή. Έτσι, το μοντέλο δεν λαμβάνει έναν θορυβώδη global depth map, αλλά μια object-aware γεωμετρική αναπαράσταση που τονίζει τους road users που είναι σημαντικοί για το crossing intention prediction.

Στο PIPN, το categorical depth χρησιμοποιείται μαζί με το semantic context στον global context branch. Με αυτόν τον τρόπο, ο branch δεν επεξεργάζεται μόνο το “τι υπάρχει” στη σκηνή, αλλά και μια προσέγγιση του “πόσο κοντά” βρίσκονται οι κρίσιμοι road users. Η αναπαράσταση αυτή είναι ιδιαίτερα χρήσιμη σε περιπτώσεις όπου η απόφαση του πεζού επηρεάζεται από την εγγύτητα του ego-vehicle ή από την παρουσία άλλων οχημάτων γύρω του.

2.4.4 Pose Estimation

Το human pose estimation εντοπίζει ανατομικά σημεία-κλειδιά του ανθρώπινου σώματος, όπως ώμους, αγκώνες, καρπούς, ισχία, γόνατα και αστραγάλους. Το αποτέλεσμα είναι ένα σύνολο keypoints που περιγράφει τη στάση του σώματος με γεωμετρικά ερμηνεύσιμο τρόπο. Στην παρούσα εργασία, η pose πληροφορία χρησιμοποιείται ως μέρος του kinematic branch, μαζί με τα bounding box dynamics και την ego-vehicle speed όπου αυτή είναι διαθέσιμη.

Η σημασία του pose estimation στο crossing intention prediction προκύπτει από το γεγονός ότι το bounding box περιγράφει κυρίως τη θέση και το μέγεθος του πεζού, αλλά δεν περιγράφει λεπτομερώς τη στάση του σώματος. Αντίθετα, τα pose keypoints μπορούν να κωδικοποιήσουν ενδείξεις όπως ο προσανατολισμός του σώματος, η κλίση προς τον δρόμο, η θέση των ποδιών ή η έναρξη βηματισμού. Αυτά τα στοιχεία μπορεί να είναι ιδιαίτερα σημαντικά λίγο πριν από μια πιθανή διάσχιση.

Στο preprocessing pipeline, η pose εκτίμηση εφαρμόζεται στο crop του πεζού και όχι σε ολόκληρο το frame. Η επιλογή αυτή μειώνει την επίδραση του background και επι-

τρέπει στο pose estimator να επικεντρωθεί στο άτομο ενδιαφέροντος. Αυτό είναι ιδιαίτερα σημαντικό σε σκηνές όπου ο πεζός βρίσκεται μακριά από την κάμερα, έχει μικρό μέγεθος στο frame ή συνυπάρχει με άλλους πεζούς.

Τα keypoints μετατρέπονται σε διανυσματική αναπαράσταση και τροφοδοτούνται στον kinematic branch. Εκεί συνδυάζονται χρονικά με τα bounding box χαρακτηριστικά, ώστε το μοντέλο να μπορεί να μάθει τόσο την τροχιά του πεζού όσο και τις μεταβολές της στάσης του σώματος μέσα στο παράθυρο παρατήρησης.

Πρέπει, ωστόσο, να τονιστεί ότι η pose πληροφορία δεν ερμηνεύεται ως άμεση πρόσβαση στην ψυχολογική πρόθεση του πεζού. Αντίθετα, αποτελεί ένα οπτικό και κινηματικό σήμα που μπορεί να συσχετίζεται με επερχόμενη διάσχιση, όταν εξετάζεται σε συνδυασμό με τα υπόλοιπα modalities.

2.4.5 Temporal και Spatio-Temporal Encoders (GRU, Conv3D)

Τα perception modules παράγουν χαρακτηριστικά ανά frame ή ανά ζεύγος frames. Ωστόσο, το crossing intention prediction είναι εγγενώς χρονικό πρόβλημα. Το ζητούμενο δεν είναι μόνο να αναγνωριστεί η κατάσταση του πεζού σε μία εικόνα, αλλά να μοντελοποιηθεί η εξέλιξη της συμπεριφοράς του μέσα σε ένα παράθυρο παρατήρησης. Για τον λόγο αυτό, η αρχιτεκτονική PIPN χρησιμοποιεί temporal και spatio-temporal encoders.

Τα Gated Recurrent Units χρησιμοποιούνται για την κωδικοποίηση ακολουθιακής πληροφορίας. Σε ένα GRU, η κρυφή κατάσταση ενημερώνεται σε κάθε χρονικό βήμα μέσω δύο βασικών πυλών: της update gate και της reset gate. Για είσοδο x_t και προηγούμενη κρυφή κατάσταση h_{t-1} οι βασικές εξισώσεις είναι [25]:

$$z_t = \sigma(W_z x_t + U_z h_{t-1} + b_z)$$

$$r_t = \sigma(W_r x_t + U_r h_{t-1} + b_r)$$

$$\tilde{h}_t = \tanh(W_h x_t + U_h (r_t \odot h_{t-1}) + b_h)$$

$$h_t = (1 - z_t) \odot h_{t-1} + z_t \odot \tilde{h}_t$$

Η update gate ελέγχει πόση προηγούμενη πληροφορία διατηρείται, ενώ η reset gate καθορίζει πόσο έντονα επηρεάζει η προηγούμενη κατάσταση την υποψήφια νέα αναπαράσταση. Σε σχέση με τα LSTM, τα GRU έχουν απλούστερη δομή και λιγότερες παραμέτρους, διατηρώντας παράλληλα την ικανότητα μοντελοποίησης χρονικών εξαρτήσεων.

Στην παρούσα αρχιτεκτονική, τα GRU χρησιμοποιούνται στον kinematic branch για την επεξεργασία των bounding boxes, pose keypoints και ego-speed, καθώς και στον local visual branch για την ακολουθιακή κωδικοποίηση των local content και local motion embeddings. Με αυτόν τον τρόπο, το μοντέλο μπορεί να μάθει μεταβολές όπως η προσέγγιση του πεζού προς το οδόστρωμα, η αλλαγή ταχύτητας ή κατεύθυνσης και η μεταβολή της στάσης του σώματος.

Παράλληλα, οι τρισδιάστατες συνελίξεις χρησιμοποιούνται σε δύο σημεία της προτεινόμενης αρχιτεκτονικής. Πρώτον, στον global context branch, για την επεξεργασία ακολουθιών semantic και categorical depth maps ως χωροχρονικών όγκων, διατηρώντας τη δομή της σκηνής. Δεύτερον, στο motion stream του local visual branch, για την κωδικοποίηση της τοπικής κίνησης του πεζού από το optical flow. Σε αντίθεση με τις δισδιάστατες συνελίξεις, οι Conv3D εφαρμόζουν φίλτρα που εκτείνονται τόσο στον χώρο όσο και στον χρόνο, και έτσι μπορούν να επεξεργαστούν ακολουθίες ως ενιαίους όγκους αντί για ανεξάρτητα frames [26].

Συνεπώς, στην παρούσα μεθοδολογία τα GRU και τα Conv3D επιτελούν συμπληρωματικούς ρόλους. Τα GRU είναι κατάλληλα για ακολουθιακά embeddings, όπως οι ακολουθίες bounding boxes, pose keypoints, ego-speed και local content. Τα Conv3D είναι κατάλληλα για χωροχρονικά maps και όγκους κίνησης, στα οποία η χωρική διάταξη πρέπει να διατηρηθεί. Ο συνδυασμός τους επιτρέπει στο PIPN να αξιοποιεί τόσο χρονικές ακολουθίες χαρακτηριστικών όσο και χωροχρονικές μεταβολές της σκηνής και της κίνησης.

2.4.6 Vision Transformers (ViT) και Μηχανισμοί Προσοχής (Self-Attention)

Οι μηχανισμοί προσοχής αποτελούν βασικό στοιχείο της σύγχρονης βαθιάς μάθησης, επειδή επιτρέπουν σε ένα μοντέλο να σταθμίζει δυναμικά διαφορετικά τμήματα της εισόδου. Στο πλαίσιο της πρόβλεψης πρόθεσης διάσχισης, αυτό είναι ιδιαίτερα χρήσιμο, καθώς δεν έχουν όλα τα frames ή όλα τα modalities την ίδια σημασία. Για παράδειγμα, οι τελευταίες χρονικές στιγμές πριν από μια πιθανή διάσχιση μπορεί να είναι πιο πληροφοριακές από τα πρώτα frames, ενώ σε ορισμένες περιπτώσεις η κίνηση του πεζού μπορεί να είναι πιο κρίσιμη από τη στάση σώματος ή το αντίστροφο.

Στην αρχιτεκτονική PIPN, η attention-based late fusion χρησιμοποιείται για τη σύντηξη των αναπαραστάσεων που προέρχονται από τους διαφορετικούς κλάδους. Κάθε branch παράγει μια συμπυκνωμένη αναπαράσταση της πληροφορίας που του αντιστοιχεί. Στη συνέχεια, ο μηχανισμός προσοχής επιτρέπει στο μοντέλο να αποδώσει διαφορετική βαρύτητα στις διαθέσιμες αναπαραστάσεις, αντί να τις συνδυάζει με στατικό ή χειροκίνητο τρόπο. Αυτό είναι σημαντικό επειδή η χρησιμότητα κάθε modality μπορεί να διαφέρει ανάλογα με το σενάριο. Σε μια σκηνή με καθαρή κίνηση του πεζού, το local motion μπορεί να είναι ιδιαίτερα ισχυρό σήμα. Σε μια πιο αμφίσημη σκηνή, το global context ή η ego-speed μπορεί να παίζουν μεγαλύτερο ρόλο.

Πέρα από τους κλασικούς μηχανισμούς attention [27], η παρούσα εργασία εξετάζει και μια εναλλακτική Transformer-based υλοποίηση για τον global context encoder. Η λογική των Vision Transformers [28] βασίζεται στη διάσπαση μιας εικόνας ή ενός feature map σε patches, τα οποία μετατρέπονται σε διανύσματα και επεξεργάζονται μέσω self-attention. Σε αντίθεση με τα συνελικτικά φίλτρα, τα οποία έχουν έντονη τοπική επαγωγική μεροληψία, το self-attention μπορεί να συσχετίσει άμεσα απομακρυσμένες περιοχές της σκηνής.

Αυτή η ιδιότητα είναι ενδιαφέρουσα για το crossing intention prediction, επειδή η απόφαση ενός πεζού μπορεί να εξαρτάται από στοιχεία που βρίσκονται μακριά από το ίδιο το σώμα του, όπως μια διάβαση, ένας σηματοδότης, ένα όχημα που προσεγγίζει ή η γεωμετρία του δρόμου. Για τον λόγο αυτό, η Spatial-Patch Transformer εκδοχή του global branch διερευνάται ως εναλλακτικός encoder για semantic και categorical depth maps.

Η συγκεκριμένη επιλογή δεν παρουσιάζεται εκ των προτέρων ως ανώτερη ή πιο αποδοτική από την Conv3D-based υλοποίηση. Αντίθετα, εξετάζεται πειραματικά ως διαφορετικό trade-off μεταξύ ακρίβειας, αριθμού παραμέτρων και σταθερότητας εκπαίδευσης. Με αυτόν τον τρόπο, η εργασία αποφεύγει υπερβολικούς ισχυρισμούς και αντιμετωπίζει τον Spatial-Patch Transformer ως ερευνητική επέκταση του global context branch, η χρησιμότητα της οποίας πρέπει να τεκμηριωθεί από τα αποτελέσματα.

2.5 Αντιπροσωπευτικά Πολυτροπικά Πλαίσια

Η παρούσα ενότητα παρουσιάζει αντιπροσωπευτικά πλαίσια που επηρέασαν άμεσα τη σχεδίαση της προτεινόμενης αρχιτεκτονικής PIPN. Η επιλογή των μεθόδων δεν γίνεται με στόχο μια εξαντλητική παράθεση όλων των διαθέσιμων μοντέλων, αλλά με βάση τη μεθοδολογική τους συνάφεια με την παρούσα εργασία. Συγκεκριμένα, εξετάζονται: το αρχικό PIE baseline, το οποίο θεμελιώνει το πρόβλημα της crossing intention estimation και εισάγει human reference scores· το CIPF, το οποίο αποτελεί χαρακτηριστικό παράδειγμα feature fusion πολυτροπικής αρχιτεκτονικής· Transformer-based προσεγγίσεις, οι οποίες δείχνουν τη σημασία του self-attention για χωροχρονική μοντελοποίηση· και το PIP-Net, το οποίο αποτελεί το πλησιέστερο αρχιτεκτονικό σημείο αναφοράς για την παρούσα εργασία.

2.5.1 PIE Baseline και Human Intention Experiment

Η δημοσίευση του PIE dataset αποτέλεσε σημαντικό σημείο αναφοράς για την πρόβλεψη πρόθεσης διάσχισης πεζού, καθώς συνδύασε video-based driving data με λεπτομερείς annotations και human intention reference scores. Το αντίστοιχο baseline μοντέλο βασίζεται σε ακολουθιακή επεξεργασία της τροχιάς του bounding box και της ego-vehicle speed μέσω LSTM encoder-decoder αρχιτεκτονικής. Με άλλα λόγια, το μοντέλο επιχειρεί να προβλέψει αν ο πεζός θα διασχίσει ή όχι τον δρόμο χρησιμοποιώντας κυρίως την ιστορική χωρική του μεταβολή και τη δυναμική του οχήματος.

Η σημασία του PIE baseline δεν περιορίζεται στην τελική του απόδοση. Αντίθετα, η βασική του συνεισφορά είναι ότι έδειξε πως ακόμη και απλά κινηματικά χαρακτηριστικά, όπως η τροχιά του bounding box, περιέχουν σημαντική πληροφορία για το crossing prediction task. Η κίνηση του πεζού προς το οδόστρωμα, η μεταβολή του μεγέθους του bounding box και η σχετική του θέση ως προς το ego-vehicle λειτουργούν ως έμμεσες ενδείξεις επερχόμενης διάσχισης. Παρ' όλα αυτά, η περιορισμένη χρήση modalities οδηγεί σε μειωμένη ικανότητα κατανόησης αμφίσημων σκηνών, όπου η τελική συμπεριφορά του πεζού εξαρτάται από παράγοντες όπως η στάση σώματος, η οπτική επαφή, η ύπαρξη διάβασης ή η παρουσία άλλων οχημάτων.

Ιδιαίτερα σημαντικό στοιχείο του PIE είναι το human intention experiment. Επειδή η πρόθεση του πεζού δεν είναι άμεσα παρατηρήσιμη μεταβλητή, οι δημιουργοί του dataset ζήτησαν από ανθρώπινους αξιολογητές να εκτιμήσουν, με βάση σύντομα video clips, αν ο πεζός φαίνεται να θέλει να διασχίσει. Τα human reference scores δεν αντικαθιστούν το πραγματικό crossing/non-crossing outcome, αλλά παρέχουν ένα χρήσιμο μέτρο ανθρώπινης αβεβαιότητας και αντιληπτής πρόθεσης. Αυτό είναι σημαντικό για τη διατύπωση του προβλήματος: η πρόβλεψη πρόθεσης δεν αντιμετωπίζεται ως ανάγνωση μιας εσωτερικής


ψυχολογικής κατάστασης, αλλά ως επιχειρησιακή εκτίμηση πιθανής διάσχισης μέσα σε συγκεκριμένο χρονικό ορίζοντα.

Για την παρούσα εργασία, το PIE baseline έχει διπλή σημασία. Πρώτον, τεκμηριώνει ότι τα κινηματικά χαρακτηριστικά αποτελούν αναγκαίο συστατικό κάθε αξιόπιστου PIP συστήματος. Δεύτερον, αναδεικνύει τους περιορισμούς των μονοτροπικών ή χαμηλής πολυτροπικότητας προσεγγίσεων, δικαιολογώντας την ανάγκη για αρχιτεκτονικές που ενσωματώνουν pose, local appearance, motion και global scene context.

2.5.2 CIPF (Crossing Intention Prediction with Feature Fusion)

Το CIPF αποτελεί αντιπροσωπευτικό παράδειγμα πολυτροπικής feature fusion προσέγγισης. Σε αντίθεση με το PIE baseline, το οποίο βασίζεται κυρίως σε bounding box trajectory και ego-speed, το CIPF επιχειρεί να συνδυάσει διαφορετικές πηγές πληροφορίας που σχετίζονται με τον πεζό, το όχημα και το περιβάλλον. Η κεντρική του ιδέα είναι ότι η crossing intention δεν μπορεί να εκτιμηθεί αξιόπιστα από ένα μόνο feature stream, αλλά απαιτεί σύντηξη ετερογενών σημάτων.

Η αρχιτεκτονική του CIPF οργανώνει τις εισόδους σε επιμέρους modules. Το observational module επεξεργάζεται κινηματικά χαρακτηριστικά, όπως pose keypoints, bounding box coordinates και ego-vehicle speed, μέσω recurrent layers. Το contextual module εξάγει οπτικά χαρακτηριστικά από crops γύρω από τον πεζό, από την πλήρη εικόνα και από semantic maps. Τέλος, ένα convolutional module χρησιμοποιεί spatio-temporal επεξεργασία σε τοπικές περιοχές γύρω από τον πεζό. Τα outputs των modules συνδυάζονται μέσω attention-based μηχανισμού και οδηγούνται σε τελικό classifier. Η αρχιτεκτονική του CIPF παρουσιάζεται στο Σχήμα 2.5.



Σχήμα 2.5: Επισκόπηση της αρχιτεκτονικής CIPF, η οποία οργανώνεται σε τρία modules (observational, contextual, convolutional)[13].

Η σημασία του CIPF για την παρούσα εργασία είναι κυρίως μεθοδολογική. Το μοντέλο δείχνει ότι η σύντηξη πολλαπλών modalities μπορεί να βελτιώσει την απόδοση σε σχέση με απλούστερες recurrent προσεγγίσεις. Παράλληλα, όμως, αναδεικνύει και ορισμένους περιορισμούς. Η χρήση απλού semantic segmentation για το scene context δεν παρέχει instance-level πληροφορία, με αποτέλεσμα το μοντέλο να μην μπορεί να διαχωρίσει διαφορετικούς πεζούς ή οχήματα μέσα στην ίδια σκηνή. Επιπλέον, η απουσία explicit optical flow περιορίζει τη δυνατότητα κωδικοποίησης της τοπικής κίνησης του πεζού, ενώ η απουσία depth estimation σημαίνει ότι το μοντέλο δεν αξιοποιεί άμεσα γεωμετρική πληροφορία απόστασης.

Ένα ιδιαίτερα ενδιαφέρον συμπέρασμα του CIPF είναι ότι τα κινηματικά χαρακτηριστικά, και ειδικά το bounding box, παραμένουν εξαιρετικά σημαντικά ακόμη και σε πιο σύνθετες πολυτροπικές αρχιτεκτονικές. Αυτό ενισχύει τη σχεδιαστική επιλογή της παρούσας εργασίας να διατηρήσει ισχυρό kinematic branch, αντί να βασιστεί αποκλειστικά σε οπτικά ή scene-level χαρακτηριστικά.

Συνολικά, το CIPF αποτελεί ενδιάμεσο βήμα ανάμεσα στα απλά trajectory-based μοντέλα και στα πιο ολοκληρωμένα multimodal frameworks. Η συμβολή του έγκειται στη συστηματική σύντηξη διαφορετικών χαρακτηριστικών, ενώ οι περιορισμοί του εντοπίζονται κυρίως στην ποιότητα και στο είδος των scene-level αναπαραστάσεων.

2.5.3 Transformer-based Προσεγγίσεις

Η εμφάνιση Transformer-based αρχιτεκτονικών στο πεδίο της pedestrian intention prediction εισήγαγε έναν διαφορετικό τρόπο μοντελοποίησης χωροχρονικών εξαρτήσεων. Σε αντίθεση με τα RNN και GRU, τα οποία επεξεργάζονται τις ακολουθίες διαδοχικά, οι Transformers βασίζονται σε μηχανισμούς self-attention που επιτρέπουν την άμεση συσχέτιση διαφορετικών χρονικών βημάτων ή χωρικών tokens [29]. Η ιδιότητα αυτή είναι ιδιαίτερα ελκυστική για την πρόβλεψη πρόθεσης πεζού, καθώς η τελική απόφαση μπορεί να εξαρτάται τόσο από τη χρονική εξέλιξη της κίνησης του πεζού όσο και από στοιχεία της σκηνής ή της τροχιάς που δεν βρίσκονται απαραίτητα στο τελευταίο frame [12], [19].

Ένα σημαντικό εύρημα της πρόσφατης βιβλιογραφίας είναι ότι οι Transformer-based προσεγγίσεις δεν χρειάζεται απαραίτητα να βασίζονται σε πλήρη οπτικά δεδομένα ή σε μεγάλο αριθμό modalities. Αρκετές εργασίες δείχνουν ότι χαμηλής διάστασης structured χαρακτηριστικά, όπως bounding boxes, pose keypoints, bbox centers και ego-vehicle motion, μπορούν να προσφέρουν ιδιαίτερα ισχυρή πληροφορία όταν μοντελοποιηθούν με κατάλληλους attention-based encoders [19], [30], [31]. Η εργασία «Is attention to bounding boxes all you need for pedestrian action prediction?» αποτελεί χαρακτηριστικό παράδειγμα, καθώς δείχνει ότι Transformer μοντέλα που χρησιμοποιούν μόνο bounding boxes μπορούν να φτάσουν ανταγωνιστική ή και ανώτερη απόδοση στο PIE benchmark [19]. Αντίστοιχα, το TrEP χρησιμοποιεί μόνο tabular χαρακτηριστικά, όπως bounding box coordinates, center, area, ratio και ego-vehicle action, αποφεύγοντας πλήρως την επεξεργασία εικόνων [31]. Παρόμοια, το PedGT συνδυάζει pose keypoints και bounding box center με Graph Convolution και Transformer temporal modeling, επιτυγχάνοντας υψηλή απόδοση με πολύ περιορισμένο αριθμό input modalities [30]. Επιπλέον, το VIT-Ped αναφέρει ότι non-visual Transformer μοντέλα με numerical inputs μπορούν να είναι σημαντικά μικρότερα από βαρύτερες multimodal αρχιτεκτονικές [32].

Τα παραπάνω ευρήματα είναι σημαντικά για την παρούσα εργασία, καθώς δείχνουν ότι το ισχυρό σήμα στην πρόβλεψη πρόθεσης πεζού συχνά βρίσκεται στην κινηματική εξέλιξη του πεζού και όχι απαραίτητα σε πλήρη visual scene representations. Η τροχιά του bounding box, η αλλαγή μεγέθους του, η στάση σώματος και η σχέση τους με την κίνηση του ego-vehicle κωδικοποιούν πληροφορίες για την προσέγγιση, την κατεύθυνση και τη δυναμική της πιθανής διάσχισης. Για τον λόγο αυτό, οι Transformer αρχιτεκτονικές που εφαρμόζονται πάνω σε τέτοια structured χαρακτηριστικά μπορούν να είναι υπολογιστικά ελαφριές, χωρίς να χάνουν απαραίτητα σε ακρίβεια.

Ωστόσο, η σύγκριση με τη βιβλιογραφία πρέπει να γίνει με προσοχή. Πολλά από τα πολύ υψηλά reported αποτελέσματα δεν οφείλονται μόνο στην αρχιτεκτονική, αλλά και σε διαφορετικά πειραματικά πρωτόκολλα ή παρεμβάσεις στα δεδομένα. Για παράδειγμα, η εργασία του Achaji et al. χρησιμοποιεί το synthetic CP2A dataset, το οποίο είναι πολύ μεγαλύτερο από το PIE, εφαρμόζει balancing με sequence flipping και undersampling, και στη συνέχεια δείχνει ότι το pretraining στο CP2A και το fine-tuning στο PIE βελτιώνει σημαντικά την απόδοση [19]. Το PedGT προσθέτει θετικά crossing samples από εξωτερικό synthetic dataset για να αντιμετωπίσει την ανισορροπία και εξετάζει διαφορετικές τεχνικές normalization, με σημαντική επίδραση στην απόδοση [30]. Το TrEP εφαρμόζει uncertainty-aware αξιολόγηση, όπου η απόρριψη high-uncertainty samples μπορεί να αυξήσει τα metrics, κάτι που δεν είναι άμεσα συγκρίσιμο με αξιολόγηση σε ολόκληρο το test set [31]. Επομένως, τα reported F1 scores δεν είναι πάντα άμεσα συγκρίσιμα με ένα αυστηρό fixed-threshold evaluation πάνω σε μη ισορροπημένο test set.


Τα ευρήματα αυτά επηρεάζουν άμεσα τη σχεδίαση της παρούσας εργασίας. Αντί ο Transformer να αντιμετωπιστεί ως πλήρης αντικαταστάτης της υπάρχουσας πολυτροπικής αρχιτεκτονικής, εξετάζεται ως εργαλείο ελεγχόμενης σύντηξης. Όπως παρουσιάζεται στο Κεφάλαιο 3, η τελική KinFormer-GRU παραλλαγή διατηρεί τον ισχυρό GRU κινηματικό κλάδο ως anchor και εισάγει επιλεγμένο scene context ως gated contextual tokens.

2.5.4 PIP-Net (Pedestrian Intention Prediction in the Wild)

Το PIP-Net αποτελεί το πιο άμεσα συναφές αρχιτεκτονικό πλαίσιο με την παρούσα εργασία. Πρόκειται για πολυτροπική αρχιτεκτονική που σχεδιάστηκε για πρόβλεψη πρόθεσης διάσχισης πεζού σε πραγματικά αστικά σενάρια. Το μοντέλο συνδυάζει κινηματικά δεδομένα, τοπικά οπτικά χαρακτηριστικά, motion information και global scene context, ενώ εισάγει την έννοια του categorical depth ως instance-aware γεωμετρική αναπαράσταση. Το paper παρουσιάζει δύο εκδοχές του PIP-Net για διαφορετικά camera setups και εισάγει επίσης το Urban-PIP dataset με multi-camera annotations.

Η αρχιτεκτονική του PIP-Net οργανώνεται γύρω από διακριτούς κλάδους που επεξεργάζονται συμπληρωματικές πηγές πληροφορίας. Ο spatial kinematics branch αξιοποιεί bounding box coordinates, body pose keypoints και ego-vehicle speed. Ο local content branch επεξεργάζεται οπτικά χαρακτηριστικά από crop γύρω από τον πεζό. Ο local motion branch χρησιμοποιεί optical flow εντός του pedestrian crop, ώστε να απομονώσει την κίνηση του πεζού από την κίνηση της ego-camera. Παράλληλα, ο semantic context branch αξιοποιεί panoptic segmentation της πλήρους σκηνής, ενώ ο categorical depth branch χρησιμοποιεί instance masks και depth estimation για να παραγάγει πιο σταθερή γεωμετρική αναπαράσταση πεζών και οχημάτων. Η αρχιτεκτονική του PIP-Net παρουσιάζεται στο

Σχήμα 2.6



Σχήμα 2.6: Επισκόπηση της αρχιτεκτονικής PIP-Net. (Pedestrian Intention Prediction in the Wild)[8].

Η πιο σημαντική συνεισφορά του PIP-Net για την παρούσα εργασία είναι η μετάβαση από απλή feature fusion σε οργανωμένη πολυκλαδική μοντελοποίηση. Κάθε modality επεξεργάζεται με κατάλληλο encoder, και οι επιμέρους αναπαραστάσεις συνδυάζονται σε μεταγενέστερο στάδιο μέσω attention-based late fusion. Αυτή η λογική επιτρέπει στο μοντέλο να διατηρεί τη σημασιολογική ιδιαιτερότητα κάθε πηγής πληροφορίας, αντί να συγχωνεύει πρόωρα ετερογενή χαρακτηριστικά.

Το categorical depth αποτελεί ιδιαίτερα κρίσιμο στοιχείο. Αντί να χρησιμοποιείται ο raw depth map, ο οποίος μπορεί να είναι θορυβώδης και ασταθής, η εκτίμηση βάθους φιλτράρεται μέσω instance masks πεζών και οχημάτων. Έτσι, το μοντέλο λαμβάνει μια object-aware αναπαράσταση σχετικής εγγύτητας, η οποία είναι πιο χρήσιμη για crossing intention prediction από έναν γενικό depth heatmap. Το ίδιο το PIP-Net paper υπογραμμίζει τη σημασία του categorical depth και του local motion flow για την κατανόηση της δυναμικής της σκηνής.

Για την παρούσα εργασία, το PIP-Net λειτουργεί ως βασικό σημείο εκκίνησης, αλλά όχι ως αυτούσια αναπαραγωγή. Η προτεινόμενη μεθοδολογία διατηρεί τη βασική πολυκλαδική λογική, αλλά αναβαθμίζει το preprocessing pipeline και διερευνά εναλλακτικές αρχιτεκτονικές επιλογές στον global context encoder. Συγκεκριμένα, το FlowNet2 [33] αντικαθίσταται από RAFT-large για local optical flow, το Slot-VPS αντικαθίσταται από Mask2Former για panoptic segmentation, και η Conv3D-based επεξεργασία του global context συγκρίνεται με Spatial-Patch Transformer encoder. Οι αλλαγές αυτές δεν παρουσιάζονται ως απλή αντικατάσταση modules, αλλά ως προσπάθεια να εξεταστεί αν η βελτίωση της ποιότητας των εισόδων και η διαφορετική χωρική μοντελοποίηση μπορούν να οδηγήσουν σε πιο σταθερή και ερμηνεύσιμη πρόβλεψη.

Παρά την ισχυρή του απόδοση, το PIP-Net αφήνει ανοιχτά ορισμένα ερωτήματα. Πρώτον, η ποιότητα των perception modules επηρεάζει άμεσα την ποιότητα των παραγόμενων multimodal features. Δεύτερον, η Conv3D-based μοντελοποίηση του global context έχει ισχυρή τοπική επαγωγική μεροληψία, αλλά ενδέχεται να μην αποτυπώνει με τον ίδιο τρόπο long-range σχέσεις μεταξύ απομακρυσμένων περιοχών της σκηνής. Τρίτον, η αξιο-

λόγηση της γενίκευσης σε διαφορετικά datasets παραμένει δύσκολη λόγω διαφορών στα annotation protocols και στη διαθεσιμότητα ισοδύναμων modalities.

2.6 Σύνοψη, Κενά της Βιβλιογραφίας και Τοποθέτηση της Παρούσας Εργασίας

2.6.1 Σύνοψη

Η βιβλιογραφική ανασκόπηση δείχνει ότι το pedestrian crossing intention prediction έχει εξελιχθεί από απλές trajectory-based προσεγγίσεις σε σύνθετα πολυτροπικά συστήματα. Τα πρώτα μοντέλα βασίστηκαν κυρίως σε bounding box trajectories και ego-vehicle speed, αποδεικνύοντας ότι η κινηματική πληροφορία του πεζού είναι σημαντική αλλά όχι επαρκής. Στη συνέχεια, feature fusion προσεγγίσεις όπως το CIPF ενσωμάτωσαν περισσότερα modalities, όπως pose, local appearance και semantic context. Τέλος, σύγχρονα πλαίσια όπως το PIP-Net συνδύασαν κινηματικά, οπτικά, motion, semantic και depth-based χαρακτηριστικά σε ενιαία branch-based αρχιτεκτονική.

Από τη συνολική ανασκόπηση προκύπτουν τέσσερα βασικά συμπεράσματα. Πρώτον, τα bounding box dynamics παραμένουν θεμελιώδες σήμα, επειδή κωδικοποιούν έμμεσα την τροχιά, τη θέση και τη σχετική μεταβολή του πεζού ως προς το όχημα. Δεύτερον, η pose και η local appearance πληροφορία συμπληρώνουν τα καθαρά κινηματικά χαρακτηριστικά, παρέχοντας ενδείξεις στάσης σώματος και προσανατολισμού. Τρίτον, το local motion είναι ιδιαίτερα χρήσιμο όταν υπολογίζεται γύρω από τον πεζό, επειδή μειώνει την επίδραση του ego-motion. Τέταρτον, το global context απαιτεί δομημένη αναπαράσταση της σκηνής, καθώς η απλή επεξεργασία ολόκληρης της RGB εικόνας μπορεί να εισάγει περιβαλλοντικό θόρυβο.

Η σημαντικότερη μεθοδολογική τάση είναι η μετάβαση από αδιαφοροποίητη σύντηξη χαρακτηριστικών σε πιο οργανωμένη πολυκλαδική μοντελοποίηση. Αντί όλα τα features να συνδυάζονται πρόωρα, κάθε modality κωδικοποιείται με κατάλληλο branch και η σύντηξη πραγματοποιείται σε μεταγενέστερο στάδιο. Αυτή η λογική επιτρέπει καλύτερη αξιοποίηση της εξειδικευμένης πληροφορίας κάθε πηγής και παρέχει πιο καθαρή βάση για ablation analysis.

2.6.2 Κενά της Βιβλιογραφίας

Παρά τη σημαντική πρόοδο, η βιβλιογραφία εξακολουθεί να παρουσιάζει ορισμένα κενά που σχετίζονται άμεσα με την παρούσα εργασία.

Πρώτον, αρκετά υπάρχοντα multimodal frameworks βασίζονται σε perception modules τα οποία είτε δεν είναι πλέον τα ισχυρότερα διαθέσιμα είτε δεν είναι εύκολα αναπαραγώγιμα λόγω περιορισμένης διαθεσιμότητας κώδικα, εξαρτήσεων και παλαιότερων εκδόσεων λογισμικού. Η ποιότητα και η αναπαραγωγικότητα του optical flow, του panoptic segmentation και του depth estimation επηρεάζουν άμεσα τις εισόδους των downstream branches.

Δεύτερον, η αξιοποίηση του global context παραμένει ανοιχτό ζήτημα. Προσεγγίσεις που βασίζονται σε απλή semantic segmentation ή σε global RGB features ενδέχεται να εισάγουν θόρυβο, ενώ η Conv3D-based επεξεργασία διατηρεί ισχυρή τοπική χωροχρονική

επαγωγική μεροληψία. Ωστόσο, δεν είναι προφανές αν αυτή η επαγωγική μεροληψία είναι πάντα η καταλληλότερη για τη μοντελοποίηση long-range σχέσεων στη σκηνή, όπως η σχέση μεταξύ πεζού, διάβασης, φωτεινού σηματοδότη και προσεγγίζοντων οχημάτων.

Τρίτον, η σύγκριση Conv3D και Transformer-based encoders στο πλαίσιο του global scene context δεν έχει μελετηθεί επαρκώς σε πολυτροπικές PIP αρχιτεκτονικές. Οι Transformer-based προσεγγίσεις έχουν δείξει ότι το self-attention μπορεί να είναι ισχυρό για χωροχρονική μοντελοποίηση, αλλά συχνά συνοδεύεται από αυξημένες απαιτήσεις σε δεδομένα, παραμέτρους και regularization. Επομένως, η χρησιμότητα ενός Transformer encoder δεν πρέπει να θεωρείται δεδομένη, αλλά να αξιολογείται πειραματικά.

Τέταρτον, η γενίκευση μεταξύ datasets παραμένει δύσκολη. Τα datasets διαφέρουν ως προς τα annotation protocols, τη διαθεσιμότητα ego-vehicle data, τη γεωγραφική περιοχή, τη συμπεριφορά κυκλοφορίας και τη διαδικασία επιλογής crossing/non-crossing samples. Για τον λόγο αυτό, η αξιοποίηση JAAD ή άλλων datasets για transfer learning πρέπει να γίνεται προσεκτικά, χωρίς να θεωρείται ότι όλα τα datasets παρέχουν ισοδύναμη πληροφορία πρόθεσης. Ειδικά το TITAN, αν και σημαντικό για trajectory forecasting και action understanding, δεν ενσωματώνεται απαραίτητα στα κύρια πειράματα binary crossing intention prediction, εκτός αν υπάρχει σαφής αντιστοίχιση labels και επαρκές πλήθος κατάλληλων samples.

Πέμπτον, πέρα από την τελική επίδοση ενός μοντέλου, παραμένει σημαντική η αναλυτική κατανόηση της συνεισφοράς κάθε τύπου πληροφορίας. Πολλά πολυτροπικά μοντέλα αναφέρουν συνολική βελτίωση από τη σύντηξη διαφορετικών χαρακτηριστικών, όμως δεν είναι πάντα σαφές ποιο modality συμβάλλει περισσότερο, σε ποιον χρονικό ορίζοντα και υπό ποιες συνθήκες. Η διάκριση αυτή είναι ιδιαίτερα κρίσιμη στην πρόβλεψη πρόθεσης πεζού, επειδή η κινηματική πληροφορία, η τοπική οπτική εμφάνιση και το global scene context ενδέχεται να έχουν διαφορετική αξία κοντά στη διάσχιση και σε πιο πρώιμες προβλέψεις. Επομένως, απαιτείται πιο συστηματική αξιολόγηση μέσω per-branch μετρήσεων, ablation studies, ανάλυσης χρονικών οριζώντων και ελέγχου της σταθερότητας των προβλέψεων.

Ένα επιπλέον ερώτημα είναι ποια scene modalities μπορούν πράγματι να αξιοποιηθούν αποδοτικά μέσα σε Transformer-based αρχιτεκτονικές. Η απλή εισαγωγή περισσότερων visual ή contextual tokens δεν εγγυάται βελτίωση, καθώς ορισμένα modalities μπορεί να εισάγουν θόρυβο ή να αποδυναμώνουν το ισχυρό κινηματικό σήμα.

2.6.3 Τοποθέτηση της Παρούσας Εργασίας

Με βάση τα παραπάνω, η παρούσα εργασία τοποθετείται ως συστηματική εξέλιξη της πολυτροπικής λογικής του PIP-Net, με έμφαση όχι μόνο στην τελική απόδοση, αλλά και στην ανάλυση των επιμέρους σχεδιαστικών επιλογών. Η εργασία δεν ισχυρίζεται ότι εισάγει ένα πλήρως νέο πρόβλημα ή ότι αντικαθιστά συνολικά τις υπάρχουσες προσεγγίσεις. Αντίθετα, εξετάζει πώς ένα ισχυρό multimodal πλαίσιο μπορεί να βελτιωθεί και να αναλυθεί μέσω πιο σύγχρονου preprocessing, εναλλακτικής χωρικής μοντελοποίησης του global context, διαφορετικής στρατηγικής σύντηξης των modalities, και προσεκτικής πειραματικής αξιολόγησης.

Ο πρώτος άξονας αφορά την αναβάθμιση του preprocessing pipeline. Η παρούσα εργασία αντικαθιστά παλαιότερα perception modules με νεότερες μεθόδους: RAFT-large

για local optical flow, Mask2Former για panoptic segmentation και ManyDepth για monocular depth estimation. Στόχος δεν είναι να παρουσιαστεί νέα μέθοδος optical flow ή segmentation, αλλά να παραχθούν πιο αξιόπιστες εισοδοί για τους αντίστοιχους branches του PIPN.

Ο δεύτερος άξονας αφορά την αρχιτεκτονική διερεύνηση του global context branch. Η Conv3D-based υλοποίηση διατηρεί τη χωρική δομή των semantic και categorical depth maps και μαθαίνει τοπικά χωροχρονικά μοτίβα. Παράλληλα, εξετάζεται Spatial-Patch Transformer εκδοχή, η οποία αντιμετωπίζει το global context ως ακολουθία χωρικών patches και αξιοποιεί self-attention για τη μοντελοποίηση σχέσεων μεταξύ απομακρυσμένων περιοχών της σκηνής. Η σύγκριση αυτή αντιμετωπίζεται ως εμπειρικό ερώτημα και όχι ως εκ των προτέρων υπόθεση υπεροχής του Transformer.

Ο τρίτος άξονας αφορά τη στρατηγική σύντηξης των modalities και την προτεινόμενη lightweight αρχιτεκτονική KinFormer-GRU. Η αρχική διερεύνηση του global context branch ανέδειξε ότι η απλή αντικατάσταση του Conv3D κλάδου από έναν ανεξάρτητο Transformer μειώνει τις παραμέτρους αλλά δεν διατηρεί την απόδοση του PIPN. Παράλληλα, η βιβλιογραφία (Ενότητα 2.5.3) υποδεικνύει ότι χαμηλής διάστασης structured κινηματικά χαρακτηριστικά αποτελούν ιδιαίτερα ισχυρό σήμα στην πρόβλεψη πρόθεσης [19], [30], [31]. Συνδυάζοντας τις δύο αυτές παρατηρήσεις, η εργασία διερευνά μια εναλλακτική στρατηγική σύντηξης: αντί ο Transformer να λειτουργεί ως ανεξάρτητος late-fusion branch, ο ισχυρός GRU κινηματικός κλάδος διατηρείται ως κεντρικό kinematic anchor, ενώ τα υπόλοιπα scene modalities, όπως categorical depth, traffic-aware segmentation masks, optical flow και local context, εισάγονται ως gated contextual tokens μέσα σε έναν per-frame Transformer. Στη σχεδίαση αυτή, η οποία ονομάζεται KinFormer-GRU, τα contextual modalities δεν αποκτούν ανεξάρτητη late-fusion ψήφο, αλλά μόνο διαμορφώνουν την κινηματική αναπαράσταση μέσω self-attention. Με αυτόν τον τρόπο, η αρχιτεκτονική αποτρέπει εξ ορισμού την ανεξάρτητη ψήφο των scene modalities, κάτι που αποτελεί έναν πιθανό μηχανισμό αντιμετώπισης της αποδυνάμωσης του κινηματικού σήματος που παρατηρήθηκε στις ανεξάρτητες-branch παραλλαγές. Η προσέγγιση αυτή δεν παρουσιάζεται ως αντικαταστάτης του PIPN ως προς τη μέγιστη ακρίβεια, αλλά ως διερεύνηση ενός performance-efficiency trade-off με σημαντικά λιγότερες παραμέτρους.

Ο τέταρτος άξονας αφορά την πειραματική αξιολόγηση και τη γενίκευση. Η εργασία αξιολογεί το μοντέλο σε PIE ως κύριο benchmark και εξετάζει, όπου είναι μεθοδολογικά ασφαλές, στρατηγικές transfer learning ή cross-dataset αξιολόγησης με JAAD. Η χρήση άλλων datasets, όπως το TITAN, παρουσιάζεται προσεκτικά ως διερεύνηση ή πιθανή μελλοντική επέκταση, εκτός αν περιλαμβάνεται πλήρως στα κύρια πειράματα. Ιδιαίτερη έμφαση δίνεται σε ένα αυστηρό fixed-threshold πρωτόκολλο πάνω σε imbalanced, pseudo-event-aligned test set με hard-negative non-crossing παραδείγματα, ώστε τα αποτελέσματα να μην υπερεκτιμώνται.

Συνολικά, η συμβολή της παρούσας εργασίας δεν είναι μία μεμονωμένη τεχνική, αλλά ένας συστηματικός επανασχεδιασμός και έλεγχος ενός πολυτροπικού PIP pipeline. Η εργασία εξετάζει κατά πόσο η βελτίωση των perception inputs, η branch-wise μοντελοποίηση, η εναλλακτική Transformer-based επεξεργασία του global context και μια kinematic-anchored gated στρατηγική σύντηξης μπορούν να συμβάλουν σε πιο αξιόπιστη και πιο αποδοτική πρόβλεψη crossing/non-crossing σε χρονικά παράθυρα πριν από τη διάσχιση.

Χαρακτηριστικό	PIE Baseline	CIPF	Transformer- based models	PIP-Net	Παρούσα εργασία
Bounding box / trajectory	Ναι	Ναι	Ναι	Ναι	Ναι
Pose	Ναι	Ναι	Ανάλογα με το μοντέλο	Ναι	Ναι
Ego-vehicle speed	Ναι	Ναι	Ανάλογα με το μοντέλο	Ναι	Ναι, όπου είναι διαθέσιμη
Local appearance	Όχι	Ναι	Ανάλογα με το μοντέλο	Ναι	Ναι
Optical flow	Όχι	Όχι	Όχι	FlowNet2	RAFT-large
Segmentation	Όχι	Semantic	Όχι πάντα	Panoptic / Slot-VPS	Panoptic / Mask2Former
Depth	Όχι	Όχι	Όχι	Categorical depth	Categorical depth
Κύριος temporal encoder	LSTM	GRU + C3D	Self-attention / Transformer	GRU + Conv3D + attention	GRU + Conv3D / Spatial-Patch Transformer / KinFormer-GRU
Κύρια αξία για την παρούσα εργασία	Θεμελίωση task	Feature fusion	Long-range attention	Βασικό αρχιτεκτονικό reference	Αναβάθμιση και συστηματικός έλεγχος

Πίνακας 2.3: Σύγκριση της παρούσας εργασίας με τα αντιπροσωπευτικά frameworks

Κεφάλαιο 3 Μεθοδολογία

Το παρόν κεφάλαιο παρουσιάζει τη μεθοδολογία της εργασίας για την πρόβλεψη πρόθεσης διάσχισης πεζού μέσω πολυτροπικής αρχιτεκτονικής PIPN. Το πρόβλημα διατυπώνεται ως δυαδική ταξινόμηση crossing/non-crossing σε χρονικό παράθυρο πριν από το ενδεχόμενο συμβάν διάσχισης. Η έννοια της πρόθεσης χρησιμοποιείται επιχειρησιακά: το μοντέλο δεν προβλέπει άμεσα μια εσωτερική ψυχολογική κατάσταση του πεζού, αλλά εκτιμά, με βάση παρατηρήσεις προηγούμενων frames, αν ο πεζός θα ανήκει σε crossing ή non-crossing περίπτωση.

Η βασική μεθοδολογική υπόθεση της εργασίας είναι ότι η πρόβλεψη αυτή δεν μπορεί να βασιστεί αξιόπιστα σε μία μόνο κατηγορία χαρακτηριστικών. Η τροχιά του bounding box παρέχει σημαντική κινηματική πληροφορία, αλλά δεν αρκεί για αμφίσημες σκηνές. Η στάση σώματος, η τοπική εμφάνιση, η οπτική κίνηση, η σημασιολογική διάταξη της σκηνής και η σχετική γεωμετρία πεζών και οχημάτων συνεισφέρουν συμπληρωματικά. Για τον λόγο αυτό, η προτεινόμενη προσέγγιση ακολουθεί πολυκλαδικό σχεδιασμό, όπου κάθε κατηγορία πληροφορίας επεξεργάζεται από εξειδικευμένο branch και οι επιμέρους αναπαραστάσεις συνδυάζονται σε μεταγενέστερο στάδιο μέσω attention-based fusion.

Κεντρική σχεδιαστική επιλογή αποτελεί ο διαχωρισμός της μεθόδου σε δύο φάσεις. Στην πρώτη φάση, τα βαριά perception modules, όπως panoptic segmentation, optical flow, monocular depth estimation και pose estimation, εφαρμόζονται offline στα βίντεο. Το αποτέλεσμα είναι ένα οργανωμένο feature store από αρχεία NPZ, όπου κάθε δείγμα περιέχει χρονικά ευθυγραμμισμένα tensors για όλα τα modalities. Στη δεύτερη φάση, το PIPN εκπαιδεύεται πάνω σε αυτά τα προϋπολογισμένα χαρακτηριστικά, χωρίς να απαιτείται εκτέλεση των perception models μέσα στο training loop. Αυτή η επιλογή βελτιώνει την υπολογιστική αποδοτικότητα, επιτρέπει αναπαραγωγίμα πειράματα και καθιστά δυνατή τη δίκαιη σύγκριση διαφορετικών αρχιτεκτονικών πάνω στο ίδιο σύνολο χαρακτηριστικών.

3.1 Διατύπωση Προβλήματος και Κατασκευή Δειγμάτων

3.1.1 Επιχειρησιακός ορισμός του crossing intention

Η εργασία αντιμετωπίζει την πρόβλεψη πρόθεσης διάσχισης ως δυαδικό πρόβλημα ταξινόμησης. Για κάθε πεζό και για κάθε χρονικό παράθυρο παρατήρησης, το μοντέλο λαμβάνει ως είσοδο μια ακολουθία πολυτροπικών χαρακτηριστικών και παράγει πιθανότητα διάσχισης:

$$\hat{y} = P(y = 1 | X)$$

όπου $y=1$ αντιστοιχεί σε crossing περίπτωση και $y=0$ σε non-crossing περίπτωση. Το X περιλαμβάνει την ακολουθία χαρακτηριστικών του πεζού, του οχήματος και της σκηνής μέσα σε παράθυρο T frames.

Η διατύπωση αυτή διατηρεί σαφή διάκριση μεταξύ πρόθεσης και τελικής δράσης. Το μοντέλο δεν εκπαιδεύεται για να αναγνωρίζει μια διάσχιση αφού αυτή έχει ήδη ξεκινήσει, αλλά για να εκτιμά την πιθανότητα μελλοντικής διάσχισης σε χρονικό παράθυρο πριν

από το συμβάν. Συνεπώς, το task παραμένει crossing intention estimation, παρότι το supervised label βασίζεται τελικά στην crossing/non-crossing έκβαση.

3.1.2 Χρονικό παράθυρο παρατήρησης και Time-to-Event

Κάθε δείγμα κατασκευάζεται ως ακολουθία σταθερού μήκους T . Στην τρέχουσα υλοποίηση του preprocessing, το προεπιλεγμένο μήκος είναι $T=10$ frames, με temporal stride 2 και TTE εύρος 30–60 raw frames, δηλαδή περίπου 1–2 δευτερόλεπτα πριν από το reference event στα 30 fps. Οι παράμετροι αυτές ορίζονται ρητά στο script `prep_kinematics.py`, το οποίο χρησιμοποιεί sliding windows με `seq_len=10`, `stride=2`, `tte_min=30` και `tte_max=60`.

Για θετικά δείγματα, το reference event είναι το πρώτο frame στο οποίο ο πεζός χαρακτηρίζεται ως crossing. Το τελευταίο frame του observation window πρέπει να βρίσκεται πριν από αυτό το συμβάν, έτσι ώστε η πρόβλεψη να είναι πραγματικά early prediction. Για αρνητικά δείγματα, όπου δεν υπάρχει crossing event, χρησιμοποιείται pseudo-event frame. Η επιλογή του pseudo-event επιτρέπει να οριστεί αντίστοιχο TTE και για non-crossing tracks, ώστε τα θετικά και αρνητικά δείγματα να είναι χρονικά συγκρίσιμα.

Η στρατηγική αυτή είναι σημαντική γιατί αποφεύγει την εκπαίδευση του μοντέλου σε τετριμμένες περιπτώσεις. Αν τα crossing δείγματα λαμβάνονταν πολύ κοντά ή μετά την έναρξη της διάσχισης, το μοντέλο θα μπορούσε να μάθει απλώς την αναγνώριση ήδη εκτελεσμένης κίνησης. Αντίθετα, με τη χρήση TTE και hard negative περιπτώσεων, το μοντέλο καλείται να εκτιμήσει τη μελλοντική συμπεριφορά του πεζού πριν αυτή γίνει πλήρως εμφανής.

Στο πειραματικό πρωτόκολλο της παρούσας εργασίας, κάθε δείγμα αποτελείται από μια χρονικά διατεταγμένη ακολουθία παρατήρησης πριν από το κρίσιμο καρέ. Το μοντέλο δεν λαμβάνει frames μετά το κρίσιμο σημείο, ώστε η πρόβλεψη να παραμένει αιτιοκρατικά συμβατή με σενάριο πραγματικού χρόνου. Η γενική χρονική διάταξη του προβλήματος παρουσιάστηκε στο Σχήμα 2.4.

3.1.3 Θετικά και αρνητικά δείγματα

Για κάθε pedestrian track, τα θετικά δείγματα προκύπτουν από tracks στα οποία υπάρχει crossing event. Το observation window επιλέγεται έτσι ώστε να προηγείται χρονικά του crossing event και να εμπίπτει στο προκαθορισμένο TTE εύρος. Για τα αρνητικά δείγματα, όπου ο πεζός δεν διασχίζει, δεν υπάρχει φυσικό reference event. Για τον λόγο αυτό, το preprocessing χρησιμοποιεί pseudo-event selection. Στην υλοποίηση υπάρχει hybrid στρατηγική επιλογής pseudo-event, η οποία περιγράφεται αναλυτικά στην επόμενη παράγραφο.

Σημαντική σχεδιαστική επιλογή είναι ο τρόπος κατασκευής των αρνητικών δειγμάτων. Αντί για την default στρατηγική επιλογής τυχαίων ακολουθιών από non-crossing tracks, η παρούσα εργασία αξιοποιεί τα human intention reference data του PIE. Όπου ήταν διαθέσιμα τα αντίστοιχα frames, το pseudo-event για τα non-crossing δείγματα τοποθετήθηκε στη χρονική περιοχή με το υψηλότερο intention score. Με αυτόν τον τρόπο, τα αρνητικά δείγματα δεν είναι τυχαία και τετριμμένα, αλλά hard negatives: περιπτώσεις πε-

ζών που εμφανίζουν ενδείξεις πιθανής διάσχισης αλλά τελικά δεν διασχίζουν. Η σύγκριση τέτοιων περιπτώσεων με πραγματικά crossing δείγματα φέρνει το πρόβλημα πιο κοντά στην εκτίμηση πρόθεσης (intention estimation) και μακριά από την απλή αναγνώριση ήδη εκτελεσμένης δράσης (action recognition). Έτσι, τα αρνητικά δείγματα είναι χρονικά ευθυγραμμισμένα παραδείγματα στα οποία ο πεζός παραμένει non-crossing παρά την ύπαρξη πιθανών ενδείξεων ή αμφισημίας, ενισχύοντας τη δυσκολία του προβλήματος και φέρνοντας την αξιολόγηση πιο κοντά στην πραγματική χρήση ενός συστήματος υποβοήθησης ή αυτόνομης οδήγησης.

3.2 Offline Preprocessing Pipeline

Το preprocessing pipeline μετατρέπει τα αρχικά βίντεο σε πεζοκεντρικές ακολουθίες χαρακτηριστικών. Για κάθε δείγμα δημιουργείται ένα αρχείο NPZ που περιέχει τις εισόδους όλων των branches: bounding boxes, pose keypoints, ego-speed, local appearance features, local optical flow, semantic labels και categorical depth. Το pipeline οργανώνεται σε τρία βασικά στάδια.

Δύο πρακτικές επιλογές διατρέχουν ολόκληρο το pipeline. Πρώτον, για όλα τα perception modules επιλέχθηκαν, όπου ήταν διαθέσιμα, προεκπαιδευμένα βάρη σε driving-oriented datasets αντί για γενικού σκοπού βάρη, καθώς η ποιότητα και η συνάφεια των frozen perception features με το domain της αυτόνομης οδήγησης επηρεάζει άμεσα την απόδοση των downstream branches. Δεύτερον, σε αντίθεση με κοινές υλοποιήσεις που εξαγουν πρώτα όλα τα frames ως εικόνες, η παρούσα υλοποίηση διαβάζει τα απαραίτητα frames απευθείας από τα βίντεο κατά το preprocessing, μειώνοντας σημαντικά τις απαιτήσεις αποθήκευσης, ιδίως όταν τα ίδια videos χρησιμοποιούνται επανειλημμένα για την παραγωγή διαφορετικών modalities.

3.2.1 Στάδιο 1 — Κινηματικά χαρακτηριστικά πεζού και οχήματος

Το πρώτο στάδιο κατασκευάζει τη βασική δομή κάθε δείγματος και εξάγει τα κινηματικά χαρακτηριστικά. Περιλαμβάνει τα bounding box coordinates, τα pose keypoints και την ego-vehicle speed.

Τα bounding boxes αναπαριστώνται ως τετράδες: $bt=[x1,y1,x2,y2]$ για κάθε χρονικό βήμα t . Οι συντεταγμένες κανονικοποιούνται ως προς τις διαστάσεις του frame, ώστε η αναπαράσταση να μην εξαρτάται από την ανάλυση του βίντεο. Η ακολουθία bounding boxes κωδικοποιεί τη σχετική μετακίνηση του πεζού, την αλλαγή κλίμακας λόγω προσέγγισης ή απομάκρυνσης, καθώς και τη θέση του μέσα στη σκηνή.

Η pose πληροφορία εξάγεται με YOLOv8-pose [34] σε crop γύρω από το bounding box του πεζού. Η χρήση crop, αντί για εκτέλεση στο πλήρες frame, μειώνει την επίδραση του background και εστιάζει την εκτίμηση στο άτομο ενδιαφέροντος. Για κάθε frame αποθηκεύονται 17 keypoints σε COCO format [35], δηλαδή 34 τιμές (x,y) . Σε περίπτωση αποτυχίας του pose estimator, το αντίστοιχο διάνυσμα μηδενίζεται, ώστε να διατηρείται σταθερό το σχήμα των δεδομένων.

Το Σχήμα 3.1 παρουσιάζει ενδεικτικά τη μορφή των κινηματικών χαρακτηριστικών που εξάγονται στο πρώτο στάδιο του preprocessing. Το bounding box παρέχει τη χωρική θέση και την κλίμακα του πεζού μέσα στο frame, ενώ τα pose keypoints προσθέ-

τούν λεπτομερέστερη πληροφορία για τη στάση και τη δυναμική του σώματος. Οι δύο αυτές πηγές πληροφορίας χρησιμοποιούνται στη συνέχεια από τον kinematic branch της αρχιτεκτονικής

Bounding box + pose (17 COCO keypoints)



Σχήμα 3.1: Παράδειγμα εξαγωγής κινηματικών χαρακτηριστικών από frame του PIE dataset. Ο target pedestrian επισημαίνεται με bounding box, ενώ η στάση σώματος αναπαρίσταται με 17 COCO keypoints.

Η ego-vehicle speed αποθηκεύεται ως χρονική ακολουθία ενός scalar ανά frame. Στο PIE, η πληροφορία αυτή προέρχεται από OBD-II δεδομένα. Σε datasets όπου η ego-speed δεν είναι διαθέσιμη, όπως το JAAD, το αντίστοιχο tensor μπορεί να συμπληρώνεται με μηδενικές τιμές. Αυτό δεν σημαίνει ότι η ταχύτητα θεωρείται μηδενική στην πραγματικότητα, αλλά ότι το συγκεκριμένο modality δεν είναι διαθέσιμο και το μοντέλο δεν μπορεί να το αξιοποιήσει ουσιαστικά για εκείνο το dataset.

Το στάδιο αυτό αποθηκεύει επίσης metadata, όπως pedestrian ID, video ID, frame indices, split, TTE και flags που δείχνουν ποια preprocessing στάδια έχουν ολοκληρωθεί. Το τελικό αρχείο NPZ λειτουργεί ως ενιαία μονάδα εισόδου για τα επόμενα στάδια.

3.2.2 Στάδιο 2 — Τοπική οπτική εμφάνιση και κίνηση

Το δεύτερο στάδιο εξάγει pedestrian-centric οπτικά χαρακτηριστικά. Στόχος του είναι να περιγράψει όχι ολόκληρη τη σκηνή, αλλά την τοπική περιοχή γύρω από τον πεζό. Η πληροφορία αυτή αντιστοιχεί στον local visual branch της αρχιτεκτονικής.

Για την τοπική εμφάνιση, από κάθε frame εξάγεται crop γύρω από τον πεζό, με μικρή επέκταση του bounding box ώστε να περιλαμβάνεται και άμεσο περιβάλλον. Το crop γίνεται resize σε 224×224 και κανονικοποιείται με ImageNet statistics. Στη συνέχεια περνά από το convolutional trunk ενός VGG19 [36] προεκπαιδευμένου στο ImageNet [37]. Το fully connected τμήμα του VGG19 δεν χρησιμοποιείται· αποθηκεύονται μόνο τα

convolutional feature maps. Το script `prep_local.py` χρησιμοποιεί VGG19 με IMAGENET1K_V1 weights και εξάγει features σε inference mode, χωρίς gradient computation.

Η τοπική οπτική είσοδος δεν περιορίζεται αυστηρά στο σώμα του πεζού, αλλά περιλαμβάνει και μικρό τμήμα του άμεσου περιβάλλοντος. Αυτό επιτρέπει στο μοντέλο να αξιοποιήσει ενδείξεις όπως ο προσανατολισμός του σώματος, η σχέση με το πεζοδρόμιο ή το οδόστρωμα και η ύπαρξη κοντινών αντικειμένων.



Σχήμα 3.2: Παράδειγμα τοπικής οπτικής εισόδου. Από το πλήρες RGB frame εξάγεται crop γύρω από τον target pedestrian, με μικρή επέκταση του bounding box ώστε να διατηρείται μέρος του άμεσου περιβάλλοντος. Το crop αναδιαστασιολογείται σε 224x224 και χρησιμοποιείται για την εξαγωγή local appearance features.

Για την τοπική κίνηση, υπολογίζεται dense optical flow μεταξύ διαδοχικών pedestrian crops. Η παρούσα υλοποίηση χρησιμοποιεί RAFT, με δυνατότητα επιλογής small ή large έκδοσης και προκαθορισμένη χρήση driving-oriented weights για το RAFT-large. Το flow υπολογίζεται σε crop γύρω από τον πεζό, αντί για ολόκληρο το frame, ώστε να μειωθεί η επίδραση του ego-motion της κάμερας και να ενισχυθεί η πληροφορία που σχετίζεται με την κίνηση του σώματος του πεζού. Το πρώτο frame κάθε ακολουθίας λαμβάνει μηδενικό flow, καθώς δεν υπάρχει προηγούμενο frame με το οποίο να συγκριθεί.

Σε αντίθεση με το global optical flow ολόκληρου του frame, το local optical flow εστιάζει στην περιοχή του target pedestrian. Με αυτόν τον τρόπο, η αναπαράσταση είναι περισσότερο σχετική με τη μικρο-κίνηση του πεζού, όπως μεταβολές στάσης, βηματισμό ή κατεύθυνση κίνησης. Όπως φαίνεται στο Σχήμα 3.3 ο πεζός ξεχωρίζει ως σκούρα/πράσινη περιοχή κατά την οπτικοποίηση του flow σε HSV (απόχρωση = κατεύθυνση, ένταση = μέγεθος κίνησης).



Σχήμα 3.3: Παράδειγμα *local motion representation*. Το *pedestrian crop* χρησιμοποιείται για την εκτίμηση πυκνού *optical flow* με RAFT, το οποίο αποτυπώνει την τοπική κίνηση του πεζού και του άμεσου περιβάλλοντος. Η κωδικοποίηση της κίνησης περιορίζεται στην περιοχή ενδιαφέροντος, μειώνοντας την επίδραση άσχετης κίνησης από την υπόλοιπη σκηνή.

Η διάκριση *local appearance* και *local motion* είναι σημαντική. Η εμφάνιση μπορεί να περιέχει ενδείξεις όπως προσανατολισμό σώματος ή στάση, ενώ το *optical flow* κωδικοποιεί τη μεταβολή αυτών των οπτικών στοιχείων στον χρόνο. Τα δύο αυτά *streams* είναι συμπληρωματικά και συνδυάζονται αργότερα στον *local visual branch*.

3.2.3 Στάδιο 3 — Global scene context και categorical depth

Το τρίτο στάδιο εξάγει πληροφορία που αφορά ολόκληρη τη σκηνή. Σε αντίθεση με τα *pedestrian crops*, το *global context* διατηρεί τη γεωμετρική διάταξη του δρόμου, των πεζοδρομίων, των οχημάτων και των υπόλοιπων στοιχείων του περιβάλλοντος. Το στάδιο αυτό παράγει δύο βασικές εισόδους: *semantic labels* και *categorical depth*.


Για το *panoptic segmentation* χρησιμοποιείται Mask2Former με Cityscapes *panoptic* προεκπαίδευση. Το script `prep_scene.py` περιλαμβάνει Mask2Former *panoptic* inference, Cityscapes-style *resize*, mapping από Cityscapes σε PIP-specific class space, ManyDepth για *depth estimation*, IoU-based instance tracking μέσα στο *temporal window* και παραγωγή *categorical depth* για pedestrians και vehicles.

Τα *semantic labels* αποθηκεύουν για κάθε pixel την κατηγορία στην οποία ανήκει. Η πληροφορία αυτή επιτρέπει στο μοντέλο να γνωρίζει τη χωρική διάταξη κρίσιμων στοιχείων, όπως *road*, *sidewalk*, *sky*, *building*, *person*, *car* και άλλα *road users*. Παράλληλα, οι *instance masks* που παράγονται από το *panoptic segmentation* χρησιμοποιούνται για την κατασκευή του *categorical depth*.

Η εκτίμηση βάθους γίνεται με ManyDepth. Ο *raw depth map* δεν χρησιμοποιείται απευθείας ως είσοδος, επειδή οι *monocular depth* εκτιμήσεις μπορεί να είναι θορυβώδεις,


ιδίως στα όρια αντικειμένων. Αντί αυτού, η παρούσα εργασία ακολουθεί την ιδέα του categorical depth: οι τιμές βάθους φιλτράρονται μέσω instance masks πεζών και οχημάτων και συνοψίζονται σε σταθερότερες τιμές ανά instance. Το αποτέλεσμα είναι ένα tensor δύο καναλιών, όπου το πρώτο κανάλι αντιστοιχεί σε pedestrians και το δεύτερο σε vehicles.

Κατά την εφαρμογή του panoptic segmentation παρατηρήθηκε ένα συστηματικό artifact στο κάτω μέρος του frame: ο καπό του ego-vehicle ταξινομούνταν συχνά ως όχημα (car). Ως αποτέλεσμα, η αντίστοιχη περιοχή λάμβανε εσφαλμένες τιμές categorical depth, εισάγοντας θόρυβο στο global context. Για την αντιμετώπιση του προβλήματος αναπτύχθηκε ένα διορθωτικό βήμα καταστολής του ego-vehicle (ego-vehicle suppression), το οποίο αντικαθιστά την περιοχή του καπό με την κατηγορία road. Η διόρθωση αυτή βασίστηκε σε εμπειρική παρατήρηση των segmentation outputs και ήταν σωστή στη συντριπτική πλειονότητα των περιπτώσεων. Επειδή η θέση και η έκταση του ορατού καπό διαφέρει μεταξύ datasets, το όριο της καταστολής ρυθμίστηκε ανά dataset: συγκεκριμένα, για το JAAD, όπου ο καπό εμφανιζόταν σε υψηλότερο σημείο του frame, το όριο ορίστηκε χειροκίνητα ελαφρώς ψηλότερα.




Σχήμα 3.4: Καταστολή του ego-vehicle (ego-suppression). (a) Αρχικό RGB frame. (b) Panoptic segmentation πριν την καταστολή το καπό του οχήματος στο κάτω μέρος ταξινομείται εσφαλμένα ως όχημα. (c) Μετά την καταστολή, η περιοχή κάτω από το όριο $y \geq 0.88 \cdot H$ αντικαθίσταται με την κατηγορία road. (d) Επισήμανση της περιοχής καταστολής.

Αυτή η αναπαράσταση είναι πιο κατάλληλη για το crossing prediction από έναν γενικό depth heatmap, επειδή εστιάζει στους road users που έχουν άμεση σχέση με την απόφαση διάσχισης. Έτσι, ο global context branch δεν λαμβάνει μόνο σημασιολογική πληροφορία για το “τι υπάρχει” στη σκηνή, αλλά και γεωμετρική πληροφορία για το “πόσο κοντά” βρίσκονται πεζοί και οχήματα.



Σχήμα 3.5: Κατασκευή categorical depth από raw monocular depth και instance masks. Τα κανάλια πεζών και οχημάτων διατηρούν μόνο τις αντίστοιχες κατηγορίες road users, αποδίδοντας σε κάθε instance σταθερή τιμή σχετικής εγγύτητας.

Η categorical depth αναπαράσταση λειτουργεί ως instance-aware γεωμετρικό cue. Αντί το μοντέλο να επεξεργάζεται ολόκληρο το noisy depth map (Σχήμα 3.5 (b)), η πληροφορία περιορίζεται σε κατηγορίες άμεσης σημασίας για το pedestrian intention



prediction, δηλαδή πεζούς (c) και οχήματα (d) αναθέτοντας μια σταθερή τιμή εγγύτητας, παρέχοντας πιο ευσταθή είσοδο στον global branch. Στο σχήμα 3.6 παρατηρούμε όσο πιο κοντά είναι τα οχήματα και οι πεζοί στο ego-vehicle τόσο πιο ανοιχτά είναι τα χρώματα και όσο πιο μακριά είναι γίνονται όλο και πιο σκούρα.

Σχήμα 3.6: Παράδειγμα categorical depth πεζών και οχημάτων σε μία εικόνα

3.2.4 Κανονικοποίηση και φόρτωση δεδομένων

Μετά την ολοκλήρωση του preprocessing, τα δείγματα φορτώνονται από τον DataLoader ως tensors. Η υλοποίηση PIESeqDataset διαβάζει τα NPZ αρχεία και φορτώνει τα βασικά πεδία: bbox, pose, speed, local_cnn, local_motion, sem_labels, cat_depth και label. Επίσης εφαρμόζει κανονικοποίηση ταχύτητας με min-max scaling και κανονικοποίηση optical flow με p99 absolute scaling, όταν έχουν δοθεί τα αντίστοιχα statistics files.

Η κανονικοποίηση πρέπει να υπολογίζεται αποκλειστικά από το training split, ώστε να αποφεύγεται data leakage από validation ή test δεδομένα. Για την ego-speed χρησιμοποιείται min-max normalization, ενώ για το optical flow χρησιμοποιείται p99 clipping/scaling, επειδή οι τιμές flow μπορεί να έχουν μεγάλα outliers λόγω θορύβου ή απότομης κίνησης.

Modality	NPZ	Σχήμα	Ρόλος
Bounding box	bbbox	(T,4)	Τροχιά και χωρική θέση πεζού
Pose	pose	(T,34)	Στάση σώματος και keypoint dynamics
Ego-speed	speed	(T,1)	Δυναμική ego-vehicle
Local appearance	local_cnn	(T,512,7,7)	Τοπική οπτική εμφάνιση πεζού
Local motion	local_motion	(T,2,224,224)	Optical flow γύρω από τον πεζό
Semantic context	sem_labels	(T,H,W)	Σημασιολογική διάταξη σκηνής
Categorical depth	cat_depth	(T,2,H,W)	Instance-aware εγγύτητα πεζών/οχημάτων


Πίνακας 3.1: Βασικές είσοδοι του μοντέλου.

3.3 Αρχιτεκτονική PIPN

3.3.1 Επισκόπηση

Η προτεινόμενη αρχιτεκτονική ακολουθεί πολυκλαδικό σχεδιασμό. Κάθε branch επεξεργάζεται διαφορετικό είδος πληροφορίας και παράγει χρονική αναπαράσταση. Οι αναπαραστάσεις αυτές συμπυκνώνονται μέσω attention και συνδυάζονται σε μεταγενέστερο στάδιο.

Στην τρέχουσα υλοποίηση PIPN, η αρχιτεκτονική περιλαμβάνει τρεις κύριους κλάδους: kinematic branch, local visual branch και global context branch. Ο kinematic branch επεξεργάζεται bounding box, pose και speed μέσω διαδοχικών GRU. Ο local visual branch επεξεργάζεται local appearance, μέσω spatial pooling και GRU, και local motion, μέσω Conv3D και GRU. Ο global context branch επεξεργάζεται semantic labels και categorical depth μέσω Conv3D towers, ακολουθούμενων από flattening, fully connected projections και temporal GRU. Στη συνέχεια, τα visual και kinematic embeddings συνδυάζονται με attention-based late fusion και οδηγούνται σε τελικό sigmoid classifier. Η συνολική αρχιτεκτονική, μαζί με τις διαστάσεις των ενδιάμεσων αναπαραστάσεων κάθε κλάδου, απεικονίζεται στο Σχήμα 3.7.



Σχήμα 3.7: Επισκόπηση της αρχιτεκτονικής PIPN. Οι τρεις κλάδοι (kinematic, local visual, global context) επεξεργάζονται ανεξάρτητα τα αντίστοιχα modalities και συντήκονται μέσω attention-based late fusion. Τα auxiliary heads (Aux) χρησιμοποιούνται μόνο κατά την εκπαίδευση.

Σε σχέση με το αρχικό PIP-Net [8], η παρούσα υλοποίηση διατηρεί τη βασική πολυκλαδική λογική, αλλά διαφοροποιείται σε επιμέρους σημεία του preprocessing και του global context branch. Οι αποκλίσεις αυτές δεν παρουσιάζονται εδώ αναλυτικά, ώστε να διατηρηθεί καθαρή η περιγραφή της αρχιτεκτονικής· τεκμηριώνονται συγκεντρωτικά στην Ενότητα 3.7.

3.3.2 Kinematic branch

Ο kinematic branch επεξεργάζεται τρία structured temporal signals: bounding boxes, pose keypoints και ego-vehicle speed. Η αρχιτεκτονική δεν τα συνενώνει όλα απευθείας στην είσοδο, αλλά τα επεξεργάζεται σταδιακά. Αρχικά, τα pose keypoints περνούν από GRU ώστε να εξαχθεί χρονική αναπαράσταση στάσης σώματος. Στη συνέχεια, η pose αναπαράσταση συνενώνεται με το bounding box και περνά από δεύτερο GRU. Τέλος, προστίθεται η ego-speed και το αποτέλεσμα περνά από τρίτο GRU, παράγοντας την τελική κρυφή ακολουθία του branch. Η υλοποίηση αυτή φαίνεται στον KinematicBranch, όπου χρησιμοποιούνται διαδοχικά pose_gru, pose_bbox_gru και full_gru.

Η σταδιακή αυτή σύνθεση έχει μεθοδολογικό νόημα. Το pose περιγράφει τη στάση του σώματος, το bounding box την τροχιά και τη θέση του πεζού, ενώ η ego-speed προσθέτει πληροφορία για τη δυναμική του οχήματος. Με αυτόν τον τρόπο, ο branch μαθαίνει

όχι μόνο πώς κινείται ο πεζός, αλλά και πώς αυτή η κίνηση σχετίζεται με την κατάσταση του ego-vehicle.

Η συγκεκριμένη σειρά επεξεργασίας (pose, έπειτα bounding box, έπειτα ego-speed) υιοθετείται από την αρχιτεκτονική CIPF και διατηρείται και στο PIP-Net, χωρίς ωστόσο καμία από τις δύο εργασίες να την αιτιολογεί ρητά. Μια εύλογη ερμηνεία είναι ότι τα διαφορετικά signals απαιτούν διαφορετικό βάθος χρονικής επεξεργασίας: η στάση σώματος (pose) είναι το πιο σύνθετο και υψηλοδιάστατο σήμα και ωφελείται από βαθύτερη ακολουθιακή κωδικοποίηση, ενώ το bounding box και η ego-speed προστίθενται σταδιακά ως πιο απλά, χαμηλοδιάστατα σήματα. Η σταδιακή αυτή σύνθεση επιτρέπει σε κάθε signal να ενσωματωθεί στο κατάλληλο επίπεδο αναπαράστασης, αντί να συγχωνεύονται όλα πρόωρα στην είσοδο.

3.3.3 Local visual branch

Ο local visual branch συνδυάζει δύο pedestrian-centric modalities: local appearance και local motion. Η local appearance προέρχεται από VGG19 feature maps, ενώ η local motion από RAFT optical flow maps.

Στην τρέχουσα υλοποίηση, τα VGG19 feature maps συμπεκνώνονται χωρικά μέσω adaptive pooling και προβάλλονται σε χαμηλότερη διάσταση. Στη συνέχεια περνούν από GRU που κωδικοποιεί τη χρονική εξέλιξη της τοπικής εμφάνισης.

Η τοπική κίνηση, αντίθετα, επεξεργάζεται με τρισδιάστατες συνελίξεις. Τα local optical flow maps, σχήματος (T, 2, H, W), αναδιατάσσονται σε χωροχρονικό όγκο (2, T, H, W) και τροφοδοτούνται σε δύο διαδοχικά Conv3D blocks με kernel $3 \times 3 \times 3$ και ενδιάμεσο spatial max-pooling. Με αυτόν τον τρόπο, ο branch δεν επεξεργάζεται κάθε flow map ανεξάρτητα, αλλά μαθαίνει τοπικά χωροχρονικά μοτίβα κίνησης του πεζού μέσα στο παράθυρο παρατήρησης. Στη συνέχεια, τα motion features συμπεκνώνονται χωρικά μέσω spatial averaging, προβάλλονται σε σταθερή διάσταση και περνούν από GRU για τη χρονική τους κωδικοποίηση. Τέλος, τα δύο streams (content και motion) συνενώνονται και περνούν από fuse GRU, παράγοντας την τελική local visual ακολουθία. Η υλοποίηση περιλαμβάνει επίσης dropout ανάμεσα στα GRU stages για regularization.

Η επιλογή Conv3D αντί για ανεξάρτητη Conv2D επεξεργασία ανά frame είναι μεθοδολογικά σημαντική. Η κίνηση του πεζού, όπως η έναρξη βηματισμού, η στροφή του κορμού ή η μεταβολή κατεύθυνσης, είναι εγγενώς χωροχρονικό φαινόμενο. Τα τρισδιάστατα φίλτρα επιτρέπουν στο μοντέλο να συλλάβει τη συνέχεια της κίνησης μεταξύ διαδοχικών flow maps απευθείας, αντί να μεταθέτει όλη τη χρονική μοντελοποίηση στο GRU.

Ο local visual branch είναι υπεύθυνος για cues που δεν εμφανίζονται καθαρά στα structured kinematic features. Για παράδειγμα, η κατεύθυνση σώματος, η μεταβολή στάσης, μικροκινήσεις και τοπικές αλλαγές γύρω από τον πεζό μπορούν να συμβάλουν στην πρόβλεψη ακόμη και όταν η τροχιά του bounding box είναι αμφίσημη.

3.3.4 Global context branch

Ο global context branch επεξεργάζεται τη σημασιολογική και γεωμετρική πληροφορία ολόκληρης της σκηνής. Οι είσοδοί του είναι τα sem_labels και cat_depth.

Τα semantic labels περνούν πρώτα από learnable embedding layer, ώστε κάθε κα-

τηγορία να μετατραπεί σε συνεχή διανυσματική αναπαράσταση 16 διαστάσεων. Στη συνέχεια, η χωρική ανάλυση μειώνεται μέσω learned downsampling, υλοποιημένου με δύο διαστάτες συνελίξεις με stride 2, ακολουθούμενες από adaptive max-pooling σε σταθερό target size 64×64 . Το categorical depth, με τα δύο του κανάλια, περνά από αντίστοιχο αλλά ξεχωριστό Conv2D downsampling module. Το βήμα αυτό είναι κρίσιμο για την υπολογιστική αποδοτικότητα: οι τρισδιάστατες συνελίξεις είναι ακριβές σε μνήμη και χρόνο, και η εφαρμογή τους απευθείας σε full-resolution maps θα ήταν απαγορευτική. Μειώνοντας πρώτα τη χωρική ανάλυση με ελαφριά Conv2D layers, ο όγκος που τροφοδοτεί τα Conv3D blocks γίνεται σημαντικά μικρότερος, διατηρώντας παράλληλα τη βασική χωρική δομή της σκηνής.

Τα δύο streams επεξεργάζονται έπειτα με ξεχωριστά Conv3D towers (semantic: $16 \rightarrow 16 \rightarrow 32 \rightarrow 64$ κανάλια, depth: $2 \rightarrow 16 \rightarrow 32 \rightarrow 64$ κανάλια). Κάθε tower εφαρμόζει τρία MaxPool3d με kernel (1, 2, 2): η χωρική ανάλυση μειώνεται από 64×64 σε 8×8 , ενώ η χρονική διάσταση T διατηρείται αμετάβλητη. Η επιλογή max-pooling έναντι average-pooling στα Conv3D towers είναι σκόπιμη. Στα semantic και depth maps, η κρίσιμη πληροφορία είναι συχνά τοπικά συγκεντρωμένη π.χ. η παρουσία ενός πεζού ή ενός οχήματος σε μια συγκεκριμένη περιοχή — και το max-pooling διατηρεί τις ισχυρότερες ενεργοποιήσεις, λειτουργώντας ως ανιχνευτής παρουσίας χαρακτηριστικού, αντί να τις εξομαλύνει όπως το average-pooling. Η τελική χωρική ανάλυση 8×8 δεν αποτελεί πλήρη κατάρρευση της χωρικής δομής σε ένα διάνυσμα, αλλά ένα αδρό χωρικό πλέγμα 64 θέσεων που διατηρεί τη γενική γεωμετρία της σκηνής: τη σχετική θέση πεζών και οχημάτων, την κατεύθυνση του δρόμου και την κατανομή εγγύτητας. Αυτή η χωρική πληροφορία μεταφέρεται στο επόμενο στάδιο μέσω του flattening (4096 τιμές ανά frame) και της προβολής σε 256 διαστάσεις, ώστε το temporal GRU να λαμβάνει μια χωρικά-ενήμερη αλλά συμπυκνωμένη αναπαράσταση ανά χρονικό βήμα. Η επιλογή αυτή εξασφαλίζει ότι κάθε χρονικό βήμα παραμένει διακριτό για τη μετέπειτα ακολουθιακή μοντελοποίηση. Στη συνέχεια, κάθε tower flattenάρεται ($64 \times 8 \times 8 = 4096$) και προβάλλεται μέσω ξεχωριστού fully connected layer σε διάσταση 256. Τα δύο projections, semantic και depth, συνενώνονται σε διάνυσμα 512 ανά frame και τροφοδοτούν ένα temporal GRU που παράγει την τελική ακολουθιακή αναπαράσταση του branch, διαστάσεων 256.

Σε σχέση με παλαιότερες, βαρύτερες σχεδιάσεις, ο global branch υιοθετεί μια πιο ελαφριά thin-tower λογική. Τα semantic και categorical depth streams δεν συγχωνεύονται πρόωρα μέσω ενός μεγάλου κοινού Conv3D block, αλλά επεξεργάζονται από ξεχωριστά towers και προβάλλονται ανεξάρτητα πριν από τη σύντηξή τους. Με αυτόν τον τρόπο μειώνεται το παραμετρικό και υπολογιστικό κόστος, ενώ διατηρείται διακριτή αναπαράσταση της σημασιολογικής και της γεωμετρικής πληροφορίας. Σημειώνεται ότι ο global branch παράγει ένα συμπυκνωμένο διάνυσμα 256 διαστάσεων ανά frame, και όχι ακολουθία χωρικών tokens.

Ο σχεδιασμός αυτός διατηρεί τη χωρική δομή της σκηνής. Σε αντίθεση με ένα απλό flattened vector υπολογισμένο από την αρχή, τα semantic και depth maps επιτρέπουν στο μοντέλο να μάθει χωροχρονικά μοτίβα, όπως η σχετική θέση πεζού-οχήματος, η ύπαρξη δρόμου ή πεζοδρομίου στην κατεύθυνση κίνησης και η μεταβολή της εγγύτητας road users μέσα στο observation window.

3.3.5 Attention-based fusion

Μετά την εξαγωγή των branch-level ακολουθιών, εφαρμόζονται attention modules για τη συμπύκνωση και σύντηξη των αναπαραστάσεων. Η αρχιτεκτονική χρησιμοποιεί attention στον kinematic branch, στον local branch και στη σύντηξη visual/global πληροφορίας. Στη συνέχεια, το visual embedding συνδυάζεται με το kinematic embedding μέσω final attention και οδηγείται σε πλήρως συνδεδεμένο output layer. Το forward pass του μοντέλου δείχνει ρητά αυτή τη ροή: πρώτα υπολογίζονται z_{kin} , z_{local} και h_{global} , έπειτα γίνεται visual fusion, και στο τέλος final attention μεταξύ visual και kinematic representations.

Ο μηχανισμός attention που χρησιμοποιείται σε όλα τα στάδια είναι κοινός και ακολουθεί μια query-based temporal διατύπωση. Δοθείσας μιας ακολουθίας κρυφών καταστάσεων $H = \{h_1, \dots, h_T\}$ με $h_t \in \mathbb{R}^d$, ορίζεται αρχικά ένα διάνυσμα αναφοράς (query) q , το οποίο είτε είναι η τελευταία κρυφή κατάσταση $q = h_T$, είτε ο χρονικός μέσος όρος $q = (1/T) \cdot \sum_t h_t$, ανάλογα με το στάδιο. Κάθε κρυφή κατάσταση προβάλλεται μέσω ενός learnable πίνακα W_p και συγκρίνεται με το query μέσω εσωτερικού γινομένου, παράγοντας ένα score ανά χρονικό βήμα:

$$e_t = (W_p \cdot h_t)^T \cdot q$$

Τα scores κανονικοποιούνται με softmax ώστε να προκύψουν τα βάρη προσοχής:

$$\alpha_t = \exp(e_t) / \sum_{k=1}^T \exp(e_k)$$

Το context vector υπολογίζεται ως το σταθμισμένο άθροισμα των κρυφών καταστάσεων:

$$c = \sum_{t=1}^T \alpha_t \cdot h_t$$

Τέλος, το context vector συνενώνεται με το query και προβάλλεται σε μη γραμμική αναπαράσταση εξόδου:

$$z = \tanh(W_c \cdot [c; q])$$

όπου $[\cdot; \cdot]$ συμβολίζει concatenation και W_c είναι learnable πίνακας προβολής. Η ίδια διατύπωση εφαρμόζεται στον kinematic branch, στον local branch, στη σύντηξη visual/global, καθώς και στο τελικό modality attention, με τη διαφορά ότι στο τελικό στάδιο η «ακολουθία» αποτελείται από δύο μόνο διανύσματα (z_{visual} , z_{kin}) και χρησιμοποιείται mean query.

Ο τελικός classifier παράγει ένα logit, το οποίο μετατρέπεται σε πιθανότητα crossing μέσω sigmoid:

$$\hat{y} = \sigma(l)$$

όπου l είναι το output logit του fully connected layer.

Η χρήση attention έχει διπλό ρόλο. Πρώτον, επιτρέπει στο μοντέλο να σταθμίσει χρονικά διαφορετικά frames, καθώς δεν έχουν όλα την ίδια σημασία. Δεύτερον, επιτρέπει προσαρμοστική στάθμιση μεταξύ visual και kinematic πληροφορίας. Αυτό είναι σημαντικό επειδή η αξιοπιστία κάθε modality διαφέρει ανάλογα με το σενάριο. Για παράδειγμα, το

pose μπορεί να είναι αναξιόπιστο σε occlusion, ενώ το global context μπορεί να είναι ιδιαίτερα χρήσιμο σε αμφίσημες σκηνές με διάβαση ή οχήματα.

Παρατηρείται εμπειρικά ότι το local visual embedding, αφού περάσει από το attention του local branch, συνεισφέρει σημαντικά κατά τη σύντηξή του με το global context. Μια πιθανή ερμηνεία είναι ότι το local attention λειτουργεί ως μηχανισμός εστίασης στον target πεζό, παρέχοντας στο global representation ένα pedestrian-centric σημείο αναφοράς. Το αρχικό PIP-Net δεν εξηγεί ρητά τον μηχανισμό αυτής της αλληλεπίδρασης.

3.3.6 Auxiliary heads και branch-level ανάλυση

Εκτός από την κύρια έξοδο, η αρχιτεκτονική περιλαμβάνει auxiliary heads για τους επιμέρους branches. Συγκεκριμένα, υπάρχουν auxiliary classifiers για kinematic, local και global representations. Τα auxiliary heads χρησιμοποιούνται μόνο κατά την εκπαίδευση και την ανάλυση· δεν συμμετέχουν στην τελική inference απόφαση. Κάθε auxiliary head παράγει ένα branch-specific logit, το οποίο συγκρίνεται με το ίδιο crossing/non-crossing label μέσω BCE loss. Οι auxiliary losses προστίθενται στο κύριο fused loss με βάρος λ_{aux} , ενισχύοντας την εκμάθηση χρήσιμων branch-level αναπαραστάσεων. Η τελική πρόβλεψη εξακολουθεί να προκύπτει αποκλειστικά από το fused representation.

3.4 Πειραματικές Transformer-based παραλλαγές

Η ενότητα αυτή περιγράφει τις Transformer-based αρχιτεκτονικές που εξετάστηκαν για την ελάφρυνση και ανασχεδίαση της πολυτροπικής αρχιτεκτονικής. Τα αριθμητικά αποτελέσματα και οι συγκρίσεις παρουσιάζονται ξεχωριστά στο Κεφάλαιο 4. Στόχος των πειραμάτων ήταν να διερευνηθεί αν μηχανισμοί self-attention μπορούν να αξιοποιήσουν αποδοτικότερα τη χωρική και πολυτροπική πληροφορία, χωρίς να χαθεί η ισχυρή κινηματική πληροφορία που παρέχεται από τα bounding boxes, τα pose keypoints και την ego-speed.

3.4.1 Spatial-Patch Transformer ως αντικατάσταση του Conv3D global branch

Η πρώτη κατεύθυνση αφορούσε την αντικατάσταση του Conv3D global context branch με έναν Spatial-Patch Transformer. Σε αυτή την παραλλαγή, η σκηνή αναπαρίσταται μέσω semantic segmentation και categorical depth, τα οποία χωρίζονται σε χωρικά patches. Κάθε patch μετατρέπεται σε token και ο Transformer μαθαίνει σχέσεις μεταξύ διαφορετικών περιοχών της σκηνής μέσω self-attention.


Η βασική υπόθεση ήταν ότι ο μηχανισμός attention θα μπορούσε να εστιάσει επιλεκτικά σε περιοχές που σχετίζονται με την πρόθεση διάσχισης, όπως ο δρόμος, το πεζοδρόμιο, οχήματα ή traffic controls, με μικρότερο αριθμό παραμέτρων σε σχέση με έναν βαρύτερο Conv3D tower. Εξετάστηκε επίσης μια factorized space-time παραλλαγή, όπου η χωρική μοντελοποίηση πραγματοποιείται ανά frame και η χρονική μοντελοποίηση αναλαμβάνεται από temporal module. Και στις δύο περιπτώσεις, όμως, ο Transformer λειτουργούσε ως ανεξάρτητος global branch, του οποίου η έξοδος εισαγόταν στη διαδικασία late fusion.

3.4.2 Transformer-only κινηματικός encoder

Παράλληλα εξετάστηκε η ιδέα ενός Transformer που θα δεχόταν απευθείας τα κινηματικά χαρακτηριστικά (bounding boxes, pose, ego-speed) , αντικαθιστώντας τον GRU κινηματικό κλάδο. Η κατεύθυνση αυτή δεν υιοθετήθηκε, διότι ο GRU κινηματικός κλάδος είναι ήδη πολύ ισχυρός, κατάλληλο για τη μικρού μήκους, πυκνή χρονική ακολουθία του παρατηρησιακού παραθύρου, ενώ ένας Transformer-only encoder με περιορισμένα δεδομένα δεν ανέδειξε αντίστοιχη ικανότητα κωδικοποίησης της κινηματικής δυναμικής. Με βάση αυτό, η τελική σχεδιαστική απόφαση ήταν να διατηρηθεί ο GRU κινηματικός κλάδος αυτούσιος ως κεντρικός decision backbone, και ο Transformer να χρησιμοποιηθεί ως μηχανισμός contextual modulation γύρω από αυτόν.

3.4.3 KinFormer-GRU: kinematic anchor με gated contextual tokens

Η προτεινόμενη KinFormer-GRU παραλλαγή βασίζεται στην ιδέα ότι ο κινηματικός κλάδος δεν πρέπει να αντικατασταθεί, αλλά να διατηρηθεί ως κεντρικός πυρήνας της απόφασης. Τα bounding boxes, τα pose keypoints και η ego-speed περνούν από τον GRU-based κινηματικό κλάδο, ο οποίος παράγει μια κινηματική αναπαράσταση ανά frame. Η αναπαράσταση αυτή προβάλλεται σε ένα kinematic anchor token διάστασης 128, το οποίο αποτελεί το βασικό token από το οποίο θα προκύψει τελικά η πρόβλεψη.



Σχήμα 3.8: Αρχιτεκτονικό διάγραμμα KinFormer-GRU

Τα υπόλοιπα διαθέσιμα modalities δεν παράγουν ανεξάρτητες αποφάσεις. Αντίθετα, μετατρέπονται σε contextual tokens και εισάγονται στον Transformer μέσω learnable gates. Συγκεκριμένα, το categorical depth και το segmentation μετατρέπονται σε 16 patch tokens το καθένα, μέσω ελαφρών Conv3D + MaxPool3d stems και χωρικού πλέγματος 4x4. Το optical flow και το local visual context μετατρέπονται σε ένα διανυσματικό token το καθένα. Κάθε contextual modality πολλαπλασιάζεται με το αντίστοιχο sigmoid gate, ώστε το μοντέλο να ελέγχει πόσο έντονα θα χρησιμοποιηθεί αυτή η πληροφορία.

Ο per-frame Transformer encoder εφαρμόζεται ανεξάρτητα σε κάθε frame. Για κάθε χρονική στιγμή, ο Transformer δέχεται το kinematic anchor token μαζί με τα contextual

tokens του ίδιου frame και επιτρέπει την αλληλεπίδρασή τους μέσω self-attention. Στην έξοδο, όμως, διαβάζεται μόνο η ενημερωμένη θέση του kinematic anchor token. Τα υπόλοιπα contextual tokens δεν περνούν απευθείας στον classifier.

Η ιδιότητα αυτή είναι σημαντική, επειδή αποτρέπει by construction την ανεξάρτητη late-fusion ψήφο των scene modalities. Τα contextual χαρακτηριστικά μπορούν να διαμορφώσουν την κινηματική αναπαράσταση μέσω attention, αλλά δεν μπορούν να υπερισχύσουν αυτόνομα στην τελική απόφαση. Έτσι, ο Transformer λειτουργεί ως μηχανισμός ελεγχόμενης ενίσχυσης του κινηματικού σήματος και όχι ως ανεξάρτητος branch που ανταγωνίζεται τον κινηματικό κλάδο.

3.4.4 Διατήρηση χωρικής πληροφορίας μέσω patch tokens

Η χωρική πληροφορία του segmentation και του depth δεν συμπιέζεται σε ένα ενιαίο διάνυσμα. Αντίθετα, κάθε modality διατηρείται ως πλέγμα 4×4 , δηλαδή ως 16 patch tokens ανά frame. Κάθε patch αντιστοιχεί σε συγκεκριμένη περιοχή της εικόνας, όπως αριστερά, δεξιά, πάνω ή κάτω.

Για να γνωρίζει ο Transformer τη θέση κάθε patch, προστίθεται learnable positional embedding. Έτσι, κάθε token περιγράφει όχι μόνο το περιεχόμενο μιας περιοχής, αλλά και τη θέση της στο frame. Η σύνδεση με το bounding box του πεζού δεν γίνεται με hard-coded ROI alignment. Το bounding box εισάγεται στον κινηματικό κλάδο, άρα το anchor περιέχει ήδη πληροφορία θέσης και τροχιάς του πεζού. Μέσω attention, το anchor μπορεί να συσχετιστεί με τα σχετικά scene patches.

Η ανάλυση 4×4 είναι αδρή, αλλά επαρκής για το πρόβλημα, καθώς συχνά αρκεί να γνωρίζουμε τη γενική χωρική ζώνη της πληροφορίας, όπως δρόμος μπροστά, όχημα δεξιά ή πεζοδρόμιο αριστερά.

3.4.5 Semantic mask channels και modality gates

Για το segmentation εξετάστηκε, εκτός από το πλήρες 20-class semantic embedding, και μια πιο στοχευμένη traffic-aware αναπαράσταση. Οι semantic labels ομαδοποιούνται σε έξι binary mask channels: pedestrians, vehicles, traffic controls, road, sidewalk και pole. Κατηγορίες χαμηλότερης συνάφειας, όπως sky, buildings και vegetation, αντιμετωπίζονται ως background.

Κάθε contextual modality ελέγχεται από ένα learnable scalar gate. Η τιμή του gate περνά από sigmoid και πολλαπλασιάζει τα αντίστοιχα tokens πριν μπουν στον Transformer. Τα gates εφαρμόζονται μόνο στα contextual tokens και όχι στο kinematic anchor, καθώς το anchor παραμένει το βασικό σήμα της απόφασης.

Χρησιμοποιήθηκαν δύο αρχικοποιήσεις: conservative gates με $\text{gate_init} = -2.0$, δηλαδή αρχική συνεισφορά περίπου 0.12, και open gates με $\text{gate_init} = 0.0$, δηλαδή αρχική συνεισφορά περίπου 0.50. Οι δύο ρυθμίσεις έχουν τον ίδιο αριθμό παραμέτρων και διαφέρουν μόνο στο αρχικό βάρος με το οποίο εισάγεται η contextual πληροφορία.

3.4.6 Στρατηγική εκπαίδευσης των παραλλαγών

Οι Transformer-based παραλλαγές εκπαιδεύτηκαν με ορισμένες προσαρμοσμένες πρακτικές σε σχέση με το κύριο PIPN: focal loss, branch-specific learning rates, αυξημένο

weight decay στις Transformer παραμέτρους και gradient clipping, για τη σταθεροποίηση της εκπαίδευσης σε σχετικά περιορισμένο dataset. Σημειώνεται ρητά ότι οι διαφορές αυτές στη συνάρτηση κόστους και στο training recipe σημαίνουν πως οι συγκρίσεις μεταξύ των παραλλαγών και του PIPN δεν είναι πλήρως ελεγχόμενες ως προς την εκπαίδευση· επομένως ερμηνεύονται ως ενδείξεις του συνολικού performance-efficiency trade-off και όχι ως απομονωμένη επίδραση της αρχιτεκτονικής.

3.5 Στρατηγική Εκπαίδευσης

3.5.1 Loss function

Η κύρια αντικειμενική συνάρτηση είναι binary cross-entropy with logits. Για την αντιμετώπιση ανισορροπίας μεταξύ crossing και non-crossing samples χρησιμοποιείται positive class weighting. Το βάρος της θετικής κλάσης υπολογίζεται από το training set ως λόγος αρνητικών προς θετικά δείγματα. Στην υλοποίηση, αυτό υπολογίζεται από τα NPZ αρχεία του train split μέσω της συνάρτησης `compute_pos_weight_from_npz`.

Η συνολική loss περιλαμβάνει τρία μέρη:

$$L = L_{main} + \lambda_{aux}L_{aux} + \lambda_{ent}L_{entropy}$$

όπου L_{main} είναι η κύρια BCE loss, L_{aux} είναι το άθροισμα των auxiliary branch losses και $L_{entropy}$ είναι regularization term πάνω στα modality weights. Η χρήση auxiliary losses βοηθά τους επιμέρους branches να μάθουν χρήσιμες αναπαραστάσεις, ενώ το entropy term λειτουργεί ως regularization στη διαδικασία fusion. Σημειώνεται ότι η focal loss δεν χρησιμοποιείται στο κύριο PIPN, αλλά μόνο στις πειραματικές Transformer-based παραλλαγές (Ενότητα 3.4).

3.5.2 Training setups

Η εργασία χρησιμοποιεί δύο βασικές στρατηγικές εκπαίδευσης.

Η πρώτη είναι PIE-only training. Σε αυτή τη ρύθμιση, το μοντέλο εκπαιδεύεται αποκλειστικά στο training split του PIE, επιλέγεται με βάση το validation AUC και αξιολογείται μία φορά στο test split. Αυτή η ρύθμιση λειτουργεί ως κύριο benchmark, επειδή το PIE είναι το dataset με την πιο άμεση σχέση με το crossing intention estimation και διαθέτει ego-vehicle speed και human intention reference data.

Η δεύτερη είναι JAAD pretraining → PIE fine-tuning. Σε αυτή τη ρύθμιση, το μοντέλο αρχικά εκπαιδεύεται στο JAAD ώστε να μάθει γενικές αναπαραστάσεις pedestrian behavior και στη συνέχεια γίνεται fine-tuning στο PIE. Το training script περιλαμβάνει ρητά Stage 1 για JAAD, Stage 2 για PIE transfer και Stage 3 για PIE-only baseline.

Η στρατηγική αυτή πρέπει να παρουσιαστεί προσεκτικά. Το JAAD δεν έχει ακριβώς το ίδιο annotation setup με το PIE και δεν διαθέτει ισοδύναμη ego-speed πληροφορία. Επομένως, το pretraining στο JAAD δεν πρέπει να παρουσιαστεί ως εκπαίδευση σε πλήρως ισοδύναμο intention dataset, αλλά ως warmup σε σχετικό pedestrian behavior domain. Η τελική αξιολόγηση και τα κύρια συμπεράσματα πρέπει να βασίζονται στο PIE.

Σε ό,τι αφορά το συγκριτικό πρωτόκολλο που χρησιμοποιείται ως βασικό σημείο

αναφοράς, η βιβλιογραφία αναφέρει αποτελέσματα σε κοντινούς χρονικούς ορίζοντες, όπως $TTE \approx 0.5$ s. Ένας τέτοιος ορίζοντας παρέχει περιορισμένο χρόνο αντίδρασης για έγκαιρη πρόβλεψη, ιδίως σε σενάρια αυτόνομης οδήγησης. Για τον λόγο αυτό, η παρούσα εργασία υιοθετεί ευρύτερο εύρος εκπαίδευσης $TTE \in [1.0, 2.0]$ s με overlap 0.6. Η διαφορά αυτή στο πρωτόκολλο εκπαίδευσης και αξιολόγησης ενδέχεται να εξηγεί μέρος των διαφορών στα αποτελέσματα σε σχέση με αναφερόμενες τιμές της βιβλιογραφίας, ζήτημα που συζητείται περαιτέρω στο Κεφάλαιο 4.

3.5.3 Model selection και αποφυγή test leakage

Η επιλογή του καλύτερου checkpoint γίνεται με βάση το validation AUC και όχι το test AUC. Αυτό είναι κρίσιμο για την αποφυγή test-set leakage. Το test split χρησιμοποιείται μόνο μετά την ολοκλήρωση της εκπαίδευσης, για την τελική αναφορά της απόδοσης του επιλεγμένου μοντέλου.

Η πρακτική αυτή είναι ιδιαίτερα σημαντική επειδή η εργασία συγκρίνει διαφορετικές αρχιτεκτονικές και training strategies. Αν η επιλογή του καλύτερου μοντέλου γινόταν με βάση το test set, τότε το test set θα χρησιμοποιούνταν έμμεσα ως validation set και τα αποτελέσματα θα ήταν αισιόδοξα. Συνεπώς, κάθε πειραματική σύγκριση πρέπει να ακολουθεί τον κανόνα:

Model selection: validation AUC

Final reporting: test AUC, F1, Accuracy, Precision, Recall

3.5.4 Optimizer και πρακτικές σταθερότητας

Η κύρια Conv3D-based υλοποίηση του PIPN εκπαιδεύεται με τον optimizer AdamW. Οι παράμετροι χωρίζονται σε ομάδες με διαφοροποιημένο weight decay: μηδενικό για τα βασικά recurrent/kinematic τμήματα, visual_l2 για τους local και global visual branches, και last_fc_l2 για το τελικό fully connected layer. Η επιλογή AdamW χρησιμοποιείται σε όλα τα κύρια πειράματα της εργασίας. Η προσαρμογή του learning rate γίνεται μέσω ReduceLROnPlateau scheduler (mode max, factor 0.5, patience 3, min_lr $1e-7$) με βάση το validation AUC, εκτός αν ενεργοποιηθεί fixed learning rate. Το training script περιλαμβάνει επίσης mixed precision μέσω AMP, early stopping και logging σε CSV.

Κατά την αξιολόγηση χρησιμοποιούνται AUC, Accuracy, F1, Precision και Recall. Το AUC αποτελεί την κύρια metric, επειδή είναι ανεξάρτητο από συγκεκριμένο classification threshold και είναι πιο κατάλληλο για δυαδικά προβλήματα με πιθανή ανισορροπία κλάσεων. Το F1 και το Precision/Recall συμπληρώνουν την εικόνα, καθώς δείχνουν πώς συμπεριφέρεται το μοντέλο όταν η πιθανότητα μετατρέπεται σε δυαδική απόφαση.

3.6 Πειραματικές Παραλλαγές και Ablations

Η μεθοδολογία υποστηρίζει διάφορα ablation experiments, τα οποία παρουσιάζονται αναλυτικά στο Κεφάλαιο 4. Τα βασικά ablations είναι τα εξής:

Σύγκριση	Μοντέλο
Χωρίς kinematic branch	PIPN
Χωρίς local visual branch	PIPN
Χωρίς global context branch	PIPN
Conv3D global vs Transformer	PIPN vs Spatial-Patch Transformer
Conv3D global vs Factorized Transformer	PIPN vs Παραλλαγή B
KinFormer-GRU modality ablation	anchor-only / depth-only / seg masks / seg+depth / full
KinFormer-GRU semantic representation	20-class embedding vs traffic-aware masks
KinFormer-GRU gate initialization	conservative (-2.0) vs open (0.0)

Πίνακας 3.2: Συνολικά ablations και συγκρίσεις.

Ιδιαίτερη προσοχή δίνεται στην ερμηνεία των ablations. Η πτώση απόδοσης μετά την αφαίρεση ενός branch δεν σημαίνει απαραίτητα ότι το branch είναι πάντα ανεξάρτητα ισχυρό. Σημαίνει ότι, μέσα στο συγκεκριμένο fused σύστημα, η πληροφορία του branch συνεισφέρει στη συνολική απόδοση. Για τον λόγο αυτό, τα auxiliary branch AUCs και τα ablation results πρέπει να διαβάζονται συμπληρωματικά.

3.7 Σχεδιαστικές αποφάσεις και αποκλίσεις από το PIP-Net

Κατά την ανάπτυξη της παρούσας μεθοδολογίας, η αρχιτεκτονική PIP-Net χρησιμοποιήθηκε ως βασικό σημείο αναφοράς. Ωστόσο, η ακριβής αναπαραγωγή της δεν ήταν άμεσα εφικτή, καθώς ο πλήρης κώδικας της αρχικής εργασίας και ορισμένα από τα preprocessing components της δεν ήταν διαθέσιμα στο πλαίσιο της παρούσας υλοποίησης. Για τον λόγο αυτό, το pipeline ανακατασκευάστηκε εξ αρχής με βάση την περιγραφή της δημοσίευσης, ενώ αρκετές σχεδιαστικές λεπτομέρειες που δεν προσδιορίζονται ρητά καθορίστηκαν πειραματικά.

Ως προς το preprocessing, η παρούσα εργασία διατηρεί τη βασική ιδέα του categorical depth του PIP-Net, αλλά αναβαθμίζει επιμέρους perception components. Το FlowNet2 αντικαθίσταται από RAFT-large για το local optical flow, ενώ το Slot-VPS αντικαθίσταται από Mask2Former με Cityscapes panoptic προεκπαίδευση για την εξαγωγή semantic και instance masks. Η εκτίμηση βάθους εξακολουθεί να βασίζεται σε ManyDepth, αλλά η κατασκευή του categorical depth πραγματοποιείται πλέον με τις instance masks του Mask2Former. Παράλληλα, όπου ήταν διαθέσιμα, επιλέχθηκαν προεκπαιδευμένα βάρη σε driving-oriented datasets, καθώς η ποιότητα των frozen perception features επηρεάζει άμεσα την απόδοση των downstream branches.

Ένα δεύτερο ζήτημα αφορά τη διαμόρφωση του global context branch. Η δημοσίευση του PIP-Net περιγράφει τη χρήση Conv3D και spatial max-pooling για τα semantic και categorical depth maps, αλλά δεν προσδιορίζει πλήρως την ακριβή εξέλιξη των κανα-

λιών, τις ενδιάμεσες διαστάσεις και τις λεπτομέρειες υλοποίησης. Επιπλέον, από το αρχιτεκτονικό διάγραμμα προκύπτει ότι τα global maps τροφοδοτούνται στα Conv3D blocks σε υψηλή χωρική ανάλυση (512×512). Η εφαρμογή τρισδιάστατων συνελιζέων απευθείας σε τέτοιους χωροχρονικούς όγκους οδηγεί σε ιδιαίτερα υψηλές απαιτήσεις μνήμης, ειδικά στο πρώτο Conv3D layer. Για τον λόγο αυτό, η παρούσα εργασία εισάγει learned Conv2D downsampling πριν από τα Conv3D towers, μειώνοντας τη χωρική ανάλυση σε σταθερό target size και διατηρώντας ταυτόχρονα τη βασική χωρική δομή της σκηνής. Η ακριβής εξέλιξη των καναλιών στα Conv3D (semantic: $16 \rightarrow 16 \rightarrow 32 \rightarrow 64$, depth: $2 \rightarrow 16 \rightarrow 32 \rightarrow 64$) καθορίστηκε πειραματικά.

Επιπλέον, αναπτύχθηκε διορθωτικό βήμα ego-vehicle suppression (Ενότητα 3.2.3), ώστε η ορατή περιοχή του καπό να μην εισάγει εσφαλμένες τιμές categorical depth πρακτική απόκλιση που προέκυψε από εμπειρική παρατήρηση των segmentation outputs. Η κατασκευή των non-crossing δειγμάτων αξιοποίησε, όπου ήταν διαθέσιμα, τα human intention reference scores του PIE για την επιλογή δυσκολότερων αρνητικών παραδειγμάτων (Ενότητα 3.1.3). Τέλος, κατά τη δειγματοληψία με temporal stride παρατηρήθηκε ότι η σταθερή υποδειγματοληψία μπορούσε να παρακάμψει το ακριβές crossing event frame· το ζήτημα αντιμετωπίστηκε με προσεκτικό χειρισμό του stride ώστε το reference event να παραμένει ευθυγραμμισμένο. Για λόγους αποδοτικότητας, τα απαραίτητα frames διαβάζονται απευθείας από τα βίντεο αντί να εξάγονται όλα εκ των προτέρων. Συνολικά, οι αποφάσεις αυτές καθιστούν το pipeline αναπαραγωγίσιμο και τεκμηριώνουν τις αποκλίσεις από το PIP-Net ως συνειδητές επιλογές.

3.8 Σύνοψη Κεφαλαίου

Το κεφάλαιο παρουσίασε τη μεθοδολογία σε τέσσερα επίπεδα. Αρχικά, ορίστηκε το πρόβλημα ως δυαδική crossing/non-crossing πρόβλεψη σε χρονικό παράθυρο πριν από το συμβάν. Έπειτα παρουσιάστηκε το offline preprocessing pipeline, που παράγει χρονικά ευθυγραμμισμένα πολυτροπικά χαρακτηριστικά μέσω RAFT, Mask2Former και ManyDepth. Στη συνέχεια αναλύθηκε η αρχιτεκτονική PIPN, η οποία συνδυάζει kinematic, local visual και global context branches μέσω attention-based late fusion. Τέλος, περιγράφηκαν η στρατηγική εκπαίδευσης, οι loss functions και οι πειραματικές παραλλαγές.

Πέρα από το κύριο PIPN, η εργασία διερευνά δύο αρχιτεκτονικές κατευθύνσεις για τον global context. Η πρώτη εξετάζει εμπειρικά αν η self-attention μοντελοποίηση χωρικών σχέσεων (Spatial-Patch και factorized Transformer παραλλαγές) μπορεί να αντικαταστήσει τον Conv3D branch. Η δεύτερη, που οδηγεί στην προτεινόμενη lightweight αρχιτεκτονική KinFormer-GRU, αλλάζει τη στρατηγική σύντηξης: διατηρεί τον GRU κινηματικό κλάδο ως κεντρικό anchor και εισάγει τα scene modalities ως gated contextual tokens, χωρίς ανεξάρτητη late-fusion ψήφο.

Για την αποφυγή ασυνέπειας μεταξύ μεθοδολογικής περιγραφής και υλοποίησης, η εργασία διακρίνει ρητά την κύρια Conv3D-based αρχιτεκτονική PIPN από τις Transformer-based παραλλαγές. Όλα τα κύρια αποτελέσματα αναφέρονται στο PIPN, εκτός αν δηλώνεται διαφορετικά, ενώ η ενδεχόμενη υιοθέτηση μιας παραλλαγής ως τελικού lightweight μοντέλου εξαρτάται από τη σύγκριση του Κεφαλαίου 4.

Κεφάλαιο 4 Πειράματα και Αποτελέσματα

Στο παρόν κεφάλαιο παρουσιάζονται τα πειραματικά αποτελέσματα της προτεινόμενης αρχιτεκτονικής PIPN στο πρόβλημα της πρόβλεψης πρόθεσης διάσχισης πεζών. Αρχικά περιγράφεται το πειραματικό πλαίσιο (Ενότητα 4.1), στη συνέχεια αξιολογείται η συνολική απόδοση του μοντέλου σε πολλαπλούς χρονικούς ορίζοντες και συγκρίνεται με τη βιβλιογραφία (Ενότητα 4.2). Ακολουθεί ενδελεχής ανάλυση της σταθερότητας του μοντέλου τόσο σε επίπεδο τυχαίας αρχικοποίησης όσο και χρονικής συνοχής (Ενότητα 4.3), και διεξάγεται συστηματική μελέτη αφαίρεσης και συνεισφοράς των επιμέρους κλάδων της αρχιτεκτονικής (Ενότητα 4.4). Τέλος, διερευνάται η ικανότητα γενίκευσης του μοντέλου μέσω cross-dataset πειραμάτων (Ενότητα 4.5) και συνοψίζονται τα κύρια ευρήματα (Ενότητα 4.6).

4.1 Πειραματική Ρύθμιση

4.1.1 Υποδομή και Πλαίσιο Εκπαίδευσης

Όλα τα πειράματα διεξήχθησαν σε υπολογιστική υποδομή με κάρτα γραφικών NVIDIA Blackwell 96 GB VRAM, η οποία επέτρεψε την εκπαίδευση της προτεινόμενης αρχιτεκτονικής με batch size 64. Η εκπαίδευση πραγματοποιήθηκε με χρήση Automatic Mixed Precision (AMP) σε FP16/FP32 mixed mode, αξιοποιώντας τα tensor cores της αρχιτεκτονικής Blackwell για επιτάχυνση των πράξεων. Το μοντέλο υλοποιήθηκε σε PyTorch 2.6 με optimizer AdamW και scheduler ReduceLROnPlateau.

Η ρύθμιση των υπερπαραμέτρων (dropout rates, learning rate, weight decay, auxiliary loss weights) πραγματοποιήθηκε σε ξεχωριστή προκαταρκτική φάση, κατά την οποία αξιολογήθηκαν περισσότερες από 15 διαφορετικές διαμορφώσεις με κριτήριο επιλογής το μέγιστο validation AUC. Η αναζήτηση επαναλήφθηκε ανεξάρτητα για κάθε μία από τις τρεις στρατηγικές εκπαίδευσης (PIE-only, Transfer, Combined), καθώς οι διαφορετικές κατανομές δεδομένων απαιτούσαν διακριτή ρύθμιση.

Η συνολική παραμετρική σύνθεση του εκπαιδευσιμου τμήματος του μοντέλου ανέρχεται σε 4,417,834 παραμέτρους. Ακολουθώντας την καθιερωμένη πρακτική της βιβλιογραφίας [PIP-Net- α , CIPF, MCIP], ο αριθμός αυτός αναφέρεται αποκλειστικά στο εκπαιδεύσιμο fusion network: Conv3D towers, recurrent units (GRU), attention modules και πλήρως συνδεδεμένα στρώματα. Δεν περιλαμβάνει τα προεκπαιδευμένα (frozen) feature extraction networks που τρέχουν σε offline φάση προεπεξεργασίας για την παραγωγή των εισόδων του δικτύου: τον CNN backbone για τα τοπικά οπτικά χαρακτηριστικά, τον optical flow estimator, τον pose estimator, το semantic segmentation network και το depth estimation network (αναλυτική περιγραφή στην Ενότητα 3.1).

Υπό αυτή τη μεθοδολογική σύμβαση, το προτεινόμενο μοντέλο διαθέτει μικρότερο εκπαιδεύσιμο μέγεθος σε σχέση με αντιπροσωπευτικές αρχιτεκτονικές της βιβλιογραφίας, όπως το PIP-Net- α , το οποίο αναφέρει περίπου 5.5M εκπαιδευσιμες παραμέτρους. Η προτεινόμενη αρχιτεκτονική, με 4.42M παραμέτρους, αντιστοιχεί σε μείωση περίπου 20%, διατηρώντας παράλληλα πολυτροπική δομή και temporal fusion.

4.1.2 Πειραματική Διαμόρφωση Datasets

Η κύρια εκπαίδευση και αξιολόγηση πραγματοποιήθηκε στο PIE dataset, ενώ για τη μελέτη cross-dataset γενίκευσης αξιοποιήθηκε επιπρόσθετα το JAAD dataset.

Η εκπαίδευση πραγματοποιήθηκε με ακολουθίες παρατήρησης μήκους 10 καρέ και χρονικό ορίζοντα πρόβλεψης $TTE \in [1.0, 2.0]$ s. Για την αξιοποίηση των διαθέσιμων δειγμάτων εφαρμόστηκε παράθυρο ολίσθησης (sliding window) μεταξύ διαδοχικών παραθύρων, με διαφοροποιημένο overlap ανά dataset: overlap 0.6 για το PIE (μεγαλύτερο dataset, μικρότερη ανάγκη πύκνωσης) και overlap 0.9 για το JAAD (μικρότερο dataset, υψηλότερη ανάγκη πύκνωσης δειγμάτων για επαρκή εκπαίδευση του δικτύου των 4.42M παραμέτρων). Ο διαχωρισμός των δεδομένων ακολουθεί τα επίσημα splits του PIE σε επίπεδο video session (set01–04 για training, set05 για validation, set06 για test), ώστε να αποφεύγεται η διαρροή πληροφορίας μεταξύ συνόλων. Επιπλέον, εντός κάθε split, sliding windows που προέρχονται από την ίδια ακολουθία (track) διατηρούνται μαζί, αποτρέποντας temporal leakage μέσω overlap. Το διαμορφωμένο σύνολο δεδομένων αποτελείται από:

PIE: 2,469 training / 662 validation / 1,846 test sequences, με κατανομή crossing / non-crossing 36% / 64% αντίστοιχα.

JAAD: 1,357 training / 230 validation / 1,282 test sequences.

Η μη ισορροπία κλάσεων αντιμετωπίστηκε κατά την εκπαίδευση μέσω weighted Binary Cross-Entropy loss, με pos_weight υπολογιζόμενο αυτόματα από την κατανομή των ετικετών του εκάστοτε training set.

4.1.3 Μετρικές Αξιολόγησης

Η αξιολόγηση του προτεινόμενου μοντέλου πραγματοποιείται με βάση μετρικές που χρησιμοποιούνται ευρέως στη βιβλιογραφία πρόβλεψης πρόθεσης πεζών.

ROC-AUC (Area Under the Receiver Operating Characteristic Curve): Αξιολογεί τη διαχωριστική ικανότητα του μοντέλου ανεξάρτητα από την επιλογή συγκεκριμένου κατωφλίου απόφασης. Αποτελεί την κύρια μετρική σύγκρισης μεταξύ μοντέλων, καθώς αποτυπώνει την ικανότητα διάκρισης μεταξύ crossing και non-crossing περιπτώσεων σε όλο το εύρος πιθανών κατωφλίων. Για τον λόγο αυτό χρησιμοποιείται και ως βασικό κριτήριο επιλογής μοντέλου στο validation set.

Οι υπόλοιπες μετρικές υπολογίζονται με στατικό κατώφλι απόφασης, το οποίο επιλέγεται αποκλειστικά στο validation set και διατηρείται αμετάβλητο σε όλες τις test αξιολογήσεις. Στο δυαδικό πρόβλημα crossing/non-crossing, ως θετική κλάση θεωρείται η περίπτωση crossing. Οι ποσότητες TP, FP, TN και FN αντιστοιχούν σε true positives, false positives, true negatives και false negatives αντίστοιχα.

Οι ορισμοί τους είναι οι εξής:

$$Precision = \frac{TP}{TP + FP}$$

$$Recall = \frac{TP}{TP + FN}$$

$$F1 = 2 \cdot \frac{Precision \cdot Recall}{Precision + Recall}$$

$$Accuracy = \frac{TP + TN}{TP + TN + FP + FN}$$

Το **Precision** εκφράζει το ποσοστό των προβλέψεων που ταξινομήθηκαν ως crossing και αντιστοιχούν πράγματι σε crossing περιπτώσεις, ενώ το **Recall** εκφράζει το ποσοστό των πραγματικών crossing περιπτώσεων που εντοπίζονται σωστά από το μοντέλο. Το **F1-score** συνδυάζει Precision και Recall μέσω του αρμονικού μέσου και είναι χρήσιμο όταν απαιτείται ισορροπία μεταξύ false positives και false negatives.

Συγκεκριμένα, το στατικό κατώφλι $\tau = 0.7585$ προέκυψε ως το σημείο μέγιστου F1-score στο ETC ≈ 1 s υποσύνολο του PIE validation set του PIE-only baseline (seed 46), κατασκευασμένο σύμφωνα με το πρωτόκολλο φιλτραρίσματος που περιγράφεται στην Ενότητα 4.1.5. Το συγκεκριμένο χρονικό σημείο επιλέχθηκε ως αντιπροσωπευτικό του τυπικού ορίζοντα πρόβλεψης που χρησιμοποιείται στη βιβλιογραφία[8], [13], και χρησιμοποιείται χωρίς επαναρύθμιση σε όλες τις επακόλουθες αξιολογήσεις συμπεριλαμβανομένων των άλλων στρατηγικών εκπαίδευσης και των άλλων χρονικών οριζόντων. Η σχετικά υψηλή τιμή του κατωφλίου σε σχέση με το τυπικό $\tau = 0.5$ αποτελεί φυσική συνέπεια του weighted Binary Cross-Entropy loss ($\text{pos_weight} > 1$) που χρησιμοποιήθηκε κατά την εκπαίδευση: το μοντέλο εκπαιδεύεται με ενίσχυση της θετικής κλάσης, με αποτέλεσμα να παράγει πιθανότητες ωθημένες προς υψηλότερες τιμές. Το κατώφλι $\tau = 0.7585$ αντικατοπτρίζει αυτό το bias και επαναφέρει την ισορροπία μεταξύ Precision και Recall στο σημείο μέγιστου F1-score.

Τέλος, η Accuracy αναφέρεται κυρίως για λόγους συμβατότητας με προηγούμενες εργασίες. Σε μη ισορροπημένα datasets, η Accuracy μπορεί να είναι παραπλανητική, καθώς ένας ταξινομητής που προβλέπει πάντα την πλειοψηφική κλάση θα πετύχαινε ήδη Accuracy περίπου 64% στο PIE. Για τον λόγο αυτό, οι κύριες μετρικές σύγκρισης στην παρούσα εργασία είναι το ROC-AUC και το F1-score με στατικό κατώφλι επιλεγμένο στο validation set.

4.1.4 Στρατηγικές Εκπαίδευσης και Υπερπαράμετροι

Η χρήση του JAAD στις στρατηγικές εκπαίδευσης βασίστηκε σε συγκεκριμένη μεθοδολογική λογική. Παρότι το JAAD αποτελεί χρήσιμη πηγή οπτικής και χωρικής πληροφορίας για τη συμπεριφορά πεζών, δεν παρέχει ισοδύναμη πληροφορία ταχύτητας του ego-vehicle, η οποία είναι σημαντική για ένα πλήρες μοντέλο πρόβλεψης πρόθεσης διάσχισης. Η ταχύτητα του οχήματος επηρεάζει το διαθέσιμο χρονικό περιθώριο αντίδρασης, τη σχετική κίνηση πεζού οχήματος και το δυναμικό πλαίσιο της σκηνής. Για τον λόγο αυτό, το

JAAD χρησιμοποιήθηκε αρχικά για την εκμάθηση γενικών οπτικοχωρικών αναπαραστάσεων, ενώ το fine-tuning στο PIE επέτρεψε την προσαρμογή του μοντέλου σε ένα πλουσιότερο πολυτροπικό πλαίσιο, όπου η πληροφορία ταχύτητας μπορεί να αξιοποιηθεί πιο άμεσα.

Πέρα από την κλασική προσέγγιση transfer learning, διερευνήθηκε και η στρατηγική ενιαίας εκπαίδευσης μέσω ένωση των JAAD και PIE. Η επιλογή αυτή εξετάζει αν η ταυτόχρονη έκθεση του μοντέλου σε δύο διαφορετικές κατανομές δεδομένων μπορεί να ενισχύσει τη γενίκευση, αντί το JAAD να χρησιμοποιείται μόνο ως προκαταρκτικό στάδιο προεκπαίδευσης.

Για την εκπαίδευση της προτεινόμενης αρχιτεκτονικής διερευνήθηκαν τρεις διακριτές στρατηγικές, καθεμία με ξεχωριστά βελτιστοποιημένες υπερπαραμέτρους:

PIE-only baseline: Εκπαίδευση αποκλειστικά στο PIE training set σε ένα στάδιο. Αντιπροσωπεύει την βασική στρατηγική όταν ο πρωταρχικός στόχος είναι η μέγιστη δυνατή απόδοση στο PIE benchmark χωρίς αξιοποίηση εξωτερικών δεδομένων.

JAAD → PIE Transfer Learning: Εκπαίδευση σε δύο διαδοχικά στάδια. Στο πρώτο στάδιο πραγματοποιείται pretrain στο JAAD training set, και στο δεύτερο στάδιο τα προκύπτοντα βάρη αποτελούν σημείο αρχικοποίησης για fine-tuning στο PIE. Η στρατηγική αυτή αξιολογεί κατά πόσο η προεκπαίδευση στο JAAD βελτιώνει την αρχικοποίηση του μοντέλου πριν την τελική εκπαίδευση στο PIE.

Combined JAAD+PIE training: Εκπαίδευση σε ένα ενιαίο στάδιο όπου τα training samples των δύο datasets αναμειγνύονται. Η στρατηγική αυτή χρησιμοποιείται για να εξεταστεί αν η κοινή εκπαίδευση σε JAAD και PIE οδηγεί σε πιο γενικεύσιμες αναπαραστάσεις, μειώνοντας τον κίνδυνο catastrophic forgetting που μπορεί να εμφανιστεί στη διαδοχική εκπαίδευση.

Ο Πίνακας 4.1 συνοψίζει τις βελτιστοποιημένες υπερπαραμέτρους κάθε στρατηγικής. Σημειώνεται ότι, λόγω των διαφορετικών μεγεθών των δύο datasets, απαιτείται διακριτή ρύθμιση εκπαίδευσης. Ειδικότερα, το JAAD, λόγω του μικρότερου αριθμού διαθέσιμων training sequences, χρειάζεται πιο συντηρητική ρύθμιση εκπαίδευσης, με μικρότερο batch size, χαμηλότερο learning rate και αυξημένο dropout. Όλες οι τιμές προκύπτουν ως οι βέλτιστες της προκαταρκτικής φάσης αναζήτησης υπερπαραμέτρων.

Υπερπαράμετρος	PIE-only	Transfer (JAAD→PIE)	Combined (JAAD+PIE)
Διαμόρφωση δεδομένων			
Sequence length	10 frames	10 frames	10 frames
TTE range	[1.0, 2.0] s	[1.0, 2.0] s	[1.0, 2.0] s
Overlap (PIE)	0.6	0.6	0.6
Overlap (JAAD)	—	0.9	0.9
Optimizer & Scheduler			
Optimizer	AdamW	AdamW	AdamW
Scheduler	ReduceLROnPlateau	ReduceLROnPlateau	ReduceLROnPlateau
Scheduler factor / patience	0.5 / 3	0.5 / 3	0.5 / 3
Learning rate			
LR (Stage 1 — JAAD pretrain)	—	1.47×10^{-5}	—
LR (Stage 2 — PIE / Combined)	1.99×10^{-5}	2.08×10^{-5}	2.08×10^{-5}
Batch size & Διάρκεια			
Batch size (PIE)	64	64	64
Batch size (JAAD)	—	10	10
Max epochs (Stage 1)	—	40	—
Max epochs (Stage 2)	15	30	30
Early stopping patience	10	6	6
Dropout rates			
Dropout p (final)	0.2	0.2	0.2
Local visual branch dropout	0.1	0.4	0.4
Global context branch dropout	0.4	0.5	0.5
Weight decay (L2)			
last_fc_l2 (final FC layer)	7.11×10^{-3}	3.24×10^{-3}	3.24×10^{-3}
visual_l2 (visual branches)	4.0×10^{-3}	4.0×10^{-3}	4.0×10^{-3}
base_l2 (kinematic branch)	0.0	0.0	0.0
Loss weights			
aux_weight (auxiliary heads)	0.25	0.20	0.20
entropy_weight (attention)	0.03	0.08	0.08
Mixed precision (AMP)	Yes	Yes	Yes
Random seed (reported run)	46	42	42

Πίνακας 4.1: Υπερπαράμετροι εκπαίδευσης ανά στρατηγική

4.1.5 Πρωτόκολλο Multi-horizon Evaluation

Πέρα από την τυπική αξιολόγηση στο εύρος εκπαίδευσης $TTE \in [1.0, 2.0]$ s, σχεδιάστηκε ένα πρωτόκολλο αξιολόγησης σε πολλαπλούς χρονικούς ορίζοντες, με στόχο να εξεταστεί η ικανότητα του μοντέλου να διατηρεί σταθερή απόδοση όταν η πρόβλεψη ζητείται σε διαφορετικά χρονικά σημεία πριν από τη διάσχιση. Η αξιολόγηση αυτή είναι ιδιαίτερα σημαντική στο πρόβλημα πρόβλεψης πρόθεσης πεζού, καθώς η δυσκολία του προβλήματος μεταβάλλεται ανάλογα με το πόσο νωρίς ή αργά πριν από τη διάσχιση λαμβάνεται η απόφαση.

Συγκεκριμένα, κατασκευάστηκαν πέντε ξεχωριστά test sets από το PIE official test split, με φιλτράρισμα των διαθέσιμων sequences, καθένα από τα οποία περιλαμβάνει δείγματα με TTE κοντά σε έναν συγκεκριμένο χρονικό ορίζοντα. Κάθε test set δημιουργήθηκε με στενό χρονικό παράθυρο γύρω από τον αντίστοιχο στόχο, ώστε η αξιολόγηση να αποτυπώνει όσο το δυνατόν καθαρότερα την απόδοση του μοντέλου σε συγκεκριμένο χρόνο πριν από την πιθανή διάσχιση.

Test set	TTE range (s)	Πλήθος δειγμάτων
$TTE \approx 0.5$ s	[0.49, 0.55]	684
$TTE \approx 1.0$ s	[0.99, 1.05]	664
$TTE \approx 2.0$ s	[1.99, 2.05]	603
$TTE \approx 3.0$ s	[2.99, 3.05]	539
$TTE \approx 4.0$ s	[3.99, 4.05]	487

Πίνακας 4.2: Test sets πολλαπλών χρονικών οριζόντων

Το μοντέλο εκπαιδεύτηκε αποκλειστικά σε δείγματα με $TTE \in [1.0, 2.0]$ s. Επομένως, τα test sets με $TTE \approx 1.0$ s και $TTE \approx 2.0$ s λειτουργούν ως αξιολόγηση εντός ή στα όρια της κατανομής εκπαίδευσης, ενώ τα test sets με $TTE \approx 0.5$ s, $TTE \approx 3.0$ s και $TTE \approx 4.0$ s αποτελούν εκτός κατανομής αξιολόγηση. Με αυτόν τον τρόπο εξετάζεται αν το μοντέλο έχει μάθει γενικεύσιμα πρότυπα συμπεριφοράς ή αν η απόδοσή του περιορίζεται μόνο στο χρονικό εύρος στο οποίο εκπαιδεύτηκε.

Η αξιολόγηση σε πολύ μικρό χρονικό ορίζοντα, όπως $TTE \approx 0.5$ s, αντιστοιχεί σε σενάριο άμεσης αντίδρασης, όπου η πρόθεση του πεζού είναι συνήθως πιο εμφανής αλλά ο διαθέσιμος χρόνος αντίδρασης για το όχημα είναι περιορισμένος. Αντίθετα, οι μεγαλύτεροι χρονικοί ορίζοντες, όπως $TTE \approx 3.0$ s και $TTE \approx 4.0$ s, αντιστοιχούν σε πιο πρώιμη πρόβλεψη, όπου η συμπεριφορά του πεζού είναι λιγότερο καθορισμένη και το πρόβλημα γίνεται δυσκολότερο. Συνεπώς, το πρωτόκολλο multi-horizon evaluation επιτρέπει την ποσοτικοποίηση τόσο της άμεσης απόδοσης του μοντέλου όσο και της ικανότητάς του για έγκαιρη πρόβλεψη.

4.2 Κύρια Αποτελέσματα στο PIE Benchmark

Η ενότητα αυτή παρουσιάζει την κύρια αξιολόγηση της προτεινόμενης αρχιτεκτονικής PIPN στο PIE benchmark. Πρώτα τεκμηριώνεται η σταθερότητα της εκπαίδευσης σε

επίπεδο τυχαίας αρχικοποίησης και η επιλογή του βέλτιστου μοντέλου (Ενότητα 4.2.1), στη συνέχεια αναλύεται η απόδοση σε πολλαπλούς χρονικούς ορίζοντες πρόβλεψης (Ενότητα 4.2.2), και τέλος παρατίθεται συγκριτική αξιολόγηση έναντι αντιπροσωπευτικών μοντέλων της βιβλιογραφίας (Ενότητα 4.2.3).

4.2.1 Σταθερότητα Εκπαίδευσης και Επιλογή Βέλτιστου Μοντέλου

Για να αξιολογηθεί η ευρωστία της προτεινόμενης αρχιτεκτονικής έναντι στοχαστικών παραγόντων εκπαίδευσης, εκτελέστηκε πέντε φορές η ίδια διαδικασία εκπαίδευσης με διαφορετικά random seeds (42, 43, 44, 45, 46). Όλες οι υπερπαραμέτροι, τα splits δεδομένων και οι ρυθμίσεις του optimizer παρέμειναν σταθερές μεταξύ των επαναλήψεων η μοναδική διαφορά αφορούσε την αρχικοποίηση των βαρών, τη σειρά shuffling των batches και τη σειρά εφαρμογής των stochastic operations (dropout, AMP). Η σύγκριση των πέντε ανεξάρτητων εκπαιδεύσεων ποσοτικοποιεί την εξάρτηση της τελικής απόδοσης από τέτοιους τυχαίους παράγοντες. Ο

Πίνακας 4.3 συνοψίζει τις επιδόσεις των πέντε εκπαιδεύσεων στο PIE test set, αξιολογημένες στον τυπικό χρονικό ορίζοντα TTE ≈ 1.5 s.

Seed	TTE	Test Loss	Val AUC	Test AUC	Test F1	Test Acc	Precision	Recall
42	~1.5s	1.2328	0.8869	0.8890	0.6974	0.8202	0.6295	0.7817
43	~1.5s	1.3122	0.8482	0.8790	0.6697	0.7639	0.5332	0.8772
44	~1.5s	1.3825	0.8720	0.8710	0.6760	0.7593	0.5275	0.8772
45	~1.5s	1.3232	0.8694	0.8960	0.7238	0.8202	0.6104	0.8889
46	~1.5s	1.1950	0.8655	0.9000	0.7150	0.7371	0.5022	0.9025
Average:	~1.5s	1.2891	0.8684	0.8870	0.6964	0.7801	0.5606	0.8655

Πίνακας 4.3: Επιδόσεις πέντε ανεξάρτητων εκπαιδεύσεων στο PIE test set



Σχήμα 4.1: Bar plot Test AUC ανά seed

Η τυπική απόκλιση του Test ROC-AUC ανέρχεται σε $\sigma = 0.0106$, δηλαδή λιγότερο από 1.2% σχετική διακύμανση γύρω από τον μέσο όρο των πέντε εκπαιδεύσεων. Όλα τα seeds επιτυγχάνουν Test ROC-AUC στο εύρος [0.871, 0.900], χωρίς να εμφανίζονται εκπαιδεύ-

σεις που να αποκλίνουν σημαντικά. Αυτή η χαμηλή ευαισθησία στην τυχαία αρχικοποίηση αποτελεί ένδειξη ευρωστίας της αρχιτεκτονικής, και προεξοφλεί ότι η σταθερότητα αυτή απορρέει από τη συμπληρωματική φύση των πολλαπλών κλάδων μια υπόθεση η οποία τεκμηριώνεται ποσοτικά παρακάτω μέσω ανάλυσης συσχετίσεων σφαλμάτων.

Επιλογή βέλτιστου μοντέλου. Για την κύρια ποσοτική αξιολόγηση αναφέρονται οι μέσοι όροι των πέντε ανεξάρτητων seeds, ώστε να αποφευχθεί επιλογή μοντέλου με βάση το test set. Συμπληρωματικά, για τις αναλύσεις πολλαπλών χρονικών οριζόντων και τα ποιοτικά παραδείγματα χρησιμοποιείται το seed = 46 ως αντιπροσωπευτικό case study όχι ως μοντέλο επιλεγμένο με κριτήριο το test. Σημειώνεται ότι το seed = 46 δεν αποτελεί στατιστικό outlier: η απόκλισή του από τον μέσο όρο (+0.013 ROC-AUC) βρίσκεται εντός 1.25σ, εντός φυσιολογικού εύρους διακύμανσης μεταξύ ανεξάρτητων εκπαιδεύσεων. Επιπλέον, το συγκεκριμένο μοντέλο παρουσιάζει το μικρότερο gap μεταξύ validation και test ROC-AUC μεταξύ των πέντε εκπαιδεύσεων (Test ROC-AUC – Val ROC-AUC = +0.0345), στοιχείο που υποδηλώνει καλή γενίκευση χωρίς ένδειξη υπερπροσαρμογής στο validation set.

Παρατήρηση για τη μεθοδολογία αξιολόγησης του Πίνακα 4.3. Όλες οι μετρικές που εξαρτώνται από κατώφλι (F1, Precision, Recall, Accuracy) στον παραπάνω πίνακα έχουν υπολογιστεί με το default threshold $\tau = 0.5$, πριν εφαρμοστεί το validation selected στατικό κατώφλι $\tau = 0.7585$. Η σταθερότητα μεταξύ των seeds που τεκμηριώνεται εδώ αφορά κατά κύριο λόγο το ROC-AUC ($\sigma = 0.0106$), το οποίο είναι ανεξάρτητο της επιλογής κατωφλίου και αποτελεί την πιο αξιόπιστη μετρική σύγκρισης. Η αξιολόγηση με το validation selected κατώφλι $\tau = 0.7585$ στους πέντε χρονικούς ορίζοντες παρουσιάζεται παρακάτω, όπου επανεξετάζονται οι μετρικές για το επιλεγμένο best model στους πέντε χρονικούς ορίζοντες.

Παρατηρείται ωστόσο ότι το seed = 46, ακόμη και με το default κατώφλι έχει υψηλή τιμή Recall 0.903 αντικατοπτρίζει εγγενή ιδιότητα του εκπαιδευμένου μοντέλου: τείνει να προβλέπει την κλάση crossing με υψηλή ευαισθησία, λόγω του weighted Binary Cross-Entropy loss με pos_weight που χρησιμοποιήθηκε κατά την εκπαίδευση για την αντιμετώπιση της μη ισορροπίας κλάσεων.


4.2.2 Αξιολόγηση σε πολλαπλούς χρονικούς ορίζοντες

Στην ενότητα αυτή παρουσιάζεται η αξιολόγηση του βέλτιστου μοντέλου (seed = 46) στα πέντε ξεχωριστά test sets που αντιστοιχούν σε διαφορετικούς χρονικούς ορίζοντες πρόβλεψης (TTE = 0.5, 1.0, 2.0, 3.0, 4.0 s). Οι μετρικές που εξαρτώνται από κατώφλι υπολογίζονται πλέον με το validation selected στατικό κατώφλι $\tau = 0.7585$, αντικαθιστώντας το default $\tau = 0.5$ της προηγούμενης ενότητας.

Ο Πίνακας 4.4 παρουσιάζει τις κύριες μετρικές απόδοσης σε όλους τους χρονικούς ορίζοντες.

Horizon	N	ROC-AUC	F1	Precision	Recall	Accuracy
TTE $\approx$ 0.5 s	684	0.8826	0.7366	0.7135	0.7611	0.8567
TTE $\approx$ 1.0 s	664	0.8984	0.7360	0.7198	0.7529	0.8584
TTE $\approx$ 2.0 s	603	0.9082	0.7576	0.7310	0.7862	0.8673
TTE $\approx$ 3.0 s	539	0.8980	0.7329	0.6993	0.7698	0.8553
TTE $\approx$ 4.0 s	487	0.8712	0.6791	0.6319	0.7339	0.8234
Μέσος όρος	—	0.8917	0.7284	0.6991	0.7608	0.8522

Πίνακας 4.4: Επιδόσεις του best model σε πέντε χρονικούς ορίζοντες



Σχήμα 4.2: Καμπύλη ROC-AUC συναρτήσει του χρονικού ορίζοντα TTE.

Πέρα από τις συγκεντρωτικές τιμές ROC-AUC του Πίνακα 4.4, το Σχήμα 4.2 παρέχει μια πιο αναλυτική εικόνα της συμπεριφοράς του μοντέλου στους διαφορετικούς χρονικούς ορίζοντες. Η ROC καμπύλη επιτρέπει την αξιολόγηση της σχέσης μεταξύ True Positive Rate και False Positive Rate για διαφορετικά κατώφλια απόφασης, αναδεικνύο-

ντας πώς μεταβάλλεται η απόδοση του μοντέλου πέρα από μία μόνο συνολική τιμή ROC-AUC.

Πρώτον, στην περιοχή χαμηλού False Positive Rate, περίπου για $FPR \leq 0.15$, παρατηρούνται διαφορές μεταξύ των χρονικών οριζόντων. Η περιοχή αυτή είναι ιδιαίτερα σημαντική για εφαρμογές ενεργής ασφάλειας οχήματος, καθώς αντιστοιχεί σε πιο αυστηρά κατώφλια απόφασης, όπου περιορίζεται ο αριθμός των false positives. Στο συγκεκριμένο τμήμα της καμπύλης, ο χρονικός ορίζοντας $TTE \approx 1.0s$ εμφανίζει υψηλή τιμή True Positive Rate σε σχέση με τους υπόλοιπους ορίζοντες. Ενδεικτικά, για $FPR \approx 0.10$, η αντίστοιχη καμπύλη επιτυγχάνει $TPR \approx 0.75$, ενώ οι υπόλοιπες καμπύλες κυμαίνονται σε χαμηλότερο εύρος. Παρότι ο ορίζοντας $TTE \approx 2.0s$ παρουσιάζει το υψηλότερο συνολικό ROC-AUC, ο ορίζοντας $TTE \approx 1.0s$ φαίνεται να αποδίδει καλύτερα σε πιο αυστηρή περιοχή του ROC χώρου.

Δεύτερον, όλες οι καμπύλες συγκλίνουν στο πάνω δεξιό τμήμα του διαγράμματος, όπου το True Positive Rate πλησιάζει την τιμή 1.0. Η σύγκλιση αυτή δείχνει ότι, σε πιο χαλαρά κατώφλια απόφασης, το μοντέλο μπορεί να ανακτήσει μεγάλο ποσοστό των θετικών περιπτώσεων σε όλους τους χρονικούς ορίζοντες. Οι βασικές διαφορές μεταξύ των οριζόντων εντοπίζονται κυρίως στο πόσο γρήγορα κάθε καμπύλη ανέρχεται προς το άνω αριστερό τμήμα του ROC χώρου, δηλαδή στην περιοχή όπου επιτυγχάνεται υψηλό TPR με χαμηλό FPR.

Συνολικά, τα αποτελέσματα δείχνουν ότι το μοντέλο διατηρεί υψηλή διαχωριστική ικανότητα σε όλους τους χρονικούς ορίζοντες, με μέσο ROC-AUC 0.8917. Η καλύτερη επίδοση εμφανίζεται στο $TTE \approx 2.0s$, δηλαδή στο άνω όριο του εύρους εκπαίδευσης, ενώ η απόδοση μειώνεται στον μακρύτερο ορίζοντα $TTE \approx 4.0s$. Η μείωση αυτή είναι αναμενόμενη, καθώς στους μεγαλύτερους χρονικούς ορίζοντες η πρόθεση του πεζού είναι λιγότερο εμφανής και τα διαθέσιμα οπτικά και κινηματικά σήματα είναι ασθενέστερα. Παρόλα αυτά, το ROC-AUC = 0.8712 στο $TTE \approx 4.0s$ παραμένει σημαντικά υψηλότερο από την τυχαία πρόβλεψη, υποδεικνύοντας ικανότητα χρονικής γενίκευσης πέρα από το εύρος εκπαίδευσης.

4.2.3 Σύγκριση με τη Βιβλιογραφία

Η συγκριτική αξιολόγηση της προτεινόμενης αρχιτεκτονικής έναντι αντιπροσωπευτικών μοντέλων της βιβλιογραφίας παρουσιάζεται στον Πίνακα 4.5 και στο Σχήμα 4.3. Πριν την ερμηνεία των αποτελεσμάτων, είναι σημαντικό να διευκρινιστεί ότι η άμεση αριθμητική σύγκριση μεταξύ διαφορετικών εργασιών δεν είναι πλήρως ισοδύναμη, καθώς τα διαθέσιμα papers συχνά διαφοροποιούνται ως προς τα splits, τις στρατηγικές δειγματοληψίας, τα augmentations, τα χρονικά παράθυρα αξιολόγησης και τα χρησιμοποιούμενα χαρακτηριστικά.

Το προτεινόμενο PIPN σχεδιάστηκε με προσανατολισμό σε σενάριο έγκαιρης προειδοποίησης (early warning). Για τον λόγο αυτό, το κύριο εύρος εκπαίδευσης ορίστηκε σε $TTE \in [1.0, 2.0] s$, όπου η πρόβλεψη παραμένει αρκετά πρόωμη ώστε να παρέχει χρήσιμο χρόνο αντίδρασης στο όχημα, αλλά ταυτόχρονα υπάρχουν επαρκή οπτικά και κινηματικά σήματα για αξιόπιστη εκτίμηση της πρόθεσης. Αντίθετα, ο χρονικός ορίζοντας $TTE \approx 0.5 s$ χρησιμοποιείται στην παρούσα εργασία κυρίως ως εκτός κατανομής αξιολόγηση, καθώς δεν περιλαμβάνεται στο εύρος εκπαίδευσης, και η πρακτική αξία της πρόβλεψης σε αυτό

το σημείο μειώνεται καθώς το διαθέσιμο χρονικό περιθώριο αντίδρασης είναι περιορισμένο. Το στατικό κατώφλι $\tau = 0.7585$ επιλέχθηκε αντίστοιχα στο $TTE \approx 1$ s υποσύνολο του validation set, σύμφωνα με αυτόν τον σχεδιαστικό προσανατολισμό.

Μεθοδολογικοί περιορισμοί της σύγκρισης. Οι βασικοί περιορισμοί της σύγκρισης είναι οι εξής:

Πρώτον, οι χρονικοί ορίζοντες αξιολόγησης δεν είναι ίδιοι σε όλες τις εργασίες. Για παράδειγμα, το CIPF αξιολογείται στο $TTE = 1$ s, ενώ μοντέλα όπως τα PCPA, GraphPlus και PIP-Net-α αναφέρουν κυρίως αποτελέσματα στο $TTE = 0.5$ s.

Δεύτερον, αρκετές εργασίες δεν αναφέρουν με πλήρη λεπτομέρεια τα splits, τις στρατηγικές augmentation ή τους ακριβείς κανόνες δειγματοληψίας (TTE εύρος εκπαίδευσης, overlap κ.λπ.).

Τρίτον, ορισμένες αρχιτεκτονικές αξιοποιούν προεκπαιδευμένα components ή εξαγόμενα χαρακτηριστικά που δεν είναι πλήρως αναπαραγώγιμα χωρίς πρόσβαση στον αρχικό κώδικα.


Ένας επιπλέον παράγοντας που επηρεάζει τη σύγκριση είναι το είδος των εισόδων που απαιτεί κάθε αρχιτεκτονική. Ορισμένες μέθοδοι αξιοποιούν χαρακτηριστικά τα οποία είναι διαθέσιμα στο PIE ή μπορούν να παραχθούν μόνο υπό συγκεκριμένες προϋποθέσεις, όπως semantic context, segmentation maps, pose, ego-vehicle speed ή άλλα χωρικά χαρακτηριστικά της σκηνής. Παρότι τέτοιες πληροφορίες μπορούν να ενισχύσουν σημαντικά την απόδοση σε benchmark συνθήκες, η αξιοποίησή τους σε πραγματικό σενάριο προϋποθέτει ότι μπορούν να παραχθούν αξιόπιστα και, ιδανικά, σε πραγματικό χρόνο από ανεξάρτητα perception modules.

Στην παρούσα εργασία, τα περισσότερα perceptual features που εισάγονται στο μοντέλο δεν παρέχονται ως ground-truth annotations κατά την αξιολόγηση, αλλά παράγονται μέσω ανεξάρτητων offline feature extraction σταδίων, όπως περιγράφηκε στο Κεφάλαιο 3.

Παρά τους περιορισμούς αυτούς, ο Πίνακας 4.5 αποτελεί την καθιερωμένη μορφή σύγκρισης στη βιβλιογραφία και παρέχει χρήσιμη ένδειξη της σχετικής τοποθέτησης του προτεινόμενου μοντέλου.

Model	Χρονικός Όριζο- ντας	Acc	ROC-AUC	F1	Precision	Recall
ATGC [14]	0.5 s	0.59	0.55	0.39	0.33	0.47
Multi- RNN[38]	0.5 s	0.83	0.80	0.71	0.69	0.73
SingleRNN [39]	0.5 s	0.81	0.75	0.64	0.67	0.61
SFRNN [40]	0.5 s	0.84	0.82	0.72	0.75	0.80
PCPA [41]	0.5 s	0.87	0.86	0.77	0.75	0.79
CAPformer [42]	0.5 s	0.88	0.80	0.71	0.69	0.74
PPCI [43]	0.5 s	0.89	0.86	0.80	0.79	0.81
GraphPlus[44]	0.5 s	0.89	0.90	0.81	0.83	0.79
MCIP* [45]	0.5 s	0.89	0.87	0.81	0.81	0.81
CIPF* [13]	1.0 s	0.91	0.89	0.84	0.85	0.83
PIT* [46]	0.5 s	0.91	0.92	0.82	0.84	0.81
VMIGI [47]	0.5 s	0.92	0.91	0.87	0.86	0.88
TrEP [12]	0.5 s	0.92	0.93	0.86	0.87	0.84
PIP-Net- α*[8]	0.5 s	0.92	0.94	0.88	0.89	0.88
Ours (PIPNet)	0.5 s	0.857	0.883	0.737	0.714	0.761
Ours (PIPNet)	2.0 s	0.867	0.908	0.758	0.731	0.786

Πίνακας 4.5: Συγκριτική αξιολόγηση στο *PIE benchmark*. Αποτελέσματα σημειωμένα με * αναφέρονται από τα πρωτότυπα *papers* λόγω μη διαθεσιμότητας κώδικα. Για το προτεινόμενο μοντέλο παρουσιάζονται δύο χρονικοί ορίζοντες: $TTE \approx 0.5 s$, ως εκτός κατανομής αξιολόγηση, και $TTE \approx 2.0 s$, ως εντός του κύριου εύρους σχεδιασμού.



Σχήμα 4.3: Multi-horizon σύγκριση ROC-AUC, F1-score και Accuracy έναντι MCIP, CIPF και PIP-Net-α στο εύρος TTE = 1–4 s.

Στον ορίζοντα TTE ≈ 2.0 s, ο οποίος βρίσκεται εντός του κύριου εύρους εκπαίδευσης και αποτελεί βασικό χρονικό ορίζοντα για τον σχεδιασμό early warning συστήματος, το προτεινόμενο PIPN επιτυγχάνει ROC-AUC = 0.908. Στον ορίζοντα TTE ≈ 1.0 s, η αντίστοιχη τιμή είναι ROC-AUC = 0.898, συγκρίσιμη με το CIPF, το οποίο αξιολογείται στον ίδιο χρονικό ορίζοντα. Αντίθετα, στον ορίζοντα TTE ≈ 0.5 s, ο οποίος δεν περιλαμβάνεται στο εύρος εκπαίδευσης του προτεινόμενου μοντέλου, η απόδοση παραμένει υψηλή (ROC-AUC = 0.883) αλλά υπολείπεται ορισμένων πρόσφατων αρχιτεκτονικών που έχουν βελτιστοποιηθεί ή αξιολογηθεί σε αυτόν τον ορίζοντα.

Multi-horizon σύγκριση. Για να εξεταστεί η συμπεριφορά των μοντέλων πέρα από μία μεμονωμένη τιμή TTE, το Σχήμα 4.3 παρουσιάζει τη σύγκριση των MCIP, CIPF και PIP-Net-α με το προτεινόμενο PIPN στο εύρος TTE = 1–4 s, όπου υπάρχουν διαθέσιμα συγκρίσιμα αποτελέσματα στη βιβλιογραφία. Οι κόκκινες καμπύλες αντιστοιχούν στο προτεινόμενο PIPN. Οι μετρικές F1-score και Accuracy του PIPN υπολογίζονται με στατικό κατώφλι επιλεγμένο στο validation set.

Παρατηρούμε ότι στο ROC-AUC το προτεινόμενο μοντέλο διατηρεί ισχυρή απόδοση καθ' όλο το εύρος (ROC-AUC ≥ 0.87 από 1 έως 4 s), ενώ τα MCIP και CIPF παρουσιάζουν πιο απότομη πτώση πέρα από τους 2 s. Στο F1-score και την Accuracy, με χρήση του στατικού κατωφλίου $\tau = 0.7585$ (επιλεγμένο στο validation set), το προτεινόμενο μοντέλο διατηρεί επίσης σταθερή απόδοση καθ' όλο το εύρος TTE = 1–4 s, σε αντίθεση με τα μοντέλα αναφοράς που παρουσιάζουν φθίνουσα τάση καθώς αυξάνεται ο χρονικός ορίζοντας.

Πέρα από τις απόλυτες τιμές ROC-AUC, μια χαρακτηριστική ιδιότητα του προτεινόμενου μοντέλου είναι η τάση προς υψηλότερο Recall σε σχέση με Precision: στο 2 s ο λόγος Recall/Precision είναι $0.786/0.731 \approx 1.08$, ενώ για το PIP-Net-α είναι $0.88/0.89 \approx$

0.99. Η συμπεριφορά αυτή είναι συμβατή με τη χρήση weighted Binary Cross-Entropy loss κατά την εκπαίδευση, καθώς η θετική κλάση λαμβάνει μεγαλύτερη βαρύτητα. Σε εφαρμογές early warning ασφαλείας, ένα τέτοιο profile είναι λειτουργικά επιθυμητό: το σύστημα μεγιστοποιεί την ανίχνευση πραγματικών διασχίσεων (high Recall), δεχόμενο κάποια αύξηση των ψευδών συναγερμών (lower Precision) ως αποδεκτό κόστος.

Η προτεινόμενη αρχιτεκτονική διαθέτει 4.42M εκπαιδευσιμες παραμέτρους, περίπου 20% λιγότερες από το PIP-Net-α ($\approx 5.5M$), διατηρώντας ταυτόχρονα πολυτροπική δομή με τρεις ξεχωριστούς κλάδους και attention-based fusion. Η μείωση αυτή υποδηλώνει ελαφρύτερο εκπαιδευσιμο fusion network, στοιχείο σημαντικό για μελλοντική αξιοποίηση σε συστήματα με περιορισμένους υπολογιστικούς πόρους.

Συνολικά, το προτεινόμενο PIPN τοποθετείται ανταγωνιστικά σε σχέση με τη βιβλιογραφία, ιδιαίτερα υπό την οπτική του κύριου στόχου σχεδιασμού της εργασίας, δηλαδή την έγκαιρη πρόβλεψη στο εύρος $TTE = 1-2$ s. Στον ορίζοντα $TTE \approx 0.5$ s, ο οποίος αποτελεί εκτός κατανομής αξιολόγηση για το προτεινόμενο μοντέλο, η απόδοση παραμένει υψηλότερη από την τυχαία πρόβλεψη ($ROC-AUC = 0.883$) αλλά υπολείπεται ορισμένων πρόσφατων αρχιτεκτονικών υψηλής χωρητικότητας. Αντίθετα, στους ορίζοντες $TTE \approx 1.0$ s και $TTE \approx 2.0$ s, το μοντέλο επιτυγχάνει ισχυρή διαχωριστική ικανότητα, με $ROC-AUC$ 0.898 και 0.908 αντίστοιχα. Επιπλέον, η σταθερή απόδοση σε πολλαπλούς χρονικούς ορίζοντες δείχνει ότι η αρχιτεκτονική δεν περιορίζεται αποκλειστικά στο εύρος εκπαίδευσης, αλλά παρουσιάζει ικανότητα χρονικής γενίκευσης. Επιπλέον, η χρήση εξαγόμενων perceptual features, αντί για ιδανικές ground-truth εισόδους, ενισχύει τον deployment-oriented χαρακτήρα της αξιολόγησης, αν και η πραγματική εφαρμογή απαιτεί μελλοντική αξιολόγηση με online detection, tracking και feature extraction.

4.2.4 Ποιοτική ανάλυση προβλέψεων

Πέρα από τις συνολικές μετρικές αξιολόγησης, πραγματοποιήθηκε ποιοτική ανάλυση επιλεγμένων προβλέψεων στο PIE test set, με στόχο να εξεταστεί η συμπεριφορά του μοντέλου σε επιτυχημένες και αποτυχημένες περιπτώσεις. Το Σχήμα 4.4 παρουσιάζει ενδεικτικά παραδείγματα true positive, true negative, false positive και false negative προβλέψεων για $ETC \approx 0.5s$.

Στις επιτυχημένες crossing περιπτώσεις, το μοντέλο αποδίδει υψηλή πιθανότητα όταν ο πεζός βρίσκεται κοντά στο οδόστρωμα ή εμφανίζει σαφή κινηματικά/οπτικά cues διάσχισης. Στις true negative περιπτώσεις, η πιθανότητα παραμένει χαμηλή όταν η στάση ή η τροχιά του πεζού δεν υποδηλώνει άμεση διάσχιση. Τα σφάλματα είναι ιδιαίτερα χρήσιμα για την ερμηνεία των περιορισμών του μοντέλου: false positives εμφανίζονται σε αμφίσημες σκηνές όπου ο πεζός βρίσκεται κοντά σε πιθανή ζώνη διάσχισης, ενώ false negatives μπορούν να προκύψουν όταν η πρόθεση δεν είναι εμφανής από το σύντομο observation window ή όταν υπάρχει μερική απόκρυψη.

Το Σχήμα 4.4 παρουσιάζει χαρακτηριστικά παραδείγματα. Στις σωστές περιπτώσεις (TP, TN), το μοντέλο αναθέτει πιθανότητες σαφώς διαχωρισμένες από το κατώφλι. Ιδιαίτερο ενδιαφέρον έχουν τα σφάλματα: το false positive (set03/video_0008, $p=0.560$) αφορά πεζό που στέκεται στο άκρο του πεζοδρομίου με στάση που υποδηλώνει πρόθεση διάσχισης, αλλά τελικά δεν διασχίζει ακριβώς το είδος hard negative που στοχεύει η μεθοδολογία. Το false negative (set03/video_0015, $p=0.112$) αφορά πεζό σε occlusion μέσα σε πλή-

θος, όπου τα οπτικά σήματα είναι ασθενή. Τα παραδείγματα αυτά δείχνουν ότι τα εναπομείναντα σφάλματα του μοντέλου εμφανίζονται κυρίως σε αμφίσημες ή occluded περιπτώσεις, συνεπείς με τη φύση του προβλήματος.

Qualitative PIPN predictions at ETC $\approx$ 0.5s



Σχήμα 4.4: Ποιοτικά παραδείγματα προβλέψεων του PIPN στο PIE test set για TTE ≈ 0.5 s. Παρουσιάζονται ενδεικτικές περιπτώσεις true positive, true negative, false

positive και false negative. Για κάθε παράδειγμα εμφανίζονται τρία χρονικά σημεία του observation window, το target bounding box και η προβλεπόμενη πιθανότητα crossing.

4.3 Ανάλυση Αρχιτεκτονικής και Σταθερότητας

Στην ενότητα αυτή εξετάζονται δύο διακριτές πτυχές της συμπεριφοράς του προτεινόμενου μοντέλου που υπερβαίνουν τις τυπικές μετρικές αξιολόγησης (ROC-AUC, F1). Στην Ενότητα 4.3.1 διερευνάται η συμπληρωματικότητα των τριών κλάδων της αρχιτεκτονικής μέσω ανάλυσης συσχετίσεων σφαλμάτων, παρέχοντας ποσοτική τεκμηρίωση για την παρατηρούμενη ευρωστία του μοντέλου έναντι της τυχαίας αρχικοποίησης. Στην Ενότητα 4.3.2 αξιολογείται η χρονική σταθερότητα των προβλέψεων σε διαδοχικά παράθυρα παρατήρησης του ίδιου πεζού, ιδιότητα κρίσιμη για deployment σε εφαρμογές αυτόνομης οδήγησης.

4.3.1 Συμπληρωματικότητα Κλάδων (Pearson Error Correlation)

Στην Ενότητα 4.2.1 τεκμηριώθηκε ότι η προτεινόμενη αρχιτεκτονική παρουσιάζει χαμηλή ευαισθησία στην τυχαία αρχικοποίηση ($\sigma = 0.0106$ σε Test ROC-AUC), στοιχείο που υποδηλώνει συστηματική ευρωστία. Στην παρούσα υποενότητα επιχειρείται η ποσοτική ερμηνεία αυτής της ευρωστίας μέσω ανάλυσης της σχέσης μεταξύ των τριών κλάδων της αρχιτεκτονικής.

Μεθοδολογία πειράματος: Η αρχιτεκτονική διαθέτει τέσσερις διακριτές εξόδους (`return_aux=True`): την κύρια συγχωνευμένη πρόβλεψη `main`, καθώς και τις τρεις βοηθητικές εξόδους `kin`, `local`, `global` που αντιστοιχούν στους ξεχωριστούς κλάδους. Για κάθε δείγμα του test set, υπολογίστηκε το σφάλμα πρόβλεψης κάθε εξόδου ως η απόλυτη διαφορά από την ετικέτα `ground truth`, και στη συνέχεια εφαρμόστηκε Pearson correlation analysis μεταξύ όλων των ζευγών κλάδων. Τιμές r κοντά στο $+1$ υποδεικνύουν ότι δύο κλάδοι κάνουν τα ίδια λάθη στα ίδια δείγματα (πλεονασμός πληροφορίας), ενώ τιμές κοντά στο 0 υποδεικνύουν ανεξάρτητα σφάλματα (συμπληρωματικότητα). Για τη διασφάλιση στατιστικής αξιοπιστίας, η διαδικασία επαναλήφθηκε σε όλα τα 5 seeds και αναφέρονται οι μέσοι όροι.

Ζεύγος κλάδων	Pearson r	Ερμηνεία
<code>main ↔ kin</code>	0.513	<code>main</code> ενσωματώνει σήμα <code>kin</code> κλάδου
<code>main ↔ local</code>	0.420	Μέτρια προς υψηλή
<code>main ↔ global</code>	0.378	Μέτρια
<code>kin ↔ local</code>	0.354	Μέτρια και οι δύο εστιάζουν στον πεζό
<code>kin ↔ global</code>	0.167	Χαμηλή συμπληρωματικότητα
<code>local ↔ global</code>	0.088	Πολύ χαμηλή ισχυρή συμπληρωματικότητα

Πίνακας 4.6: Συσχέτιση κατά Pearson μεταξύ σφαλμάτων ζευγών κλάδων στο *PIE test set* (Οι τιμές αναφέρονται ως μέσοι όροι των πέντε seeds και χρησιμοποιούνται κυρίως για ποιοτική ερμηνεία της συμπληρωματικότητας των κλάδων).

Από τα αποτελέσματα προκύπτουν τρεις διακριτές κατηγορίες συσχετίσεων:

Συσχετίσεις του main με τους υπόλοιπους κλάδους ($r \in [0.38, 0.51]$). Οι συσχετίσεις αυτές είναι αναμενόμενα υψηλές, καθώς ο main κλάδος αποτελεί τη συγχωνευμένη έξοδο που ενσωματώνει όλους τους κλάδους μέσω του attention μηχανισμού. Η ελαφρώς υψηλότερη συσχέτιση με τον κινηματικό κλάδο ($r = 0.513$) είναι συμβατή με την κυρίαρχη συνεισφορά του στις βραχυπρόθεσμες προβλέψεις, εύρημα που επιβεβαιώνεται και από τη μελέτη αφαίρεσης κλάδων στην Ενότητα 4.4.

Μέτρια συσχέτιση kin-local ($r = 0.354$). Είναι λογική, καθώς και οι δύο κλάδοι επεξεργάζονται pedestrian-centric χαρακτηριστικά: ο κινηματικός κλάδος επικεντρώνεται σε κίνηση και θέση του πεζού, ενώ ο τοπικός οπτικός κλάδος σε RGB patches γύρω από αυτόν. Παρότι αξιοποιούν διαφορετικές πηγές πληροφορίας, και οι δύο τείνουν να αποτυγχάνουν σε παρόμοιες περιπτώσεις όπως πεζοί σε ασυνήθιστες στάσεις ή με μερική απόκρυψη. Πολύ χαμηλές συσχετίσεις του global κλάδου ($r < 0.17$). Αποτελούν το πιο σημαντικό εύρημα της ανάλυσης. Ο καθολικός χωρικός κλάδος εμφανίζει ελάχιστη συσχέτιση σφαλμάτων τόσο με τον κινηματικό ($r = 0.167$) όσο και με τον τοπικό οπτικό κλάδο ($r = 0.088$). Το αποτέλεσμα αυτό υποδεικνύει ότι ο global κλάδος μαθαίνει ουσιαστικά διαφορετική πληροφορία από τους υπόλοιπους, λειτουργώντας ως πραγματικά συμπληρωματική πηγή σήματος βασισμένη σε scene-level χαρακτηριστικά (διάταξη οδού, διαβάσεις, ζώνες πεζών) αντί σε pedestrian-level χαρακτηριστικά.

Τα παραπάνω παρέχουν ποσοτική απάντηση στο ερώτημα του γιατί η αρχιτεκτονική εμφανίζει χαμηλή ευαισθησία στην τυχαία αρχικοποίηση. Όταν τρεις κλάδοι μαθαίνουν ως επί το πλείστον ανεξάρτητη πληροφορία όπως αποδεικνύεται από την πολύ χαμηλή συσχέτιση σφαλμάτων του global με τους δύο pedestrian-centric κλάδους μια υποβέλτιστη αρχικοποίηση σε έναν μόνο κλάδο δεν είναι σε θέση να επηρεάσει καθοριστικά την τελική απόδοση, καθώς οι υπόλοιποι κλάδοι συνεχίζουν να παρέχουν αξιοποιήσιμη ροή πληροφορίας. Με άλλα λόγια, η πολυκλαδική δομή λειτουργεί ως ensemble-like συμπεριφορά σε επίπεδο αναπαράστασης, χωρίς την ανάγκη ξεχωριστής εκπαίδευσης πολλών μοντέλων.

4.3.2 Χρονική Σταθερότητα (Temporal Jitter Analysis)

Πέρα από τη σταθερότητα μεταξύ διαφορετικών εκπαιδεύσεων, μια εξίσου κρίσιμη ιδιότητα για συστήματα αυτόνομης οδήγησης είναι η χρονική συνοχή των προβλέψεων. Σε ένα πραγματικό σενάριο deployment, το μοντέλο εφαρμόζεται διαδοχικά σε ολισθαίνοντα χρονικά παράθυρα που αφορούν τον ίδιο πεζό. Είναι επιθυμητό οι προβλεπόμενες πιθανότητες πρόθεσης διάσχισης να παρουσιάζουν ομαλή χρονική εξέλιξη, χωρίς απότομες ταλαντώσεις. Διαφορετικά, ένα downstream σύστημα ελέγχου του οχήματος θα ελάμβανε ασυνεπείς αποφάσεις (π.χ. απότομα φρεναρίσματα), που είναι ανεπιθύμητο για την ομαλή πορεία και την άνεση των επιβατών.

Μεθοδολογία πειράματος: Για την ποσοτική αξιολόγηση της χρονικής συνοχής αξιοποιήθηκαν τα μοναδικά pedestrian IDs των annotations του PIE dataset. Συσχετίζοντας διαδοχικά παράθυρα που αφορούν τον ίδιο πεζό, ορίστηκαν 613 multi-window tracks, καθένα από τα οποία περιλαμβάνει τουλάχιστον δύο διαδοχικά παράθυρα. Για κάθε track υπολογίστηκαν δύο μετρικές διακύμανσης:

$\sigma(P)$: η τυπική απόκλιση των προβλεπόμενων πιθανοτήτων P εντός του track. Αντικατοπτρίζει τη συνολική διασπορά των προβλέψεων.

$|\Delta P|$: η μέση απόλυτη μεταβολή της πιθανότητας μεταξύ διαδοχικών παραθύρων. Αντικατοπτρίζει την τοπική ομαλότητα της χρονικής εξέλιξης.

Στη συνέχεια υπολογίστηκαν οι μέσοι όροι των δύο μετρικών πάνω στα 613 tracks.

Ο πίνακας 4.7 παρουσιάζει ενδεικτικά εύρη που χαρακτηρίζουν διαφορετικά επίπεδα χρονικής σταθερότητας, βασισμένα σε εμπειρικές παρατηρήσεις από προηγούμενα πειράματα μη βελτιστοποιημένων μοντέλων.

Επίπεδο σταθερότητας	$\sigma(P)$	$ \Delta P $
Χαμηλή (ασταθές μοντέλο)	≈ 0.15	≈ 0.25
Μέτρια	≈ 0.08	≈ 0.15
PIPN (το προτεινόμενο)	0.055	0.073
Τέλεια σταθερότητα	0.00	0.00

Πίνακας 4.7: Ποιοτική κατάταξη χρονικής σταθερότητας προβλέψεων.

Οι τιμές $\sigma(P) = 0.055$ και $|\Delta P| = 0.073$ κατατάσσουν το μοντέλο εντός του εύρους υψηλής χρονικής σταθερότητας. Πρακτικά αυτό σημαίνει ότι, για έναν πεζό που παρακολουθείται σε διαδοχικά παράθυρα παρατήρησης, η προβλεπόμενη πιθανότητα διάσχισης δεν παρουσιάζει ταλαντώσεις: αν στο πρώτο παράθυρο η πιθανότητα εκτιμηθεί π.χ. στο 0.80, στο επόμενο παράθυρο θα κυμανθεί τυπικά στο εύρος $[0.73, 0.87]$ και όχι σε εντελώς διαφορετικό σημείο. Η συμπεριφορά αυτή είναι κρίσιμη για σταθερότητα στις αποφάσεις του οχήματος: ένα σύστημα ελέγχου που λαμβάνει συνεπείς εκτιμήσεις πιθανότητας μπορεί να λάβει ομαλές, μη απότομες αποφάσεις σχετικά με ταχύτητα, φρενάρισμα ή παρακολούθηση.

Η παρατηρούμενη χρονική ομαλότητα δεν είναι τυχαία, αλλά συνδέεται με δύο σχεδιαστικές επιλογές της αρχιτεκτονικής. Πρώτον, η χρήση παραθύρου ολίσθησης με overlap 0.6 στην εκπαίδευση εκθέτει το μοντέλο σε ελαφρώς μετατοπισμένες εκδοχές του ίδιου συμβάντος, ενθαρρύνοντας έμμεσα τη χρονική συνέπεια των αναπαραστάσεων.

4.4 Μελέτη Αφαίρεσης και Συνεισφοράς Κλάδων (Ablation Study)

Για να κατανοηθεί ο ρόλος κάθε κλάδου στην προτεινόμενη πολυτροπική αρχιτεκτονική, πραγματοποιήθηκε συστηματική ανάλυση συνεισφοράς σε δύο συμπληρωματικά επίπεδα. Αρχικά, στην Ενότητα 4.4.1 αξιολογείται η ανεξάρτητη διαχωριστική ικανότητα κάθε κλάδου μέσω των auxiliary heads της αρχιτεκτονικής. Η ανάλυση αυτή δείχνει τι μπορεί να προβλέψει κάθε κλάδος όταν εξετάζεται ως αυτόνομος ταξινομητής, πριν από τη συγχώνευσή του με τους υπόλοιπους κλάδους.

Στη συνέχεια, στην Ενότητα 4.4.2 εξετάζεται η συμβολή κάθε κλάδου στη fused έξοδο μέσω branch-zeroing ablation. Σε αυτή τη διαδικασία, τα features ενός κλάδου μηδενίζονται κατά την αξιολόγηση, ενώ το υπόλοιπο δίκτυο παραμένει ενεργό. Με τον τρόπο αυτό ποσοτικοποιείται πόση απόδοση χάνεται όταν αφαιρείται ένας κλάδος από το πλήρες fused μοντέλο. Η διάκριση ανάμεσα στις δύο αναλύσεις είναι σημαντική. Η ανεξάρτητη απόδοση ενός κλάδου δεν ταυτίζεται απαραίτητα με τη συνεισφορά του στο πλήρες μοντέλο. Ένας κλάδος μπορεί να έχει υψηλή απόδοση, αλλά να περιέχει πληροφορία που επικαλύπτεται με άλλους κλάδους. Αντίστροφα, ένας κλάδος με μέτρια απόδοση μπορεί να πα-

ρέχει πληροφορία που δεν μπορεί να αναπληρωθεί εύκολα από τους υπόλοιπους. Για τον λόγο αυτό, οι δύο αναλύσεις ερμηνεύονται συμπληρωματικά.

Όλες οι αναλύσεις πραγματοποιούνται στους πέντε χρονικούς ορίζοντες αξιολόγησης.


4.4.1 Αξιολόγηση Ανεξάρτητων Κλάδων

Η αρχιτεκτονική έχει σχεδιαστεί ώστε να επιτρέπει την ανεξάρτητη αξιολόγηση κάθε κλάδου μέσω τριών auxiliary classification heads, ενός για κάθε κλάδο: kinematic, local visual και global context. Τα auxiliary heads εκπαιδεύονται παράλληλα με το κύριο fused head μέσω auxiliary loss term. Κατά την αξιολόγηση, το μοντέλο επιστρέφει τόσο την τελική fused πρόβλεψη όσο και τις ενδιάμεσες εξόδους των επιμέρους κλάδων. Κάθε auxiliary logit μετατρέπεται σε πιθανότητα μέσω sigmoid και αξιολογείται ανεξάρτητα.

Με αυτόν τον τρόπο, κάθε κλάδος εξετάζεται ως αυτόνομος classifier πριν από την συγχώνευση μέσω του attention-based fusion μηχανισμού. Η ανάλυση αυτή αποτυπώνει τη διαχωριστική ικανότητα των επιμέρους modalities, χωρίς να λαμβάνει υπόψη τις αλληλεπιδράσεις μεταξύ τους.

Χρονικός Ορίζοντας	Fused	Kinematic	Local	Global
TTE = 0.5 s	0.883	0.880	0.767	0.741
TTE = 1.0 s	0.898	0.877	0.823	0.765
TTE = 2.0 s	0.908	0.855	0.803	0.819
TTE = 3.0 s	0.898	0.832	0.821	0.800
TTE = 4.0 s	0.871	0.798	0.794	0.791
Δ (0.5s $\rightarrow$ 4s)	-0.012	-0.082	+0.027	+0.050

Πίνακας 4.8: Per-branch ROC-AUC σε όλους τους χρονικούς ορίζοντες (best model).



Σχήμα 4.5: Per-branch ROC-AUC συναρτήσεως του χρονικού ορίζοντα TTE, με σκιαγραφημένη την out-of-distribution περιοχή ($TTE \geq 2.5$ s). Σταδιακή σύγκλιση των kinematic και global branches γύρω από το $TTE \approx 2.0$ s.

Από τον Πίνακα 4.8 προκύπτει ότι κάθε κλάδος παρουσιάζει διαφορετικό προφίλ συμπεριφοράς ως προς τον χρονικό ορίζοντα πρόβλεψης.

Ο kinematic branch είναι ο ισχυρότερος ανεξάρτητος κλάδος στους κοντινούς χρονικούς ορίζοντες. Στο $TTE \approx 0.5$ s, επιτυγχάνει $ROC-AUC = 0.880$, σχεδόν ίσο με το fused μοντέλο, το οποίο επιτυγχάνει $ROC-AUC = 0.883$. Ωστόσο, η απόδοσή του μειώνεται σταδιακά όσο αυξάνεται ο χρονικός ορίζοντας, φτάνοντας $ROC-AUC = 0.798$ στο $TTE \approx 4.0$ s. Η μείωση αυτή δείχνει ότι τα καθαρά κινηματικά χαρακτηριστικά είναι ιδιαίτερα χρήσιμα όταν η πρόθεση του πεζού έχει ήδη αρχίσει να εκδηλώνεται, αλλά γίνονται λιγότερο επαρκή για πιο πρώιμες προβλέψεις.

Ο global context branch ακολουθεί την αντίθετη τάση. Στους κοντινούς ορίζοντες είναι ο ασθενέστερος ανεξάρτητος κλάδος, με $ROC-AUC = 0.741$ στο $TTE \approx 0.5$ s. Καθώς όμως ο χρονικός ορίζοντας αυξάνεται, η απόδοσή του βελτιώνεται, φτάνοντας $ROC-AUC = 0.819$ στο $TTE \approx 2.0$ s και παραμένοντας ανταγωνιστική στους μακρύτερους ορίζοντες. Η συμπεριφορά αυτή υποδηλώνει ότι το ευρύτερο σκηνικό πλαίσιο αποκτά μεγαλύτερη αξία όταν η άμεση κίνηση του πεζού δεν έχει ακόμη αποκαλύψει ξεκάθαρα την πρόθεσή του.

Ο local visual branch βρίσκεται ενδιάμεσα. Δεν φτάνει την απόδοση του kinematic branch στους κοντινούς ορίζοντες, αλλά διατηρεί σχετικά σταθερή απόδοση στο εύρος $TTE \approx 1.0$ s έως $TTE \approx 4.0$ s. Αυτό δείχνει ότι τα τοπικά οπτικά χαρακτηριστικά γύρω από τον πεζό παρέχουν συμπληρωματική πληροφορία, ιδίως όταν η στάση σώματος, ο προσανατολισμός και το άμεσο οπτικό περιβάλλον μπορούν να βοηθήσουν στην εκτίμηση πρόθεσης.

Ιδιαίτερο ενδιαφέρον παρουσιάζει το σημείο γύρω από το $TTE \approx 2.0s$, όπου οι αποδόσεις των kinematic και global branches γίνονται συγκρίσιμες. Στον ίδιο χρονικό ορίζοντα το fused μοντέλο επιτυγχάνει τη μέγιστη επίδοσή του, με $ROC-AUC = 0.908$. Το εύρημα αυτό υποδηλώνει ότι η καλύτερη συνολική απόδοση επιτυγχάνεται όταν οι επιμέρους κλάδοι παρέχουν συμπληρωματικά και ισορροπημένα σήματα: ο kinematic branch προσφέρει πληροφορία άμεσης κίνησης, ενώ ο global branch προσφέρει πληροφορία σκηνής και πιθανών περιοχών διάσχισης.

Συνολικά, η ανάλυση των auxiliary heads δείχνει ότι η πολυκλαδική δομή δεν αποτελεί περιττή πολυπλοκότητα. Αντίθετα, διαφορετικοί κλάδοι είναι πιο χρήσιμοι σε διαφορετικούς χρονικούς ορίζοντες. Οι κοντινές προβλέψεις βασίζονται περισσότερο σε pedestrian-centric σήματα, ενώ οι πιο πρώιμες προβλέψεις απαιτούν μεγαλύτερη αξιοποίηση του global scene context.

4.4.2 Πείραμα Αφαίρεσης Κλάδων (Branch-Zeroing Ablation)

Η προηγούμενη ενότητα αξιολόγησε κάθε κλάδο ως ανεξάρτητο classifier. Στην παρούσα ενότητα ακολουθείται διαφορετική προσέγγιση: το πλήρες μοντέλο διατηρείται ενεργό, αλλά κατά την inference μηδενίζονται τα features εξόδου ενός κλάδου πριν εισέλθουν στο attention-based fusion module. Η διαδικασία αυτή ονομάζεται branch-zeroing ablation.

Η μεθοδολογία αυτή ποσοτικοποιεί πόση απόδοση χάνεται όταν αφαιρείται ένας συγκεκριμένος κλάδος, ενώ οι υπόλοιποι παραμένουν ενεργοί. Συνεπώς, η μετρική που προκύπτει δεν εκφράζει τη συνολική σημασία ενός branch, αλλά τη μη-αντικαταστήσιμη συνεισφορά του στη fused έξοδο. Με άλλα λόγια, μετρά πόσο δύσκολο είναι να αναπληρωθεί η πληροφορία ενός κλάδου από τους υπόλοιπους κλάδους.


Η μείωση της απόδοσης υπολογίζεται ως:

$$\Delta ROC - AUC = ROC - AUC_{full} - ROC - AUC_{ablated}$$

Μικρή τιμή $\Delta ROC-AUC$ δεν σημαίνει απαραίτητα ότι ένας κλάδος είναι ασήμαντος. Μπορεί να σημαίνει ότι η πληροφορία του επικαλύπτεται με την πληροφορία άλλων κλάδων και μπορεί να αντισταθμιστεί από αυτούς. Αντίθετα, μεγάλη τιμή $\Delta ROC-AUC$ υποδηλώνει ότι η πληροφορία του συγκεκριμένου κλάδου είναι δύσκολο να αναπληρωθεί από τις υπόλοιπες εισόδους.

TTE	Full ROC-AUC	Δ Kinematic	Δ Local visual	Δ Global context
0.5 s	0.883	0.067	0.079	0.020
1.0 s	0.898	0.037	0.076	0.018
2.0 s	0.908	0.034	0.033	0.049
3.0 s	0.898	0.019	0.044	0.064
4.0 s	0.871	0.014	0.028	0.072

Πίνακας 4.9: Μείωση ROC-AUC μετά τον μηδενισμό κάθε κλάδου ανά χρονικό ορίζοντα



Σχήμα 4.6: Bar plot της μείωσης ROC-AUC (ΔAUC) μετά την εξάλειψη κάθε κλάδου, ανά χρονικό ορίζοντα TTE. Σημειώνονται οι δύο αντίθετες τάσεις: αύξηση της σημασίας του global κλάδου και μείωση της σημασίας των kin/local κλάδων με την αύξηση του TTE.

Το Σχήμα 4.6 παρουσιάζει οπτικά τις τιμές $\Delta ROC-AUC$, αναδεικνύοντας δύο αντίθετες τάσεις: η μη-αντικαταστήσιμη συνεισφορά των kinematic και local visual branches μειώνεται όσο αυξάνεται το TTE, ενώ η αντίστοιχη συνεισφορά του global context branch αυξάνεται.

Στους κοντινούς χρονικούς ορίζοντες, δηλαδή για $TTE \leq 1.0s$, η αφαίρεση του local visual branch προκαλεί τη μεγαλύτερη πτώση απόδοσης. Συγκεκριμένα, η πτώση είναι 0.079 στο $TTE \approx 0.5s$ και 0.076 στο $TTE \approx 1.0s$. Αυτό δεν σημαίνει ότι ο local branch είναι ο ισχυρότερος standalone classifier, καθώς στην Ενότητα 4.4.1 φάνηκε ότι ο kinematic branch έχει υψηλότερη ανεξάρτητη απόδοση στους ίδιους ορίζοντες. Σημαίνει όμως ότι η πληροφορία που μεταφέρει ο local branch είναι δύσκολο να αναπληρωθεί από τους kinematic και global branches όταν αυτός αφαιρεθεί από το fused μοντέλο.

Η ερμηνεία αυτή είναι σημαντική. Στους κοντινούς ορίζοντες, τα τοπικά οπτικά χαρακτηριστικά γύρω από τον πεζό, όπως η στάση σώματος, ο προσανατολισμός και το άμεσο οπτικό περιβάλλον, φαίνεται να παρέχουν μοναδική συμπληρωματική πληροφορία. Παρότι ο kinematic branch είναι ήδη πολύ ισχυρός, δεν μπορεί να αναπληρώσει πλήρως

την πληροφορία του local visual branch. Αντίθετα, η αφαίρεση του global branch έχει μικρή επίδραση στους κοντινούς ορίζοντες, με πτώση μόνο 0.020 στο $TTE \approx 0.5s$ και 0.018 στο $TTE \approx 1.0s$. Αυτό υποδηλώνει ότι η ευρύτερη σκηνή είναι λιγότερο αναντικατάστατη όταν η πρόθεση του πεζού είναι ήδη εμφανής μέσα από άμεσα pedestrian-centric σήματα.

Στους μακρύτερους χρονικούς ορίζοντες, δηλαδή για $TTE \geq 3.0s$, η εικόνα αντιστρέφεται. Η αφαίρεση του global context branch προκαλεί τη μεγαλύτερη πτώση απόδοσης: 0.064 στο $TTE \approx 3.0s$ και 0.072 στο $TTE \approx 4.0s$. Αντίθετα, η αφαίρεση του kinematic branch έχει πλέον μικρή επίδραση, με πτώση 0.019 στο $TTE \approx 3.0s$ και 0.014 στο $TTE \approx 4.0s$. Αυτό δείχνει ότι, όταν η πρόθεση του πεζού δεν έχει ακόμη εκδηλωθεί έντονα κινηματικά, το ευρύτερο σκηνικό πλαίσιο γίνεται η πιο δύσκολα αναπληρώσιμη πηγή πληροφορίας.

Το ενδιαμέσο σημείο $TTE \approx 2.0s$ παρουσιάζει ιδιαίτερο ενδιαφέρον. Σε αυτόν τον ορίζοντα οι πτώσεις των τριών κλάδων βρίσκονται σε σχετικά κοντινό εύρος: 0.034 για τον kinematic branch, 0.033 για τον local visual branch και 0.049 για τον global context branch. Κανένας κλάδος δεν κυριαρχεί αποκλειστικά ως μη-αντικαταστήσιμη πηγή πληροφορίας. Το γεγονός αυτό συμπίπτει με τη μέγιστη απόδοση του fused μοντέλου, το οποίο επιτυγχάνει $ROC-AUC = 0.908$ στον ίδιο χρονικό ορίζοντα. Η σύμπτωση αυτή υποδηλώνει ότι η βέλτιστη συνολική απόδοση προκύπτει όταν οι κλάδοι λειτουργούν πραγματικά συμπληρωματικά.

Οι αντίθετες τάσεις μπορούν να ποσοτικοποιηθούν καθαρά. Η επίδραση της αφαίρεσης του kinematic branch μειώνεται από 0.067 στο $TTE \approx 0.5s$ σε 0.014 στο $TTE \approx 4.0s$, δηλαδή μειώνεται περίπου 4.8 φορές. Ο local visual branch παρουσιάζει επίσης φθίνουσα τάση, από 0.079 σε 0.028, δηλαδή περίπου 2.8 φορές μικρότερη επίδραση. Αντίθετα, η επίδραση της αφαίρεσης του global context branch αυξάνεται από 0.020 σε 0.072, δηλαδή περίπου 3.6 φορές. Το αποτέλεσμα αυτό αναδεικνύει μια σαφή χρονική εξειδίκευση των κλάδων.

Η συμπεριφορά αυτή είναι συνεπής με τη φύση του προβλήματος. Σε βραχυπρόθεσμες προβλέψεις, τα pedestrian-centric χαρακτηριστικά είναι ιδιαίτερα ισχυρά, επειδή η κίνηση και η στάση του πεζού έχουν ήδη αρχίσει να υποδηλώνουν πιθανή διάσχιση. Σε μακροπρόθεσμες προβλέψεις, η κινηματική πληροφορία είναι πιο αμφίσημη, καθώς ο πεζός μπορεί να κινείται παράλληλα με τον δρόμο ή να βρίσκεται ακόμη σε στάδιο αναμονής. Σε αυτές τις περιπτώσεις, τα scene-level χαρακτηριστικά, όπως η ύπαρξη διάβασης, πεζοδρομίου, ζώνης αναμονής ή η γενικότερη γεωμετρία της σκηνής, γίνονται κρίσιμα για την έγκαιρη πρόβλεψη.

Το βασικό συμπέρασμα της ανάλυσης είναι ότι η συνεισφορά των κλάδων δεν είναι σταθερή στον χρόνο. Στους κοντινούς ορίζοντες, η πληροφορία των local και kinematic branches είναι ιδιαίτερα σημαντική για τη fused απόφαση. Στους μακρύτερους ορίζοντες, η μη-αντικαταστήσιμη συνεισφορά μετατοπίζεται προς τον global context branch. Το σημείο ισορροπίας γύρω από τα 2 s συμπίπτει με την υψηλότερη συνολική απόδοση του fused μοντέλου, γεγονός που ενισχύει την υπόθεση ότι η αρχιτεκτονική αποδίδει καλύτερα όταν συνδυάζει ισορροπημένα άμεσα κινηματικά, τοπικά οπτικά και καθολικά σκηνικά χαρακτηριστικά.

Συνεπώς, η πολυκλαδική αρχιτεκτονική επιδεικνύει ικανότητα δυναμικής αναπροσαρμογής στις απαιτήσεις κάθε χρονικού ορίζοντα. Ο attention-based fusion μηχανισμός

δεν αντιμετωπίζει όλους τους κλάδους ως ισοδύναμους σε κάθε περίπτωση, αλλά φαίνεται να αξιοποιεί διαφορετικές πηγές πληροφορίας ανάλογα με το πόσο νωρίς πριν από τη διάσχιση ζητείται η πρόβλεψη.

4.4.3 Post-hoc Logit Fusion: Συνολική Βελτίωση και Περιορισμοί

Πέρα από την ανάλυση των επιμέρους κλάδων, εξετάστηκε μια εναλλακτική στρατηγική συνδυασμού των εξόδων του μοντέλου μέσω post-hoc logit fusion. Η στρατηγική αυτή μπορεί να θεωρηθεί ως μια ελαφριά ensemble-like προσέγγιση σε επίπεδο εξόδων, καθώς συνδυάζει τις προβλέψεις του κύριου fused head και των auxiliary heads χωρίς επανεκπαίδευση της αρχιτεκτονικής. Σε αντίθεση με ένα κλασικό ensemble, δεν απαιτεί την εκπαίδευση πολλαπλών ανεξάρτητων μοντέλων, αλλά αξιοποιεί εξόδους που ήδη παράγονται από την ίδια πολυκλαδική αρχιτεκτονική. Τα βάρη του συνδυασμού επιλέχθηκαν μέσω grid search στο validation set, με βήμα 0.05, υπό τον περιορισμό ότι είναι μη αρνητικά και αθροίζουν στη μονάδα.

Η post-hoc fusion αξιολογήθηκε αρχικά στο κύριο test set με χρονικό εύρος $TTE \in [1.0, 2.0]$ s. Στο συγκεκριμένο εύρος, το οποίο αντιστοιχεί στο βασικό εύρος εκπαίδευσης και αξιολόγησης της εργασίας, η μέθοδος προσέφερε μικρή αλλά μετρήσιμη βελτίωση σε σχέση με το standalone main output.

Μετρική	Main output	Post-hoc fusion	Δ
ROC-AUC	0.8870	0.8960	+0.0090
F1-score	0.6964	0.7068	+0.0104

Πίνακας 4.10: Επίδραση του post-hoc logit fusion στο κύριο test set $TTE \in [1.0, 2.0]$ s. Μέσος όρος από όλα τα seeds.

Κλάδος	Βάρος
Main	63%
Kinematic	23%
Global	14%
Local	0%

Πίνακας 4.11: Βέλτιστα βάρη post-hoc fusion.

Τα βέλτιστα βάρη που προέκυψαν από το validation set παρουσιάζονται στον

Η κατανομή των βαρών δείχνει ότι το κύριο fused head παραμένει η κυρίαρχη πηγή πληροφορίας, ενώ οι kinematic και global έξοδοι προσφέρουν μικρή συμπληρωματική βελτίωση. Αντίθετα, ο local visual κλάδος λαμβάνει μηδενικό βάρος στη post-hoc διαμόρφωση. Το αποτέλεσμα αυτό δεν σημαίνει ότι ο local branch είναι ασήμαντος. Όπως έδειξε η branch-zeroing ανάλυση της Ενότητας 4.4.2, ο local branch συνεισφέρει ουσιαστικά στο επίπεδο των fused representations. Η μηδενική post-hoc στάθμιση δείχνει μόνο ότι, στο επίπεδο των τελικών πιθανοτήτων, η πληροφορία του local branch έχει ήδη ενσωματωθεί στο main output και δεν προσφέρει επιπλέον όφελος μέσω απλού γραμμικού συνδυασμού.

Ωστόσο, η βελτίωση της post-hoc fusion δεν διατηρήθηκε όταν η ίδια στρατηγική αξιολογήθηκε ξεχωριστά στους επιμέρους χρονικούς ορίζοντες του multi-horizon πρωτοκόλλου. Το εύρημα αυτό είναι σημαντικό, καθώς δείχνει ότι τα σταθερά post-hoc βάρη δεν

γενικεύουν απαραίτητα σε διαφορετικά TTE splits. Η συμπεριφορά αυτή είναι συνεπής με τα ευρήματα των Ενοτήτων 4.4.1 και 4.4.2, όπου φάνηκε ότι η συνεισφορά των κλάδων μεταβάλλεται συστηματικά με τον χρονικό ορίζοντα. Επομένως, ένας ενιαίος γραμμικός συνδυασμός των branch outputs μπορεί να βελτιώνει τη μέση απόδοση σε μια συγκεκριμένη κατανομή, αλλά δεν μπορεί να προσαρμοστεί δυναμικά στις διαφορετικές απαιτήσεις κάθε χρονικού ορίζοντα.

Συνεπώς, η post-hoc fusion ερμηνεύεται ως συμπληρωματικό διαγνωστικό πείραμα και όχι ως κύρια βελτίωση της αρχιτεκτονικής. Η μικρή βελτίωση στο aggregate test set δείχνει ότι τα auxiliary heads περιέχουν επιπλέον αξιοποιήσιμη πληροφορία. Παράλληλα, η αδυναμία της μεθόδου να βελτιώσει σταθερά τα επιμέρους TTE splits επιβεβαιώνει ότι η χρονικά μεταβαλλόμενη συνεισφορά των κλάδων είναι καλύτερα να αντιμετωπίζεται εντός του attention-based fusion μηχανισμού, και όχι μέσω σταθερού post-hoc γραμμικού συνδυασμού.

4.5 Ικανότητα Γενίκευσης (Cross-Dataset Transferability)

Για να αξιολογηθεί η ικανότητα γενίκευσης της προτεινόμενης αρχιτεκτονικής πέρα από το κύριο dataset εκπαίδευσης, πραγματοποιήθηκε μελέτη cross-dataset transferability. Συγκεκριμένα, συγκρίθηκαν τρεις στρατηγικές εκπαίδευσης: η βασική PIE-only εκπαίδευση, η στρατηγική JAAD $\rightarrow$ PIE Transfer Learning και η στρατηγική Combined JAAD+PIE training. Τα μοντέλα αξιολογήθηκαν σε ξεχωριστά held-out test sets των PIE και JAAD, με στόχο να εξεταστεί ο συμβιβασμός μεταξύ εξειδίκευσης στο κύριο benchmark και γενίκευσης σε διαφορετική κατανομή δεδομένων.

Η ανάλυση αυτή είναι σημαντική, καθώς η υψηλή απόδοση σε ένα μεμονωμένο dataset δεν συνεπάγεται απαραίτητα αντίστοιχη απόδοση σε διαφορετικό domain. Τα PIE και JAAD διαφοροποιούνται ως προς τη διαθεσιμότητα χαρακτηριστικών, τις συνθήκες λήψης, την κατανομή σκημών και τις συμβάσεις annotation. Επομένως, η cross-dataset αξιολόγηση παρέχει μια πιο αυστηρή ένδειξη της ανθεκτικότητας της αρχιτεκτονικής σε domain shift.

4.5.1 Σύγκριση Στρατηγικών Εκπαίδευσης

Ο Πίνακας 4.12 παρουσιάζει τη σύγκριση των τριών στρατηγικών εκπαίδευσης στα PIE και JAAD test sets. Οι μετρικές που εξαρτώνται από κατώφλι υπολογίζονται με το προκαθορισμένο στατικό κατώφλι που επιλέχθηκε στο PIE validation set, χωρίς επαναρύθμιση στο JAAD validation ή test set.

Μετρική	PIE-only / PIE test	Transfer / PIE test	Combined/ PIE test	PIE-only / JAAD test	Transfer / JAAD test	Combined/ JAAD test
ROC-AUC	0.892	0.857	0.856	0.543	0.621	0.635
F1-score	0.729	0.616	0.625	0.464	0.405	0.613
Precision	0.710	0.692	0.692	0.504	0.547	0.626
Recall	0.760	0.585	0.601	0.522	0.659	0.601

Πίνακας 4.12: Σύγκριση στρατηγικών εκπαίδευσης σε PIE και JAAD test sets.

Πριν από την ερμηνεία των αποτελεσμάτων, πρέπει να σημειωθεί ότι οι σχετικά χαμηλές τιμές στο JAAD test set δεν οφείλονται σε απουσία ρύθμισης του μοντέλου. Όπως περιγράφηκε στην Ενότητα 4.1.4, η αναζήτηση υπερπαραμέτρων πραγματοποιήθηκε ξεχωριστά για κάθε στρατηγική εκπαίδευσης, ενώ οι στρατηγικές που αξιοποιούν το JAAD χρησιμοποίησαν διαφορετικές ρυθμίσεις σε learning rate, batch size, dropout και early stopping. Παρόλα αυτά, η αξιολόγηση στο JAAD παραμένει ιδιαίτερα απαιτητική, καθώς το dataset είναι μικρότερο, δεν παρέχει ισοδύναμη πληροφορία ταχύτητας του ego-vehicle και αξιολογείται στο ίδιο early-warning εύρος $TTE \in [1.0, 2.0]$ s. Επιπλέον, το στατικό κατώφλι απόφασης δεν επαναρρυθμίστηκε στο JAAD validation set, αλλά διατηρήθηκε το κατώφλι που είχε επιλεγεί στο PIE validation set. Συνεπώς, τα αποτελέσματα στο JAAD πρέπει να ερμηνεύονται ως αυστηρή cross-dataset αξιολόγηση και όχι ως dataset-specific βελτιστοποιημένη επίδοση.

Τα αποτελέσματα αναδεικνύουν έναν σαφή συμβιβασμό μεταξύ εξειδίκευσης και γενίκευσης. Το PIE-only μοντέλο επιτυγχάνει την υψηλότερη απόδοση στο PIE test set, με $ROC-AUC = 0.892$ και $F1-score = 0.729$. Ωστόσο, η απόδοσή του στο JAAD test set είναι περιορισμένη, με $ROC-AUC = 0.543$, τιμή που βρίσκεται οριακά πάνω από την τυχαία πρόβλεψη. Το εύρημα αυτό υποδηλώνει ότι η εκπαίδευση αποκλειστικά στο PIE οδηγεί σε ισχυρή εξειδίκευση στο συγκεκριμένο domain, αλλά περιορίζει την ικανότητα μεταφοράς σε διαφορετική κατανομή δεδομένων.

Η στρατηγική JAAD $\rightarrow$ PIE Transfer Learning βελτιώνει την απόδοση στο JAAD test set σε σχέση με το PIE-only μοντέλο, αυξάνοντας το ROC-AUC από 0.543 σε 0.621. Ωστόσο, η βελτίωση αυτή συνοδεύεται από μείωση της απόδοσης στο PIE test set, όπου το ROC-AUC μειώνεται από 0.892 σε 0.857. Το αποτέλεσμα αυτό δείχνει ότι η προεκπαίδευση στο JAAD προσφέρει χρήσιμη αρχικοποίηση και καλύτερη cross-dataset συμπεριφορά, αλλά η τελική εξειδίκευση στο PIE δεν διατηρεί πλήρως τη γενικευσιμότητα του πρώτου σταδίου.

Η στρατηγική Combined JAAD+PIE training επιτυγχάνει την καλύτερη απόδοση στο JAAD test set, με $ROC-AUC = 0.635$ και $F1-score = 0.613$. Παρότι η απόδοση στο PIE είναι ελαφρώς χαμηλότερη από το PIE-only baseline, η Combined στρατηγική προσφέρει τον καλύτερο συμβιβασμό μεταξύ των δύο datasets. Η ταυτόχρονη έκθεση του μοντέλου σε δείγματα από JAAD και PIE φαίνεται να οδηγεί σε πιο γενικεύσιμες αναπαραστάσεις, περιορίζοντας την υπερεξειδίκευση στο PIE και βελτιώνοντας τη μεταφορά στο JAAD. Συνολικά, τα αποτελέσματα δείχνουν ότι η επιλογή στρατηγικής εκπαίδευσης εξαρτάται από τον στόχο εφαρμογής. Αν ο κύριος στόχος είναι η μέγιστη απόδοση στο PIE benchmark, η PIE-only στρατηγική παραμένει η ισχυρότερη επιλογή. Αντίθετα, αν ο στόχος είναι καλύτερη cross-dataset γενίκευση, η Combined στρατηγική εμφανίζεται πιο κατάλληλη, καθώς επιτυγχάνει σαφώς καλύτερη απόδοση στο JAAD με περιορισμένο κόστος στο PIE.

4.5.2 Per-branch Cross-Dataset Transferability

Πέρα από τη συνολική απόδοση του fused μοντέλου, εξετάστηκε και η μεταφερσιμότητα των επιμέρους κλάδων της αρχιτεκτονικής. Η ανάλυση αυτή έχει στόχο να δείξει ποια είδη χαρακτηριστικών γενικεύουν καλύτερα από το PIE στο JAAD και ποια επηρεάζονται περισσότερο από το domain shift.

Ο Πίνακας 4.13 παρουσιάζει το ROC-AUC κάθε branch στο JAAD test set για το PIE-only και το Combined μοντέλο.

Branch	PIE-only @ JAAD	Combined @ JAAD	Δ
Kinematic	0.583	0.615	+0.032
Local visual	0.495	0.550	+0.055
Global context	0.579	0.674	+0.095
Fused main	0.543	0.635	+0.092

Πίνακας 4.13: Per-branch ROC-AUC στο JAAD test set ανά στρατηγική εκπαίδευσης.

Το σημαντικότερο εύρημα είναι ότι ο global context branch παρουσιάζει τη μεγαλύτερη βελτίωση στο JAAD test set, αυξάνοντας το ROC-AUC από 0.579 σε 0.674. Η αύξηση αυτή είναι μεγαλύτερη από την αντίστοιχη βελτίωση του kinematic branch και του local visual branch. Το αποτέλεσμα υποδηλώνει ότι τα scene-level χαρακτηριστικά είναι περισσότερο μεταβιβάσιμα μεταξύ datasets σε σχέση με χαρακτηριστικά που εξαρτώνται πιο έντονα από dataset-specific κινηματικά μοτίβα, annotation conventions ή τοπικές οπτικές ιδιαιτερότητες.

Το εύρημα αυτό είναι συνεπές με την ανάλυση της Ενότητας 4.4. Εκεί φάνηκε ότι ο global context branch αποκτά μεγαλύτερη σημασία στους μεγαλύτερους χρονικούς ορίζοντες, όπου η άμεση κινηματική πληροφορία του πεζού δεν είναι ακόμη πλήρως καθοριστική. Η παρούσα cross-dataset ανάλυση επεκτείνει αυτό το συμπέρασμα, δείχνοντας ότι το global scene context δεν είναι μόνο χρήσιμο για μακροπρόθεσμη πρόβλεψη, αλλά και πιο ανθεκτικό στη μεταφορά μεταξύ διαφορετικών datasets.

Αντίθετα, ο kinematic branch παρουσιάζει πιο περιορισμένη βελτίωση. Αυτό είναι αναμενόμενο, καθώς τα κινηματικά χαρακτηριστικά μπορούν να επηρεαστούν από διαφορές στον τρόπο annotation, στην ποιότητα των trajectories, στη συχνότητα δειγματοληψίας και στη διαθεσιμότητα δυναμικής πληροφορίας του ego-vehicle. Ο local visual branch βελτιώνεται περισσότερο από τον kinematic, αλλά παραμένει χαμηλότερα από τον global context branch, γεγονός που υποδηλώνει ότι τα τοπικά οπτικά χαρακτηριστικά γύρω από τον πεζό επηρεάζονται επίσης από domain-specific παράγοντες, όπως η ανάλυση εικόνας, η γωνία κάμερας, οι συνθήκες φωτισμού και η εμφάνιση των πεζών.

Συνολικά, η per-branch cross-dataset ανάλυση δείχνει ότι η γενίκευση της αρχιτεκτονικής δεν προέρχεται ομοιόμορφα από όλους τους κλάδους. Ο global context branch φαίνεται να αποτελεί το πιο μεταβιβάσιμο συστατικό της αρχιτεκτονικής, ενώ η fused έξοδος ωφελείται από τον συνδυασμό του με τους υπόλοιπους κλάδους. Το αποτέλεσμα αυτό ενισχύει την επιλογή πολυκλαδικού σχεδιασμού, καθώς διαφορετικά είδη πληροφορίας συμβάλλουν σε διαφορετικές πτυχές της απόδοσης και της γενίκευσης.

4.5.3 Περιορισμοί στο JAAD Evaluation

Παρότι η αξιολόγηση στο JAAD παρέχει χρήσιμη ένδειξη cross-dataset γενίκευσης, τα αποτελέσματα πρέπει να ερμηνεύονται με προσοχή. Τα PIE και JAAD δεν αποτελούν πλήρως ισοδύναμα benchmarks, καθώς διαφοροποιούνται ως προς τη διαθεσιμότητα χαρακτηριστικών, το μέγεθος, τη δομή των annotations και τη φύση του προβλήματος.

Πρώτον, το JAAD δεν παρέχει ισοδύναμη πληροφορία ego-vehicle speed με το PIE. Η δυναμική του οχήματος αποτελεί σημαντικό στοιχείο για την πρόβλεψη πρόθεσης διάσχισης, καθώς επηρεάζει το χρονικό περιθώριο αντίδρασης και τη σχετική κίνηση πεζού-οχήματος. Η απουσία αντίστοιχης πληροφορίας στο JAAD περιορίζει κυρίως τον kinematic branch, ο οποίος στο PIE μπορεί να αξιοποιήσει πληρέστερα τη δυναμική πληροφορία της σκηνής.

Δεύτερον, το JAAD είναι μικρότερο και λιγότερο ποικιλόμορφο σε σχέση με το PIE μετά την προεπεξεργασία. Παρότι πραγματοποιήθηκε ξεχωριστή αναζήτηση υπερπαραμέτρων για τις στρατηγικές που αξιοποιούν JAAD, το περιορισμένο μέγεθος του dataset δυσχεραίνει την εκπαίδευση μιας πολυτροπικής αρχιτεκτονικής με 4.42M εκπαιδευσιμες παραμέτρους. Αυτό αυξάνει τον κίνδυνο υπερπροσαρμογής και περιορίζει τη δυνατότητα του μοντέλου να αξιοποιήσει πλήρως τα διαθέσιμα πολυτροπικά χαρακτηριστικά.

Τρίτον, το JAAD evaluation πραγματοποιήθηκε στο ίδιο χρονικό εύρος $TTE \in [1.0, 2.0]$ s για validation και test, ώστε να διατηρηθεί συνέπεια με το κύριο πρωτόκολλο της εργασίας. Το εύρος αυτό είναι πιο απαιτητικό από πολύ κοντινούς ορίζοντες, όπως $TTE \approx 0.5$ s, καθώς η πρόθεση του πεζού δεν έχει πάντοτε εκδηλωθεί πλήρως κινηματικά. Επομένως, η αξιολόγηση στο JAAD δεν αντιστοιχεί σε ευκολότερο near-crossing σενάριο, αλλά σε early-warning ρύθμιση αντίστοιχη με τον σχεδιασμό του προτεινόμενου μοντέλου.

Τέταρτον, το στατικό κατώφλι απόφασης δεν επαναρυθμίστηκε στο JAAD. Οι μετρικές που εξαρτώνται από κατώφλι, όπως F1-score, Precision και Recall, υπολογίστηκαν με το κατώφλι που είχε επιλεγεί στο PIE validation set. Η επιλογή αυτή καθιστά την cross-dataset αξιολόγηση αυστηρότερη και πιο αντιπροσωπευτική ενός σεναρίου μεταφοράς χωρίς dataset-specific calibration, αλλά μπορεί να υποτιμά τη μέγιστη δυνατή απόδοση στο JAAD. Με βάση τα παραπάνω, η PIE-only εκπαίδευση χρησιμοποιείται ως κύρια στρατηγική αναφοράς για την αξιολόγηση στο βασικό benchmark της εργασίας. Παράλληλα, η Combined στρατηγική αναδεικνύεται ως πιο κατάλληλη επιλογή σε σενάρια όπου η cross-dataset ανθεκτικότητα είναι σημαντικότερη από τη μέγιστη εξειδίκευση σε ένα μόνο dataset. Συνεπώς, οι δύο στρατηγικές δεν πρέπει να θεωρηθούν ανταγωνιστικές, αλλά κατάλληλες για διαφορετικούς στόχους: η PIE-only για υψηλή εξειδίκευση στο PIE και η Combined για καλύτερη γενίκευση σε διαφορετικές κατανομές δεδομένων.

Συνεπώς, η χαμηλότερη απόδοση στο JAAD δεν πρέπει να ερμηνευθεί αποκλειστικά ως αδυναμία της αρχιτεκτονικής. Αντίθετα, συνδέεται με τον ισχυρό domain shift μεταξύ PIE και JAAD, το μικρότερο μέγεθος του JAAD, την απουσία ισοδύναμης πληροφορίας ego-vehicle speed, τη χρήση αυστηρού χρονικού εύρους $TTE \in [1.0, 2.0]$ s και τη διατήρηση του ίδιου validation-selected threshold χωρίς επαναρύθμιση στο JAAD.

4.6 Αποτελέσματα των Transformer-based παραλλαγών

Η παρούσα ενότητα εξετάζει τις Transformer-based παραλλαγές που παρουσιάστηκαν στην Ενότητα 3.4. Στόχος δεν είναι μόνο η σύγκριση τελικής απόδοσης, αλλά κυρίως η κατανόηση του πώς επηρεάζεται η πολυτροπική αρχιτεκτονική όταν ο Transformer εισάγεται με διαφορετικούς τρόπους. Συγκεκριμένα, εξετάζονται τρεις διαδοχικές κατευθύνσεις: η αντικατάσταση του Conv3D global context branch από Spatial-Patch Transformer, η αξιοποίηση του ισχυρού κινηματικού σήματος ως βάση ελαφρύτερης αρχιτεκτονικής, και τέλος η KinFormer-GRU παραλλαγή, όπου ο GRU-based κινηματικός κλάδος διατηρείται ως anchor και τα υπόλοιπα modalities εισάγονται ελεγχόμενα μέσω gated contextual tokens.

Πριν την παρουσίαση των αποτελεσμάτων, πρέπει να διευκρινιστεί ότι στο Κεφάλαιο 4 χρησιμοποιούνται δύο συμπληρωματικά πρωτόκολλα αξιολόγησης. Το πρώτο είναι το κύριο aggregate PIE test set στο εύρος $TTE \in [1.0, 2.0]$ s, το οποίο χρησιμοποιείται για τη multi-seed αξιολόγηση και τη συνολική σταθερότητα του PIPN. Το δεύτερο είναι το αυστηρό multi-horizon πρωτόκολλο, όπου δημιουργούνται ξεχωριστά test subsets χωρίς πρόσθετη πύκνωση για συγκεκριμένους χρονικούς ορίζοντες $TTE \approx 0.5, 1, 2, 3$ και 4s. Επομένως, τα aggregate αποτελέσματα του Πίνακα 4.3 και τα horizon-specific αποτελέσματα των Πινάκων 4.5 και 4.8 δεν πρέπει να ερμηνεύονται ως το ίδιο test set, αλλά ως συμπληρωματικές αξιολογήσεις.

Ως σημείο αναφοράς για τις Transformer-based παραλλαγές χρησιμοποιείται το PIPN, το οποίο αξιολογήθηκε στις προηγούμενες ενότητες. Όπως παρουσιάστηκε στον Πίνακα 4.3, το PIPN εμφανίζει σταθερή multi-seed συμπεριφορά στο κύριο aggregate PIE test set, με μέσο Test ROC-AUC 0.8870. Επιπλέον, στον Πίνακα 4.5 φαίνεται ότι στο αυστηρό multi-horizon πρωτόκολλο επιτυγχάνει ROC-AUC 0.883 στο $TTE \approx 0.5$ s και 0.908 στο $TTE \approx 2.0$ s. Οι τιμές αυτές χρησιμοποιούνται ως baseline για την αξιολόγηση των ελαφρύτερων Transformer-based παραλλαγών.

Η per-branch ανάλυση του Πίνακα 4.8 έδειξε ότι ο κινηματικός κλάδος είναι ιδιαίτερα ισχυρός στους κοντινούς χρονικούς ορίζοντες, ενώ ο global context branch αποκτά μεγαλύτερη σημασία σε μεγαλύτερα TTE. Το εύρημα αυτό είναι κρίσιμο για τη σχεδίαση της KinFormer-GRU, καθώς υποδεικνύει ότι ο κινηματικός κλάδος δεν πρέπει να αντικατασταθεί, αλλά να χρησιμοποιηθεί ως βασικό anchor γύρω από το οποίο εισάγεται ελεγχόμενα η contextual πληροφορία.

4.6.1 Αντικατάσταση του Conv3D global branch με Transformer

Η πρώτη Transformer-based κατεύθυνση αφορούσε την αντικατάσταση του Conv3D global context branch από έναν Spatial-Patch Transformer. Η λογική αυτής της παραλλαγής ήταν ότι το semantic context και το categorical depth μπορούν να χωριστούν σε χωρικά patches, τα οποία στη συνέχεια επεξεργάζονται με self-attention. Με αυτόν τον τρόπο, ο Transformer μπορεί θεωρητικά να μοντελοποιήσει σχέσεις μεταξύ απομακρυσμένων περιοχών της σκηνής, όπως δρόμος, πεζοδρόμιο, οχήματα ή traffic controls.

Η παραλλαγή αυτή μείωσε σημαντικά τον αριθμό παραμέτρων σε σχέση με το PIPN. Ωστόσο, η μείωση αυτή συνοδεύτηκε από πτώση της απόδοσης, όπως φαίνεται στον Πίνακα 4.14. Η Spatial-Patch Transformer παραλλαγή πέτυχε χαμηλότερο ROC-AUC από το PIPN, ενώ η factorized space-time εξετάστηκε αλλά δεν συμπεριλήφθηκε στα τελικά συγκριτικά πειράματα. Επομένως, η απλή αντικατάσταση του Conv3D global branch από

έναν ανεξάρτητο Transformer branch δεν ήταν αρκετή για να διατηρηθεί η απόδοση του αρχικού πολυτροπικού μοντέλου.

Παραλλαγή	Παράμετροι	ROC-AUC	Παρατήρηση
PIPN	4,417,834	0,900	Strongest-AUC baseline
Spatial-Patch Transformer	2,081,322	0.860	Λιγότερες παράμετροι, χαμηλότερη απόδοση

Πίνακας 4.14: Trade-off παραμέτρων και απόδοσης για τις αρχικές Transformer-based παραλλαγές.

Το αποτέλεσμα αυτό δείχνει ότι η χρησιμότητα του Transformer εξαρτάται από τον τρόπο εισαγωγής του στην αρχιτεκτονική. Παρότι ο Transformer μπορεί να μειώσει την παραμετρική πολυπλοκότητα, η απώλεια του Conv3D spatio-temporal inductive bias φαίνεται να επηρεάζει αρνητικά τη γενίκευση του global context branch. Μια πιθανή ερμηνεία, η οποία διατυπώνεται ως υπόθεση και όχι ως αποδεδειγμένος μηχανισμός, είναι ότι ένας ανεξάρτητος Transformer branch μπορεί να λειτουργήσει ως ασθενές ή ασταθές σήμα μέσα στο late fusion, αραιώνοντας την ήδη ισχυρή κινηματική πληροφορία.

Με βάση αυτή την παρατήρηση, η επόμενη κατεύθυνση δεν ήταν να αντικατασταθεί περαιτέρω ο κινηματικός κλάδος ή να ενισχυθεί απλώς ο Transformer branch, αλλά να αλλάξει ο τρόπος σύντηξης. Ο Transformer χρησιμοποιήθηκε πλέον ως μηχανισμός ελεγχόμενης διαμόρφωσης του κινηματικού anchor και όχι ως ανεξάρτητος branch με δική του late-fusion συνεισφορά.

4.6.2 KinFormer-GRU: anchor-only έλεγχος και σταδιακή προσθήκη contextual modalities

Η επόμενη κατεύθυνση ήταν να διατηρηθεί ο ισχυρός GRU-based κινηματικός κλάδος και να χρησιμοποιηθεί ως anchor για την ελεγχόμενη εισαγωγή contextual πληροφορίας. Για τον λόγο αυτό, η KinFormer-GRU αξιολογήθηκε αρχικά σε anchor-only μορφή, δηλαδή μόνο με bounding boxes, pose keypoints και ego-speed, χωρίς segmentation, categorical depth, optical flow ή local context.

Το anchor-only μοντέλο λειτουργεί ως βασικός έλεγχος της νέας αρχιτεκτονικής. Η απόδοσή του βρίσκεται κοντά στην ανεξάρτητη απόδοση του κινηματικού κλάδου του PIPN, γεγονός που δείχνει ότι η KinFormer-GRU δεν αποδυναμώνει το κινηματικό σήμα. Αντίθετα, ξεκινά από μια ισχυρή κινηματική βάση, πάνω στην οποία μπορούν να προστεθούν ελεγχόμενα τα υπόλοιπα modalities.

Στη συνέχεια αξιολογήθηκε η σταδιακή προσθήκη contextual modalities. Τα modalities αυτά δεν εισάγονται ως ανεξάρτητοι κλάδοι απόφασης, αλλά ως gated contextual tokens που μπορούν να διαμορφώσουν το kinematic anchor μέσω self-attention. Έτσι, η contextual πληροφορία δεν αποκτά δική της late-fusion ψήφο, αλλά χρησιμοποιείται μόνο για να ενισχύσει ή να διορθώσει το κινηματικό σήμα.

Configuration	Παράμετροι	ROC-AUC	F1	Accuracy	Παρατήρηση
Anchor only	393,729	0.870	0.677	0.777	Ισχυρό κινηματικό baseline
Segmentation embeddings	527,954	0.856	0.664	0.776	Δεν βελτιώνει την απόδοση
Segmentation embeddings + depth	656,953	0.878	0.672	0.779	Το depth αναγκά μέρος της πληροφορίας
Flow only	472,754	0.864	0.682	0.783	Δεν προσφέρει ουσιαστική βελτίωση
Local only	459,778	0.816	0.626	0.761	Ασθενέστερη προσθήκη
Depth only	522,728	0.879	0.698	0.804	Ισχυρό single contextual variant
Full modalities	797,387	0.882	0.638	0.832	Περισσότερες παράμετροι χωρίς όφελος
Segmentation masks	523,314	0.881	0.670	0.765	Τα traffic-aware masks βελτιώνουν το AUC
Segmentation masks + depth	652,313	0.887	0.716	0.844	Καλύτερο balanced KinFormer-GRU

Πίνακας 4.15: *Modality ablation στο KinFormer-GRU.*

Από τον Πίνακα 4.15 προκύπτει ότι τα contextual modalities δεν είναι όλα εξίσου χρήσιμα. Το categorical depth αποτελεί το ισχυρότερο single contextual variant, καθώς βελτιώνει την απόδοση σε σχέση με το anchor-only μοντέλο και παρουσιάζει καλύτερη fixed-threshold συμπεριφορά από τις υπόλοιπες μεμονωμένες προσθήκες. Το αποτέλεσμα αυτό υποδεικνύει ότι η γεωμετρική πληροφορία της σκηνής λειτουργεί συμπληρωματικά προς την κινηματική πληροφορία.

Αντίθετα, η πλήρης semantic αναπαράσταση με embeddings όλων των κλάσεων δεν βελτιώνει την απόδοση. Πιθανή ερμηνεία είναι ότι πολλές semantic κατηγορίες δεν σχετίζονται άμεσα με το crossing intention task και, σε token-based Transformer setup, μπορούν να εισάγουν θόρυβο. Για τον λόγο αυτό εξετάστηκε μια πιο στοχευμένη traffic-aware αναπαράσταση, όπου το segmentation συμπίεζεται σε έξι binary mask channels: pedestrians, vehicles, traffic controls, road, sidewalk και pole. Η αναπαράσταση αυτή οδηγεί σε καλύτερο ROC-AUC από την πλήρη semantic embedding εκδοχή.

Ο καλύτερος συνδυασμός προκύπτει από τη χρήση segmentation masks μαζί με categorical depth. Το segmentation παρέχει πληροφορία για τη διάταξη των κυκλοφοριακά σχετικών περιοχών, ενώ το categorical depth προσθέτει object-aware γεωμετρική πληροφορία. Έτσι, το μοντέλο αξιοποιεί ταυτόχρονα το «τι υπάρχει» στη σκηνή και το «πόσο κοντά» βρίσκονται σημαντικοί road users.

Αντίθετα, το optical flow και το local context δεν προσφέρουν βελτίωση στο συγκεκριμένο setup. Αυτό δεν σημαίνει ότι οι πληροφορίες αυτές είναι γενικά άχρηστες, αλλά ότι με τον συγκεκριμένο τρόπο εισαγωγής τους ως gated contextual tokens δεν πρόσθεσαν αξιοποιήσιμη πληροφορία πέρα από το ήδη ισχυρό κινηματικό σήμα.

Επειδή οι περισσότερες KinFormer-GRU παραλλαγές αξιολογήθηκαν ως single-seed runs, οι μικρές αριθμητικές διαφορές πρέπει να ερμηνεύονται με προσοχή. Για τον λόγο αυτό, η ανάλυση εστιάζει στα πιο σταθερά μοτίβα: το depth βοηθά, τα traffic-aware masks είναι πιο χρήσιμα από τα πλήρη semantic embeddings, και ο συνδυασμός segmentation masks + depth αποτελεί την πιο ισορροπημένη ελαφριά παραλλαγή.

4.6.3 Επίδραση της αρχικοποίησης των gates

Για το καλύτερο KinFormer-GRU setup, δηλαδή segmentation masks + categorical depth, εξετάστηκαν δύο διαφορετικές αρχικοποιήσεις των gates. Η conservative ρύθμιση χρησιμοποιεί $\text{gate_init} = -2.0$, που αντιστοιχεί σε μικρή αρχική συνεισφορά των contextual tokens. Η open ρύθμιση χρησιμοποιεί $\text{gate_init} = 0.0$, επιτρέποντας μεγαλύτερη αρχική συνεισφορά των modalities.

Configuration	gate_init	Παράμετροι	ROC-AUC	F1	Accuracy	Παρατήρηση
Segmentation masks + depth	-2.0	652,313	0.887	0.716	0.844	Conservative context injection
Segmentation masks + depth	0.0	652,313	0.887	0.728	0.854	Καλύτερη fixed-threshold συμπεριφορά

Πίνακας 4.16: Επίδραση της αρχικοποίησης των gates στο KinFormer-GRU seg+depth.

Οι δύο εκδόσεις έχουν τον ίδιο αριθμό παραμέτρων και διαφέρουν μόνο στην αρχικοποίηση. Από τον Πίνακα 4.16 φαίνεται ότι η open-gate παραλλαγή δεν αλλάζει ουσιαστικά το ROC-AUC, αλλά βελτιώνει το F1 και την Accuracy. Αυτό υποδεικνύει ότι τα gates επηρεάζουν κυρίως τη fixed-threshold συμπεριφορά και όχι τη συνολική διαχωριστική ικανότητα του μοντέλου.

4.6.4 Αξιολόγηση σε πολλαπλούς χρονικούς ορίζοντες


Οι καλύτερες KinFormer-GRU παραλλαγές αξιολογήθηκαν και στο αυστηρό multi-horizon πρωτόκολλο, με ξεχωριστά test subsets από ETC0_5 έως ETC4. Η αξιολόγηση αυτή εξετάζει αν η απόδοση παραμένει σταθερή όταν η πρόβλεψη ζητείται σε διαφορετικά χρονικά σημεία πριν από το crossing event.

Horizon	N	Pos	ROC-AUC	Acc@0.5	F1@0.5	Precision	Recall
ETC0_5	684	180	0.8927	0.8480	0.7111	0.7111	0.7111
ETC1	664	174	0.8881	0.8464	0.7151	0.6957	0.7356
ETC2	603	159	0.8780	0.8342	0.7059	0.6630	0.7547
ETC3	539	139	0.8752	0.8275	0.6990	0.6353	0.7770
ETC4	487	124	0.8460	0.8296	0.6982	0.6358	0.7742

Πίνακας 4.17: Horizon evaluation του KinFormer-GRU seg+depth με conservative gates.

Horizon	N	Pos	ROC-AUC	Acc@0.5	F1@0.5	Precision	Recall
ETC0_5	684	180	0.8953	0.8538	0.7253	0.7174	0.7333
ETC1	664	174	0.8875	0.8494	0.7175	0.7056	0.7299
ETC2	603	159	0.8784	0.8292	0.6925	0.6591	0.7296
ETC3	539	139	0.8775	0.8386	0.7031	0.6688	0.7410
ETC4	487	124	0.8475	0.8275	0.6889	0.6370	0.7500

Πίνακας 4.18: Horizon evaluation του KinFormer-GRU seg+depth με open gates.



Σχήμα 4.7: Multi-horizon σύγκριση ROC-AUC, F1 και Accuracy μεταξύ του PIPN και της ελαφριάς KinFormer-GRU (open gate) στο εύρος TTE = 0.5–4 s.

Το Σχήμα 4.7 συνοψίζει οπτικά τη σύγκριση μεταξύ του PIPN και της ελαφριάς KinFormer-GRU (open gate) στους πέντε χρονικούς ορίζοντες. Στον πιο κοντινό ορίζοντα (TTE≈0.5s) η KinFormer-GRU πετυχαίνει ελαφρώς υψηλότερο ROC-AUC από το PIPN (0.895 έναντι 0.883), ενώ από τον ορίζοντα του 1s και έπειτα το PIPN προηγείται, με τη μεγαλύτερη διαφορά στο 2s (0.908 έναντι 0.878). Και τα δύο μοντέλα παρουσιάζουν πτώ-

ση προς τα 4s, όπου η διαφορά στο ROC-AUC παραμένει μικρή (0.871 έναντι 0.848). Ως προς τα fixed-threshold μέτρα (F1, Accuracy), το PIPN διατηρεί μικρό αλλά σταθερό προβάδισμα σε όλους τους ορίζοντες.

Η εικόνα αυτή είναι συνεπής με την per-branch ανάλυση του Πίνακα 4.8: ο κινηματικός κλάδος είναι ιδιαίτερα ισχυρός σε κοντινούς ορίζοντες, όπου η κίνηση του πεζού είναι πιο καθοριστική, ενώ ο global context branch αποκτά μεγαλύτερη σημασία σε μεγαλύτερα TTE, όπου η πρόθεση είναι πιο ασαφής και η σκηνική πληροφορία πιο κρίσιμη. Το kinematic-anchored σχέδιο της KinFormer-GRU αποδίδει επομένως καλύτερα εκεί που κυριαρχεί η κινηματική και υπολείπεται εκεί που το βαρύτερο global context του PIPN προσφέρει πλεονέκτημα. Σημειώνεται ότι η KinFormer-GRU επιτυγχάνει αυτή τη συμπεριφορά με περίπου **6.8× λιγότερες παραμέτρους** (652,313 έναντι 4,417,834), γεγονός που αναδεικνύει το performance-efficiency trade-off ως τη βασική συνεισφορά της παραλλαγής.

4.6.5 PIPN mask-channel ablation

Για να εξεταστεί αν τα traffic-aware segmentation masks βοηθούν γενικά ή αν το όφελός τους συνδέεται ειδικά με την KinFormer-GRU, δημιουργήθηκε παραλλαγή του PIPN στην οποία το πλήρες semantic embedding αντικαταστάθηκε από τα έξι traffic-aware mask channels. Κατά τα υπόλοιπα, η αρχιτεκτονική διατηρήθηκε όσο το δυνατόν πιο κοντά στο αρχικό PIPN.

Model	Semantic input	ROC-AUC	F1	Accuracy
PIPn	Full semantic embeddings	0.900	0.7151	0.8239
PIPn + 6 mask channels	Traffic-aware masks	0.893	0.688	0.828

Πίνακας 4.19: PIPN mask channel ablation.

Τα αποτελέσματα δείχνουν ότι τα traffic-aware masks δεν βελτιώνουν το PIPN. Το αρχικό PIPN με full semantic embeddings παραμένει καλύτερο ως προς ROC-AUC και F1. Το εύρημα αυτό είναι σημαντικό, επειδή δείχνει ότι η χρησιμότητα μιας αναπαράστασης εξαρτάται από την αρχιτεκτονική στην οποία εισάγεται.

Στο PIPN, ο Conv3D global branch φαίνεται να μπορεί να αξιοποιήσει αποτελεσματικά την πλήρη semantic αναπαράσταση. Αντίθετα, στο token-based KinFormer-GRU, η πιο συμπιεσμένη και traffic-aware αναπαράσταση είναι πιο κατάλληλη, πιθανώς επειδή μειώνει τον θόρυβο από άσχετες semantic κατηγορίες και παρέχει καθαρότερα contextual tokens.

4.7 Σύνοψη Αποτελεσμάτων

Στο παρόν κεφάλαιο παρουσιάστηκε η πειραματική αξιολόγηση της προτεινόμενης αρχιτεκτονικής PIPN για το πρόβλημα πρόβλεψης πρόθεσης διάσχισης πεζών. Η αξιολόγηση κάλυψε τόσο την κύρια απόδοση στο PIE benchmark όσο και τη συμπεριφορά του

μοντέλου σε διαφορετικούς χρονικούς ορίζοντες, τη σταθερότητα εκπαίδευσης, τη συνεισφορά των επιμέρους κλάδων και την ικανότητα cross-dataset γενίκευσης.

Αρχικά, η προτεινόμενη αρχιτεκτονική εμφάνισε ισχυρή απόδοση στο PIE benchmark. Στο πρωτόκολλο multi-horizon evaluation, το μοντέλο πέτυχε τη μέγιστη τιμή του στο $TTE \approx 2.0s$, με $ROC-AUC = 0.908$, ενώ διατήρησε υψηλή διαχωριστική ικανότητα σε ολόκληρο το εύρος $TTE = 0.5 - 4.0s$. Ακόμη και στον μακρύτερο ορίζοντα $TTE \approx 4.0s$, ο οποίος βρίσκεται εκτός του εύρους εκπαίδευσης, η απόδοση παρέμεινε σημαντικά υψηλότερη από την τυχαία πρόβλεψη, με $ROC-AUC = 0.871$. Το αποτέλεσμα αυτό υποδηλώνει ότι το μοντέλο δεν περιορίζεται αποκλειστικά στο εύρος $TTE \in [1.0, 2.0] s$ όπου εκπαιδεύτηκε, αλλά παρουσιάζει ικανότητα χρονικής γενίκευσης.

Η σύγκριση με τη βιβλιογραφία έδειξε ότι το PIPN τοποθετείται ανταγωνιστικά, ιδιαίτερα υπό την οπτική του κύριου σχεδιαστικού στόχου της εργασίας, δηλαδή την έγκαιρη πρόβλεψη σε χρονικό εύρος $TTE = 1 - 2s$. Στον ορίζοντα $TTE \approx 0.5s$, που αποτελεί εκτός κατανομής αξιολόγηση για το προτεινόμενο μοντέλο, η απόδοση παραμένει υψηλή αλλά υπολείπεται ορισμένων πρόσφατων αρχιτεκτονικών που έχουν βελτιστοποιηθεί ή αξιολογηθεί κυρίως σε αυτόν τον κοντινό ορίζοντα. Αντίθετα, στους ορίζοντες $TTE \approx 1.0s$ και $TTE \approx 2.0s$, το μοντέλο εμφανίζει ισχυρή διαχωριστική ικανότητα και καλύτερη αντιστοίχιση με τον early-warning χαρακτήρα της εργασίας.

Σε επίπεδο σταθερότητας, η αρχιτεκτονική παρουσίασε χαμηλή ευαισθησία στην τυχαία αρχικοποίηση. Οι πέντε ανεξάρτητες εκπαιδεύσεις με διαφορετικά random seeds εμφάνισαν μικρή διακύμανση στο test ROC-AUC, γεγονός που δείχνει ότι η τελική απόδοση δεν εξαρτάται έντονα από στοχαστικούς παράγοντες εκπαίδευσης. Παράλληλα, η temporal jitter analysis έδειξε ότι οι προβλέψεις του μοντέλου παραμένουν χρονικά ομαλές σε διαδοχικά παράθυρα του ίδιου πεζού, ιδιότητα ιδιαίτερα σημαντική για εφαρμογές αυτόνομης οδήγησης όπου απαιτούνται σταθερές και μη ταλαντευόμενες αποφάσεις.

Η ανάλυση συσχέτισης σφαλμάτων έδειξε ότι οι επιμέρους κλάδοι της αρχιτεκτονικής μαθαίνουν συμπληρωματικές πληροφορίες. Ιδιαίτερα χαμηλή συσχέτιση παρατηρήθηκε μεταξύ του global context branch και των pedestrian-centric branches, γεγονός που υποδηλώνει ότι το scene-level context παρέχει διαφορετικό είδος πληροφορίας από την κινηματική και την τοπική οπτική περιγραφή του πεζού. Το εύρημα αυτό εξηγεί εν μέρει τη σταθερότητα και την ευρωστία του fused μοντέλου, καθώς η τελική πρόβλεψη δεν βασίζεται σε μία μόνο πηγή πληροφορίας.

Η μελέτη αφαίρεσης κλάδων ανέδειξε σαφή χρονική εξειδίκευση των επιμέρους branches. Στους κοντινούς χρονικούς ορίζοντες, η αφαίρεση του local visual branch προκαλεί τη μεγαλύτερη πτώση ROC-AUC, δείχνοντας ότι η τοπική οπτική πληροφορία γύρω από τον πεζό δεν αναπληρώνεται εύκολα από τους υπόλοιπους κλάδους. Αντίθετα, στους μεγαλύτερους χρονικούς ορίζοντες, η μη-αντικαταστήσιμη συνεισφορά μετατοπίζεται προς τον global context branch. Η επίδραση της αφαίρεσης του global branch αυξάνεται από 0.020 στο $TTE \approx 0.5s$ σε 0.072 στο $TTE \approx 4.0s$, ενώ η αντίστοιχη επίδραση του kinematic branch μειώνεται. Το αποτέλεσμα αυτό δείχνει ότι η πολυκλαδική δομή της αρχιτεκτονικής είναι ουσιαστική: διαφορετικές πηγές πληροφορίας είναι χρήσιμες σε διαφορετικούς χρονικούς ορίζοντες.

Η post-hoc logit fusion εξετάστηκε ως ελαφριά ensemble-like τεχνική σε επίπεδο εξόδων, χωρίς επανεκπαίδευση του μοντέλου. Η μέθοδος προσέφερε μικρή βελτίωση στο

aggregate test set $TTE \in [1.0, 2.0]$ s, αυξάνοντας το ROC-AUC από 0.887 σε 0.896 και το F1-score από 0.696 σε 0.707. Ωστόσο, η βελτίωση αυτή δεν διατηρήθηκε σταθερά όταν η ίδια στρατηγική αξιολογήθηκε ξεχωριστά στους επιμέρους χρονικούς ορίζοντες. Συνεπώς, η post-hoc fusion ερμηνεύεται ως διαγνωστικό πείραμα που δείχνει ότι τα auxiliary heads περιέχουν πρόσθετη πληροφορία, αλλά δεν υποκαθιστά τη δυναμική προσαρμογή που παρέχει ο attention-based fusion μηχανισμός.

Τέλος, η cross-dataset αξιολόγηση ανέδειξε έναν σαφή συμβιβασμό μεταξύ εξειδίκευσης και γενίκευσης. Η PIE-only στρατηγική πέτυχε την υψηλότερη απόδοση στο PIE test set, αλλά παρουσίασε περιορισμένη μεταφορά στο JAAD. Αντίθετα, η Combined JAAD+PIE στρατηγική πέτυχε την καλύτερη απόδοση στο JAAD test set, με ROC-AUC=0.635, έναντι 0.543 του PIE-only μοντέλου, με περιορισμένο κόστος στην απόδοση στο PIE. Το αποτέλεσμα αυτό δείχνει ότι η κοινή εκπαίδευση σε πολλαπλές κατανομές δεδομένων μπορεί να οδηγήσει σε πιο γενικεύσιμες αναπαραστάσεις. Παράλληλα, η per-branch ανάλυση στο JAAD έδειξε ότι ο global context branch είναι το πιο μεταβιβάσιμο συστατικό της αρχιτεκτονικής, αυξάνοντας το ROC-AUC από 0.579 σε 0.674 στη μετάβαση από PIE-only σε Combined training.

Πέρα από το κύριο PIPN, το κεφάλαιο διερεύνησε Transformer-based παραλλαγές για τον global context branch. Η απλή αντικατάσταση του Conv3D global branch από έναν ανεξάρτητο Spatial-Patch Transformer μείωσε σημαντικά τις παραμέτρους (2.08M έναντι 4.42M), αλλά συνοδεύτηκε από πτώση του ROC-AUC (0.860 έναντι 0.900). Το εύρημα αυτό ανέδειξε ότι η χρησιμότητα του Transformer εξαρτάται από τον τρόπο εισαγωγής του: ένας ανεξάρτητος Transformer branch δεν αρκεί για να διατηρηθεί η απόδοση του πολυτροπικού μοντέλου.

Με βάση αυτή την παρατήρηση αναπτύχθηκε η ελαφριά KinFormer-GRU, όπου ο GRU κινηματικός κλάδος διατηρείται ως anchor και τα scene modalities εισάγονται ως gated contextual tokens χωρίς ανεξάρτητη late-fusion ψήφο. Σε anchor-only μορφή το μοντέλο πέτυχε ROC-AUC 0.870, κοντά στην ανεξάρτητη απόδοση του κινηματικού κλάδου του PIPN, επιβεβαιώνοντας ότι η αρχιτεκτονική δεν αποδυναμώνει το κινηματικό σήμα. Η σταδιακή προσθήκη modalities έδειξε ότι δεν συνεισφέρουν όλα εξίσου: το categorical depth ήταν το ισχυρότερο μεμονωμένο contextual σήμα (0.879), τα traffic-aware masks αποδείχθηκαν χρησιμότερα από τα πλήρη semantic embeddings, ενώ το optical flow και το local context δεν πρόσθεσαν αξιοποιήσιμη πληροφορία πέρα από το ήδη ισχυρό κινηματικό σήμα. Ο καλύτερος ισορροπημένος συνδυασμός ήταν segmentation masks + categorical depth, με ROC-AUC 0.887 και βελτιωμένα fixed-threshold μέτρα (F1 έως 0.728, Accuracy έως 0.854 στη ρύθμιση open gate), όπου η αρχικοποίηση των gates επηρέασε κυρίως τη συμπεριφορά στο σταθερό κατώφλι και όχι το συνολικό ranking.

Στο multi-horizon πρωτόκολλο, η KinFormer-GRU εμφάνισε συμπληρωματικό προφίλ προς το PIPN: στον πιο κοντινό ορίζοντα ($TTE \approx 0.5s$) πέτυχε ελαφρώς υψηλότερο ROC-AUC (0.895 έναντι 0.883), ενώ από τα 2s και έπειτα το PIPN προηγείτο χάρη στο βαρύτερο global context branch (0.908 έναντι 0.878 στο 2s, με σύγκλιση προς τα 4s). Η συμπεριφορά αυτή είναι συνεπής με τη χρονική εξειδίκευση των κλάδων που τεκμηριώθηκε στην Ενότητα 4.4. Το σημαντικότερο εύρημα είναι ότι η KinFormer-GRU πετυχαίνει ROC-AUC συγκρίσιμο με τον multi-seed μέσο όρο του PIPN (0.887) χρησιμοποιώντας περίπου $6.8 \times$ λιγότερες παραμέτρους (652K έναντι 4.42M), αναδεικνύοντας ένα ευνοϊκό

performance-efficiency trade-off. Δεδομένου ότι οι KinFormer-GRU παραλλαγές αξιολογήθηκαν ως single-seed, οι μικρές διαφορές ερμηνεύονται με προσοχή.

Τέλος, η αντικατάσταση των πλήρων semantic embeddings από traffic-aware masks στο ίδιο το PIPN δεν βελτίωσε την απόδοσή του (0.893 έναντι 0.900), σε αντίθεση με ό,τι παρατηρήθηκε στην KinFormer-GRU. Το εύρημα αυτό υπογραμμίζει ότι η χρησιμότητα μιας αναπαράστασης δεν είναι απόλυτη, αλλά εξαρτάται από την αρχιτεκτονική στην οποία εισάγεται: ο Conv3D branch του PIPN αξιοποιεί αποτελεσματικά την πλήρη semantic πληροφορία, ενώ το token-based KinFormer-GRU ωφελείται από μια πιο συμπιεσμένη, traffic-aware αναπαράσταση.

Συνολικά, τα αποτελέσματα επιβεβαιώνουν την αξία της προτεινόμενης πολυκλαδικής αρχιτεκτονικής για την πρόβλεψη πρόθεσης διάσχισης πεζών. Το PIPN συνδυάζει ισχυρή απόδοση στο κύριο PIE benchmark, σταθερή συμπεριφορά σε διαφορετικούς χρονικούς ορίζοντες, ερμηνεύσιμη συνεισφορά κλάδων και τεκμηριωμένη δυνατότητα cross-dataset γενίκευσης. Ταυτόχρονα, τα αποτελέσματα αναδεικνύουν και τους βασικούς περιορισμούς της προσέγγισης: η απόδοση επηρεάζεται από τη διαθεσιμότητα χαρακτηριστικών όπως η ταχύτητα του ego-vehicle, από το μέγεθος και τη δομή των datasets. Παράλληλα, η διερεύνηση των Transformer-based παραλλαγών ανέδειξε ότι μια ελαφριά, kinematic-anchored αρχιτεκτονική (KinFormer-GRU) μπορεί να προσεγγίσει την απόδοση του PIPN με σημαντικά λιγότερες παραμέτρους, προσφέροντας μια ελπιδοφόρα κατεύθυνση για εφαρμογές με περιορισμένους υπολογιστικούς πόρους.

Κεφάλαιο 5 Συμπεράσματα και Μελλοντικές Επεκτάσεις

5.1 Ανακεφαλαίωση της Εργασίας

Η παρούσα εργασία ασχολήθηκε με το πρόβλημα της πρόβλεψης πρόθεσης διάσχισης πεζού σε περιβάλλοντα αυτόνομης οδήγησης. Το πρόβλημα διατυπώθηκε ως δυαδική ταξινόμηση crossing/non-crossing σε χρονικό παράθυρο πριν από το πιθανό συμβάν διάσχισης. Η έννοια της πρόθεσης χρησιμοποιήθηκε με επιχειρησιακό τρόπο: το μοντέλο δεν επιχειρεί να προβλέψει άμεσα μια εσωτερική ψυχολογική κατάσταση του πεζού, αλλά να εκτιμήσει, με βάση πολυτροπικές παρατηρήσεις προηγούμενων frames, αν ο πεζός είναι πιθανό να διασχίσει τον δρόμο.

Για την αντιμετώπιση του προβλήματος σχεδιάστηκε και αξιολογήθηκε η πολυκλαδική αρχιτεκτονική PIPN. Η αρχιτεκτονική βασίζεται στην υπόθεση ότι η πρόθεση διάσχισης δεν μπορεί να εκτιμηθεί αξιόπιστα από μία μόνο κατηγορία χαρακτηριστικών. Για τον λόγο αυτό, συνδυάζει κινηματική πληροφορία, τοπικά οπτικά χαρακτηριστικά, τοπική κίνηση μέσω optical flow, σημασιολογική κατανόηση της σκηνής και γεωμετρική πληροφορία μέσω categorical depth.

Η μεθοδολογία οργανώθηκε σε δύο στάδια. Στο πρώτο στάδιο, εφαρμόστηκε offline preprocessing με χρήση σύγχρονων perception modules, όπως RAFT για optical flow, Mask2Former για panoptic segmentation και ManyDepth για monocular depth estimation. Τα παραγόμενα χαρακτηριστικά αποθηκεύτηκαν σε μορφή NPZ και αποτέλεσαν τις εισόδους του μοντέλου. Στο δεύτερο στάδιο, το PIPN εκπαιδεύτηκε πάνω σε αυτά τα προϋπολογισμένα χαρακτηριστικά, επιτρέποντας αποδοτική εκπαίδευση, αναπαραγωγή πειράματα και δίκαιη σύγκριση μεταξύ διαφορετικών εκδόσεων της αρχιτεκτονικής.

Η κύρια υλοποίηση της εργασίας βασίστηκε σε Conv3D-based global context branch και Conv3D-based local motion stream. Παράλληλα, παρουσιάστηκαν ως πειραματικές παραλλαγές δύο Transformer-based εκδοχές του global context branch, οι οποίες μπορούν να αξιολογηθούν μελλοντικά ως εναλλακτικές στρατηγικές μοντελοποίησης του scene context.

5.2 Κύρια Πειραματικά Ευρήματα

Τα πειραματικά αποτελέσματα στο PIE benchmark έδειξαν ότι το προτεινόμενο PIPN επιτυγχάνει ισχυρή απόδοση στο πρόβλημα της πρόβλεψης πρόθεσης διάσχισης. Στο multi-horizon evaluation, το μοντέλο παρουσίασε μέσο ROC-AUC 0.8917 σε πέντε χρονικούς ορίζοντες και μέγιστη απόδοση στο $TTE \approx 2.0s$, με ROC-AUC 0.908. Η απόδοση παρέμεινε υψηλή ακόμη και σε χρονικούς ορίζοντες εκτός του εύρους εκπαίδευσης, όπως στο $TTE \approx 4.0s$, όπου το μοντέλο πέτυχε ROC-AUC 0.871. Το αποτέλεσμα αυτό δείχνει ότι η αρχιτεκτονική δεν περιορίζεται αποκλειστικά στο TTE εύρος στο οποίο εκπαιδεύτηκε, αλλά παρουσιάζει ικανότητα χρονικής γενίκευσης.

Η σύγκριση με τη βιβλιογραφία έδειξε ότι το PIPN τοποθετείται ανταγωνιστικά, ειδικά όταν αξιολογείται υπό το πρίσμα του κύριου σχεδιαστικού στόχου της εργασίας: την

έγκαιρη πρόβλεψη σε χρονικούς ορίζοντες $TTE \approx 1.0-2.0s$. Στο $TTE \approx 0.5s$, το οποίο αντιμετωπίζεται στην παρούσα εργασία ως εκτός κατανομής αξιολόγηση, το μοντέλο παραμένει ισχυρό αλλά υπολείπεται ορισμένων πρόσφατων αρχιτεκτονικών που έχουν βελτιστοποιηθεί ή αξιολογηθεί κυρίως σε αυτόν τον κοντινό ορίζοντα. Αντίθετα, στο $TTE \approx 2.0s$ επιτυγχάνει ROC-AUC 0.908, το οποίο είναι ιδιαίτερα σημαντικό για early-warning σενάρια, όπου απαιτείται μεγαλύτερος διαθέσιμος χρόνος αντίδρασης.

Επιπλέον, η αρχιτεκτονική παρουσίασε σταθερότητα ως προς την τυχαία αρχικοποίηση: οι πέντε ανεξάρτητες εκπαιδεύσεις είχαν μέσο Test ROC-AUC 0.8870 και τυπική απόκλιση 0.0106. Η temporal jitter analysis έδειξε επίσης ότι οι προβλεπόμενες πιθανότητες παραμένουν χρονικά ομαλές σε διαδοχικά παράθυρα του ίδιου πεζού, με $\sigma(P)=0.055$ και $|\Delta P|=0.073$, ιδιότητα κρίσιμη για εφαρμογές αυτόνομης οδήγησης.

Παράλληλα με το κύριο PIPN, η διερεύνηση των Transformer-based παραλλαγών οδήγησε σε ένα δεύτερο σημαντικό εύρημα. Η απλή αντικατάσταση του Conv3D global branch από έναν ανεξάρτητο Spatial-Patch Transformer μείωσε τις παραμέτρους (2.08M έναντι 4.42M) αλλά μείωσε και το ROC-AUC (0.860 έναντι 0.900), δείχνοντας ότι ο τρόπος εισαγωγής του Transformer είναι κρίσιμος. Η ελαφριά KinFormer-GRU, που διατηρεί τον κινηματικό κλάδο ως anchor και εισάγει τα scene modalities ως gated contextual tokens, πέτυχε με τον συνδυασμό segmentation masks + categorical depth ROC-AUC 0.887, συγκρίσιμο με τον multi-seed μέσο όρο του PIPN (0.887), χρησιμοποιώντας περίπου **6.8× λιγότερες παραμέτρους** (652K έναντι 4.42M). Στο multi-horizon πρωτόκολλο εμφάνισε συμπληρωματικό προφίλ προς το PIPN, με ελαφρώς υψηλότερο ROC-AUC στον κοντινότερο ορίζοντα (0.895 έναντι 0.883 στο $TTE \approx 0.5s$) και μικρή υστέρηση στους μεγαλύτερους ορίζοντες. Δεδομένου ότι η KinFormer-GRU αξιολογήθηκε ως single-seed, τα ευρήματα αυτά παρουσιάζονται ως ενθαρρυντική ένδειξη ενός performance-efficiency trade-off και όχι ως απόδειξη υπεροχής.

5.3 Ερμηνεία της Πολυκλαδικής Αρχιτεκτονικής

Ένα από τα βασικά συμπεράσματα είναι ότι η πολυκλαδική σχεδίαση του PIPN δεν αποτελεί απλώς αρχιτεκτονική πολυπλοκότητα, αλλά εξυπηρετεί ουσιαστικό ρόλο. Η ανάλυση των auxiliary heads έδειξε ότι κάθε κλάδος εμφανίζει διαφορετικό προφίλ απόδοσης ανάλογα με τον χρονικό ορίζοντα.

Ο kinematic branch είναι ιδιαίτερα ισχυρός στους κοντινούς ορίζοντες (ROC-AUC 0.880 στο $TTE \approx 0.5s$, σχεδόν ίσο με το fused μοντέλο), αλλά η απόδοσή του μειώνεται όσο αυξάνεται το TTE (0.798 στο $TTE \approx 4.0s$). Τα κινηματικά χαρακτηριστικά είναι δηλαδή ιδιαίτερα χρήσιμα όταν η πρόθεση έχει αρχίσει να εκδηλώνεται, αλλά λιγότερο επαρκή για πρώιμες προβλέψεις. Αντίθετα, ο global context branch παρουσίασε αυξανόμενη χρησιμότητα σε μεγαλύτερα TTE (από 0.741 στο $TTE \approx 0.5s$ σε 0.819 στο $TTE \approx 2.0s$), υποδεικνύοντας ότι η πληροφορία της σκηνης αποκτά σημασία όταν τα άμεσα κινηματικά σήματα δεν είναι ακόμη σαφή.

Η branch-zeroing ablation επιβεβαίωσε τη χρονική εξειδίκευση: στους κοντινούς ορίζοντες η αφαίρεση του local visual branch είχε τη μεγαλύτερη επίδραση, ενώ στους μακρύτερους η μεγαλύτερη πτώση προέκυψε από την αφαίρεση του global context branch (Δ ROC-AUC από 0.020 στο $TTE \approx 0.5s$ σε 0.072 στο $TTE \approx 4.0s$). Η ανάλυση συσχέτισης

σφαλμάτων ενίσχυσε αυτή την εικόνα: οι χαμηλές συσχετίσεις του global branch με τους pedestrian-centric branches (ιδίως local-global με $r=0.088$) δείχνουν ότι οι κλάδοι μαθαίνουν διαφορετικές όψεις του προβλήματος, γεγονός που εξηγεί τη σταθερότητα του fused μοντέλου. Σημειώνεται ότι ακριβώς αυτό το εύρημα η ισχύς του κινηματικού κλάδου στους κοντινούς ορίζοντες αποτέλεσε το κίνητρο για τη σχεδίαση της KinFormer-GRU γύρω από έναν κινηματικό anchor.

5.4 Γενίκευση μεταξύ Datasets

Η cross-dataset αξιολόγηση ανέδειξε έναν σαφή συμβιβασμό μεταξύ εξειδίκευσης και γενίκευσης. Το PIE-only μοντέλο πέτυχε την καλύτερη απόδοση στο PIE test set (ROC-AUC 0.892, F1 0.729), αλλά στο JAAD η απόδοση μειώθηκε σημαντικά (ROC-AUC 0.543). Η στρατηγική JAAD→PIE transfer learning βελτίωσε το JAAD (από 0.543 σε 0.621) με κόστος στο PIE, ενώ η Combined στρατηγική πέτυχε την καλύτερη απόδοση στο JAAD (ROC-AUC 0.635, F1 0.613) διατηρώντας αποδεκτή απόδοση στο PIE.

Το αποτέλεσμα δείχνει ότι η κοινή εκπαίδευση σε διαφορετικές κατανομές μπορεί να οδηγήσει σε πιο γενικεύσιμες αναπαραστάσεις, αλλά και ότι η γενίκευση παραμένει δύσκολη λόγω διαφορών στη διαθεσιμότητα ego-vehicle speed, στη δομή των annotations και στην ποικιλία σκηνών. Ιδιαίτερο ενδιαφέρον έχει η per-branch ανάλυση: ο global context branch εμφάνισε τη μεγαλύτερη βελτίωση στο JAAD με Combined training (ROC-AUC από 0.579 σε 0.674), υποδεικνύοντας ότι τα scene-level χαρακτηριστικά είναι πιο μεταβιβάσιμα μεταξύ datasets από τα πιο dataset-specific κινηματικά ή τοπικά οπτικά μοτίβα.

5.5 Συνεισφορές της Εργασίας

Η **πρώτη** συνεισφορά είναι η ανακατασκευή και προσαρμογή ενός σύγχρονου πολυτροπικού pipeline για crossing intention prediction. Λόγω της μη πλήρους διαθεσιμότητας του αρχικού PIP-Net κώδικα και ορισμένων preprocessing components, το pipeline αναπτύχθηκε εξ αρχής, με σύγχρονα perception modules και πλήρως αναπαραγώγιμη διαδικασία παραγωγής χαρακτηριστικών.

Η **δεύτερη** συνεισφορά είναι η αναβάθμιση του preprocessing. Το FlowNet2 αντικαταστάθηκε από RAFT-large, ενώ το Slot-VPS από Mask2Former για panoptic segmentation και instance mask extraction. Η ιδέα του categorical depth διατηρήθηκε αλλά κατασκευάστηκε με τις νέες instance masks και την εκτίμηση βάθους μέσω ManyDepth, ενώ αναπτύχθηκε διορθωτικό βήμα ego-vehicle suppression για να μην εισάγει θόρυβο η ορατή περιοχή του καπό.

Η **τρίτη** συνεισφορά είναι ο ανασχεδιασμός του global context branch με learned Conv2D downsampling και thin-tower Conv3D σχεδίαση, που μειώνει το μνημονικό και υπολογιστικό κόστος επεξεργασίας semantic και categorical depth maps, διατηρώντας τη χωροχρονική δομή της σκηνής.

Η **τέταρτη** συνεισφορά είναι η κατασκευή δυσκολότερων αρνητικών δειγμάτων μέσω των human intention reference scores του PIE. Αντί για τυχαία non-crossing windows, αξιοποιήθηκαν περιοχές με υψηλότερο intention score, δημιουργώντας hard

negatives που φέρνουν το task πιο κοντά στην εκτίμηση πρόθεσης.

Η **πέμπτη** συνεισφορά είναι η εκτενής ανάλυση της αρχιτεκτονικής: σταθερότητα μεταξύ seeds, temporal jitter, per-branch απόδοση, error correlation, branch-zeroing ablations, post-hoc fusion και cross-dataset transferability, παρέχοντας πιο πλήρη εικόνα του πώς λειτουργεί η αρχιτεκτονική και όχι μόνο του πόσο καλά αποδίδει σε μία μετρική.

Η **έκτη** συνεισφορά είναι η σχεδίαση και αξιολόγηση της ελαφριάς KinFormer-GRU. Αντί ο Transformer να λειτουργεί ως ανεξάρτητος global branch, ο κινηματικός κλάδος διατηρείται ως anchor και τα scene modalities (traffic-aware segmentation masks, categorical depth κ.ά.) εισάγονται ως gated contextual tokens χωρίς ανεξάρτητη late-fusion ψήφο. Η αρχιτεκτονική αυτή πετυχαίνει ROC-AUC συγκρίσιμο με τον μέσο όρο του PIPN με περίπου $6.8\times$ λιγότερες παραμέτρους, αναδεικνύοντας ένα ευνοϊκό performance-efficiency trade-off και προσφέροντας μια κατεύθυνση για περιβάλλοντα με περιορισμένους πόρους.

5.6 Περιορισμοί

1. Τα perception modules εκτελούνται offline και όχι σε πραγματικό χρόνο. Αυτό επιτρέπει καθαρή και αναπαραγώγιμη αξιολόγηση, αλλά δεν αποδεικνύει ακόμη ότι ολόκληρο το pipeline μπορεί να λειτουργήσει online σε πραγματικό όχημα.
2. Η ποιότητα των εισόδων εξαρτάται από frozen perception models. Λάθη στο optical flow, στο segmentation, στο pose ή στο depth estimation μπορούν να μεταφερθούν στο downstream μοντέλο — όπως φάνηκε στην περίπτωση του ego-vehicle hood artifact. Ειδικά το categorical depth προέρχεται από monocular depth estimation, η οποία είναι εγγενώς θορυβώδης.
3. Η σύγκριση με τη βιβλιογραφία δεν είναι πλήρως ισοδύναμη, λόγω διαφορών σε TTE/ETC πρωτόκολλα, στρατηγικές δειγματοληψίας, splits, augmentations και feature extraction pipelines. Τα αποτελέσματα ερμηνεύονται ως σχετική τοποθέτηση και όχι ως απόλυτη αριθμητική ισοδυναμία.
4. Η cross-dataset αξιολόγηση επηρεάζεται από τη μη ισοδυναμία PIE και JAAD (απουσία ισοδύναμης ego-vehicle speed, μικρότερο μέγεθος, διαφορετικά annotations). Η χαμηλότερη απόδοση στο JAAD αντανakλά κυρίως ισχυρό domain shift και όχι αποκλειστικά αδυναμία της αρχιτεκτονικής.
5. Η αρχιτεκτονική είναι pedestrian-centric και εκτιμά την πρόθεση ενός πεζού τη φορά, χωρίς να μοντελοποιεί ρητά τις αλληλεπιδράσεις μεταξύ πολλών πεζών. Σε πυκνές σκηνές με αλληλοεπικαλυπτόμενους πεζούς, η εκτίμηση γίνεται δυσκολότερη και λιγότερο αξιόπιστη, όπως παρατηρήθηκε και κατά την ποιοτική αξιολόγηση.

5.7 Μελλοντικές Επεκτάσεις

Μία άμεση μελλοντική επέκταση αφορά την περαιτέρω ενίσχυση της ελαφριάς KinFormer-GRU. Ιδιαίτερο ενδιαφέρον παρουσιάζει η ρητή γεωμετρική σύνδεση μεταξύ

του bounding box και των scene patches π.χ. μέσω ROI-based gather ή ένδειξης του grid-cell στο οποίο βρίσκεται ο πεζός ώστε η αντιστοίχιση κινηματικής θέσης και περιοχής σκηνής να μην βασίζεται αποκλειστικά στο attention. Επιπλέον, καθώς το optical flow και το local context δεν πρόσθεσαν αξιοποιήσιμη πληροφορία με τον τρέχοντα τρόπο εισαγωγής τους, μελλοντική εργασία μπορεί να διερευνήσει εναλλακτικούς τρόπους ενσωμάτωσής τους ως contextual tokens.

Δεύτερη επέκταση είναι η ενσωμάτωση μηχανισμών uncertainty estimation. Σε πραγματικές εφαρμογές αυτόνομης οδήγησης, δεν αρκεί το μοντέλο να προβλέπει crossing probability· είναι επίσης σημαντικό να γνωρίζει πότε η πρόβλεψη είναι αβέβαιη. Μέθοδοι όπως evidential learning, Monte Carlo dropout ή temperature calibration θα μπορούσαν να προσφέρουν πιο αξιόπιστη εκτίμηση κινδύνου.

Τρίτη επέκταση είναι η ανάπτυξη online pipeline. Η παρούσα εργασία βασίστηκε σε offline feature extraction, αλλά ένα deployment-oriented σύστημα θα πρέπει να λειτουργεί σε πραγματικό χρόνο. Αυτό απαιτεί βελτιστοποίηση των perception modules, πιθανή αντικατάσταση βαριών components με ελαφρύτερες εκδόσεις και αξιολόγηση latency σε πραγματικό hardware. Μια επιπλέον μελλοντική κατεύθυνση αφορά την ενσωμάτωση πρόσθετων αισθητήρων, και ιδιαίτερα LiDAR. Στην παρούσα εργασία, η γεωμετρική πληροφορία της σκηνής και συγκεκριμένα το categorical depth προέρχεται από monocular depth estimation, η οποία είναι εγγενώς θορυβώδης και ευαίσθητη σε σφάλματα, ιδίως για απομακρυσμένα ή μερικώς αποκρυμμένα αντικείμενα. Η αξιοποίηση ενός LiDAR αισθητήρα θα μπορούσε να προσφέρει άμεσες και πιο αξιόπιστες μετρήσεις βάθους και απόστασης, βελτιώνοντας την ποιότητα του categorical depth και, κατ' επέκταση, την απόδοση του global context branch. Παράλληλα, ο συνδυασμός κάμερας και LiDAR μέσω sensor fusion θα μπορούσε να ενισχύσει τόσο τη γεωμετρική ακρίβεια όσο και την ευρωστία του συστήματος σε δύσκολες συνθήκες, όπως χαμηλός φωτισμός ή νυχτερινές σκηνές, όπου η εκτίμηση βάθους από μία μόνο κάμερα είναι λιγότερο αξιόπιστη.

Τέταρτη επέκταση αφορά τη βελτίωση της cross-dataset γενίκευσης. Τα αποτελέσματα έδειξαν ότι το Combined training βοηθά τη μεταφορά στο JAAD, αλλά η απόδοση παραμένει περιορισμένη. Μελλοντικές εργασίες μπορούν να εξετάσουν domain adaptation, domain-invariant feature learning, adversarial training ή dataset-specific calibration. Επιπλέον, η χρήση περισσότερων datasets, όπως TITAN ή άλλα urban driving datasets, θα μπορούσε να βοηθήσει στην εκπαίδευση πιο γενικεύσιμων representations.

Πέμπτη επέκταση είναι η ενσωμάτωση temporal consistency losses. Η temporal jitter analysis έδειξε ότι το μοντέλο έχει ήδη σχετικά ομαλές προβλέψεις. Ωστόσο, η χρονική σταθερότητα θα μπορούσε να ενισχυθεί ρητά μέσω loss όρων που τιμωρούν απότομες μεταβολές πιθανότητας σε διαδοχικά παράθυρα του ίδιου pedestrian track.

Τέλος, θα ήταν χρήσιμη η λεπτομερέστερη ανάλυση των failure cases. Η εργασία ανέδειξε τη σημασία των διαφορετικών branches, αλλά μελλοντική ανάλυση θα μπορούσε να εξετάσει κατηγορίες αποτυχιών όπως occlusions, μικροί ή μακρινοί πεζοί, έντονη κίνηση κάμερας, ασυνήθιστες στάσεις σώματος, νυχτερινές σκηνές και περιπτώσεις όπου το global context παραπλανά το μοντέλο.

5.8 Τελικό Συμπέρασμα

Συνολικά, η παρούσα εργασία έδειξε ότι η πρόβλεψη πρόθεσης διάσχισης πεζού ωφελείται από πολυτροπική και πολυκλαδική μοντελοποίηση. Το PIPN συνδυάζει κινηματικά, τοπικά οπτικά, χαρακτηριστικά κίνησης και καθολική πληροφορία σκηνής, επιτυγχάνοντας ισχυρή απόδοση στο PIE benchmark και σταθερή συμπεριφορά σε πολλαπλούς χρονικούς ορίζοντες.

Τα αποτελέσματα δείχνουν ότι κανένας κλάδος δεν είναι εξίσου κατάλληλος για όλους τους χρονικούς ορίζοντες. Η κινηματική πληροφορία είναι ιδιαίτερα ισχυρή κοντά στη διάσχιση, η τοπική οπτική πληροφορία παρέχει χρήσιμες pedestrian-centric ενδείξεις, ενώ το καθολικό context γίνεται σημαντικότερο όσο η πρόβλεψη ζητείται νωρίτερα. Η συνδυαστική αξιοποίησή τους μέσω attention-based fusion οδηγεί σε πιο σταθερή και ερμηνεύσιμη πρόβλεψη.

Παράλληλα, η διερεύνηση των Transformer-based παραλλαγών έδειξε ότι ο τρόπος εισαγωγής του Transformer είναι καθοριστικός. Η απλή αντικατάσταση του Conv3D global branch με ανεξάρτητο Transformer μείωσε τις παραμέτρους αλλά όχι χωρίς κόστος στην απόδοση. Αντίθετα, η KinFormer-GRU, η οποία διατηρεί τον κινηματικό κλάδο ως anchor και εισάγει επιλεγμένο scene context μέσω gated contextual tokens, προσφέρει ένα ευνοϊκό performance-efficiency trade-off και αποτελεί υποσχόμενη κατεύθυνση για πιο ελαφριά συστήματα.

Η τελική εικόνα είναι ότι το PIPN αποτελεί μια ισχυρή, ερμηνεύσιμη και επεκτάσιμη βάση για την εκτίμηση πρόθεσης διάσχισης. Παρότι απαιτείται περαιτέρω εργασία για online λειτουργία, βελτίωση της cross-dataset γενίκευσης και πιο ακριβή γεωμετρική ευθυγράμμιση μεταξύ πεζού και σκηνής, τα αποτελέσματα δείχνουν ότι ο συνδυασμός pedestrian-centric και scene-level πληροφορίας αποτελεί ουσιαστική κατεύθυνση για ασφαλέστερα συστήματα αντίληψης σε αυτόνομα οχήματα.

Βιβλιογραφία

- [1] World Health Organization, 'Global status report on road safety 2018: Summary'. Ημερομηνία πρόσβασης: 26 Απρίλιος 2026. [Έκδοση σε ψηφιακή μορφή]. Διαθέσιμο στο: <https://www.who.int/publications/i/item/WHO-NMH-NVI-18.20>
- [2] A. Rasouli και J. K. Tsotsos, 'Autonomous Vehicles That Interact With Pedestrians: A Survey of Theory and Practice', *IEEE Trans. Intell. Transp. Syst.*, τ. 21, τχ. 3, σελ. 900–918, Μαρτίου 2020, doi: 10.1109/TITS.2019.2901817.
- [3] S. K. Jayaraman, L. P. Robert, X. J. Yang, και D. M. Tilbury, 'Multimodal Hybrid Pedestrian: A Hybrid Automaton Model of Urban Pedestrian Behavior for Automated Driving Applications', *IEEE Access*, τ. 9, σελ. 27708–27722, 2021, doi: 10.1109/ACCESS.2021.3058307.
- [4] M. Azarmi, M. Rezaei, H. Wang, και A. Arabian, 'Feature Importance in Pedestrian Intention Prediction: A Context-Aware Review', 11 Σεπτέμβριος 2024, *arXiv*: arXiv:2409.07645. doi: 10.48550/arXiv.2409.07645.
- [5] A. Rasouli, I. Kotseruba, T. Kunic, και J. Tsotsos, 'PIE: A Large-Scale Dataset and Models for Pedestrian Intention Estimation and Trajectory Prediction', στο *2019 IEEE/CVF International Conference on Computer Vision (ICCV)*, Οκτωβρίου 2019, σελ. 6261–6270. doi: 10.1109/ICCV.2019.00636.
- [6] 'Predicting Pedestrian Crossing Intention With Feature Fusion and Spatio-Temporal Attention | Request PDF', *ResearchGate*, doi: 10.1109/TIV.2022.3162719.
- [7] J. Gesnouin, S. Pechberti, B. Stanciulescu, και F. Moutarde, *Assessing Cross-dataset Generalization of Pedestrian Crossing Predictors*. 2022. doi: 10.48550/arXiv.2201.12626.
- [8] M. Azarmi, M. Rezaei, και H. Wang, 'PIP-Net: Pedestrian Intention Prediction in the Wild', *IEEE Trans. Intell. Transp. Syst.*, τ. 26, τχ. 7, σελ. 9824–9837, Ιουλίου 2025, doi: 10.1109/TITS.2025.3570794.
- [9] D. Feng κ.ά., 'Deep Multi-modal Object Detection and Semantic Segmentation for Autonomous Driving: Datasets, Methods, and Challenges', *arXiv.org*. Ημερομηνία πρόσβασης: 21 Μάιος 2026. [Έκδοση σε ψηφιακή μορφή]. Διαθέσιμο στο: <https://arxiv.org/abs/1902.07830v4>
- [10] A. Mirzabagheri, M. Ahmadi, N. Zhang, R. Alirezaee, S. Mozaffari, και S. Alirezaee, 'Navigating Uncertainty: Advanced Techniques in Pedestrian Intention Prediction for Autonomous Vehicles—A Comprehensive Review', *Vehicles*, τ. 7, τχ. 2, σελ. 57, Ιουνίου 2025, doi: 10.3390/vehicles7020057.
- [11] C. Zhang και C. Berger, 'Pedestrian Behavior Prediction Using Deep Learning Methods for Urban Scenarios: A Review', *IEEE Trans. Intell. Transp. Syst.*, τ. PP, σελ. 1–23, Οκτωβρίου 2023, doi: 10.1109/TITS.2023.3281393.
- [12] Z. Zhang, R. Tian, και Z. Ding, 'TrEP: Transformer-Based Evidential Prediction for Pedestrian Intention with Uncertainty', *Proc. AAAI Conf. Artif. Intell.*, τ. 37, τχ. 3, σελ. 3534–3542, Ιουνίου 2023, doi: 10.1609/aaai.v37i3.25463.
- [13] J.-S. Ham, D. H. Kim, N. Jung, και J. Moon, 'CIPF: Crossing Intention Prediction Network based on Feature Fusion Modules for Improving Pedestrian Safety', στο *2023 IEEE/CVF Conference on Computer Vision and Pattern Recognition Workshops (CVPRW)*, Vancouver, BC, Canada: IEEE, Ιουνίου 2023, σελ. 3666–3675. doi: 10.1109/CVPRW59228.2023.00374.
- [14] A. Rasouli, I. Kotseruba, και J. K. Tsotsos, 'Are They Going to Cross? A Benchmark Dataset and Baseline for Pedestrian Crosswalk Behavior', στο *2017 IEEE International Conference on Computer Vision Workshops (ICCVW)*, Οκτωβρίου 2017, σελ. 206–213. doi: 10.1109/ICCVW.2017.33.
- [15] S. Malla, B. Dariush, και C. Choi, 'TITAN: Future Forecast Using Action Priors', παρουσιάστηκε στο *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, 2020, σελ. 11186–11196. Ημερομηνία πρόσβασης: 22 Μάιος 2026. [Έκδοση σε ψηφιακή

- μορφή]. Διαθέσιμο στο:
https://openaccess.thecvf.com/content_CVPR_2020/html/Malla_TITAN_Future_Forecast_Using_Action_Priors_CVPR_2020_paper.html
- [16] N. Sharma, C. Dhiman, και S. Indu, 'Pedestrian Intention Prediction for Autonomous Vehicles: A Comprehensive Survey', *Neurocomputing*, τ. 508, σελ. 120–152, Οκτωβρίου 2022, doi: 10.1016/j.neucom.2022.07.085.
 - [17] Z. Fang και A. M. López, 'Is the Pedestrian going to Cross? Answering by 2D Pose Estimation', 15 Ιούλιος 2018, *arXiv*: arXiv:1807.10580. doi: 10.48550/arXiv.1807.10580.
 - [18] X. Song, M. Kang, S. Zhou, J. Wang, Y. Mao, και N. Zheng, 'Pedestrian Intention Prediction Based on Traffic-Aware Scene Graph Model', Οκτωβρίου 2022, σελ. 9851–9858. doi: 10.1109/IROS47612.2022.9981690.
 - [19] L. Achaji, J. Moreau, T. Fouqueray, F. Aioun, και F. Charpillet, 'Is attention to bounding boxes all you need for pedestrian action prediction?', στο *2022 IEEE Intelligent Vehicles Symposium (IV)*, Aachen, Germany: IEEE Press, Μαρτίου 2022, σελ. 895–902. doi: 10.1109/IV51971.2022.9827084.
 - [20] B. Liu κ.ά., 'Spatiotemporal Relationship Reasoning for Pedestrian Intent Prediction', 20 Φεβρουάριος 2020, *arXiv*: arXiv:2002.08945. doi: 10.48550/arXiv.2002.08945.
 - [21] B. Cheng, I. Misra, A. G. Schwing, A. Kirillov, και R. Girdhar, 'Masked-Attention Mask Transformer for Universal Image Segmentation', παρουσιάστηκε στο *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, 2022, σελ. 1290–1299. Ημερομηνία πρόσβασης: 27 Μάιος 2026. [Έκδοση σε ψηφιακή μορφή]. Διαθέσιμο στο:
https://openaccess.thecvf.com/content/CVPR2022/html/Cheng_Masked-Attention_Mask_Transformer_for_Universal_Image_Segmentation_CVPR_2022_paper.html
 - [22] M. Cordts κ.ά., 'The Cityscapes Dataset for Semantic Urban Scene Understanding', 7 Απρίλιος 2016, *arXiv*: arXiv:1604.01685. doi: 10.48550/arXiv.1604.01685.
 - [23] Z. Teed και J. Deng, 'RAFT: Recurrent All-Pairs Field Transforms for Optical Flow', 25 Αύγουστος 2020, *arXiv*: arXiv:2003.12039. doi: 10.48550/arXiv.2003.12039.
 - [24] J. Watson, O. M. Aodha, V. Prisacariu, G. Brostow, και M. Firman, 'The Temporal Opportunist: Self-Supervised Multi-Frame Monocular Depth', 14 Ιούλιος 2021, *arXiv*: arXiv:2104.14540. doi: 10.48550/arXiv.2104.14540.
 - [25] K. Cho κ.ά., 'Learning Phrase Representations using RNN Encoder-Decoder for Statistical Machine Translation', 3 Σεπτέμβριος 2014, *arXiv*: arXiv:1406.1078. doi: 10.48550/arXiv.1406.1078.
 - [26] D. Tran, L. Bourdev, R. Fergus, L. Torresani, και M. Paluri, 'Learning Spatiotemporal Features with 3D Convolutional Networks', 7 Οκτώβριος 2015, *arXiv*: arXiv:1412.0767. doi: 10.48550/arXiv.1412.0767.
 - [27] A. Vaswani κ.ά., 'Attention Is All You Need', 2 Αύγουστος 2023, *arXiv*: arXiv:1706.03762. doi: 10.48550/arXiv.1706.03762.
 - [28] 'Figure 6: ViT architecture The ViT [Dosovitskiy et al., 2021] marked a...', ResearchGate. Ημερομηνία πρόσβασης: 27 Μάιος 2026. [Έκδοση σε ψηφιακή μορφή]. Διαθέσιμο στο:
https://www.researchgate.net/figure/T-architecture-The-ViT-Dosovitskiy-et-al-2021-marked-a-significant-shift-in-computer_fig3_392162748
 - [29] A. Vaswani κ.ά., 'Attention Is All You Need', 2 Αύγουστος 2023, *arXiv*: arXiv:1706.03762. doi: 10.48550/arXiv.1706.03762.
 - [30] M. Riaz, M. Wielgosz, C. Xie, και A. López, *PedGT: Enhancing Pedestrian Intention Prediction Using a Skeleton-Based Graph-Transformer*. 2025. doi: 10.1109/IV64158.2025.11097602.
 - [31] Z. Zhang, R. Tian, και Z. Ding, 'TrEP: Transformer-Based Evidential Prediction for Pedestrian Intention with Uncertainty', *Proc. AAAI Conf. Artif. Intell.*, τ. 37, τχ. 3, σελ. 3534–3542, Ιουνίου 2023, doi: 10.1609/aaai.v37i3.25463.
 - [32] A. R. Elkammar, K. M. Gamaleldin, και C. M. Elias, 'ViT-Ped: Visionary Intention Transformer for Pedestrian Behavior Analysis', 5 Ιανουάριος 2026, *arXiv*: arXiv:2601.01989. doi: 10.48550/arXiv.2601.01989.

- [33] E. Ilg, N. Mayer, T. Saikia, M. Keuper, A. Dosovitskiy, και T. Brox, 'FlowNet 2.0: Evolution of Optical Flow Estimation With Deep Networks', παρουσιάστηκε στο Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition, 2017, σελ. 2462–2470. Ημερομηνία πρόσβασης: 27 Μάιος 2026. [Έκδοση σε ψηφιακή μορφή]. Διαθέσιμο στο: https://openaccess.thecvf.com/content_cvpr_2017/html/Ilg_FlowNet_2.0_Evolution_CVPR_2017_paper.html
- [34] G. Jocher, J. Qiu, και A. Chaurasia, *Ultralytics YOLO*. (Ιανουάριος 2023). Python. Ημερομηνία πρόσβασης: 27 Μάιος 2026. [Έκδοση σε ψηφιακή μορφή]. Διαθέσιμο στο: <https://github.com/ultralytics/ultralytics>
- [35] 'COCO keypoints (Lin et al., 2014) - Αναζήτηση Google'. Ημερομηνία πρόσβασης: 27 Μάιος 2026. [Έκδοση σε ψηφιακή μορφή]. Διαθέσιμο στο: <https://www.google.com/search?q=COCO+keypoints+%28Lin+et+al.%2C+2014%29&sourceid=chrome&ie=UTF-8>
- [36] K. Simonyan και A. Zisserman, 'Very Deep Convolutional Networks for Large-Scale Image Recognition', arXiv.org. Ημερομηνία πρόσβασης: 27 Μάιος 2026. [Έκδοση σε ψηφιακή μορφή]. Διαθέσιμο στο: <https://arxiv.org/abs/1409.1556v6>
- [37] 'ImageNet'. Ημερομηνία πρόσβασης: 27 Μάιος 2026. [Έκδοση σε ψηφιακή μορφή]. Διαθέσιμο στο: <https://www.image-net.org/>
- [38] A. Bhattacharyya, M. Fritz, και B. Schiele, *Long-Term On-Board Prediction of People in Traffic Scenes under Uncertainty*. 2017. doi: 10.48550/arXiv.1711.09026.
- [39] I. Kotseruba, A. Rasouli, και J. Tsotsos, 'Do They Want to Cross? Understanding Pedestrian Intention for Behavior Prediction', Οκτωβρίου 2020, σελ. 1688–1693. doi: 10.1109/IV47402.2020.9304591.
- [40] A. Rasouli, I. Kotseruba, και J. Tsotsos, *Pedestrian Action Anticipation using Contextual Feature Fusion in Stacked RNNs*. 2020. doi: 10.48550/arXiv.2005.06582.
- [41] I. Kotseruba, A. Rasouli, και J. K. Tsotsos, 'Benchmark for Evaluating Pedestrian Action Prediction', παρουσιάστηκε στο Proceedings of the IEEE/CVF Winter Conference on Applications of Computer Vision, 2021, σελ. 1258–1268. Ημερομηνία πρόσβασης: 27 Μάιος 2026. [Έκδοση σε ψηφιακή μορφή]. Διαθέσιμο στο: https://openaccess.thecvf.com/content/WACV2021/html/Kotseruba_Benchmark_for_Evaluating_Pedestrian_Action_Prediction_WACV_2021_paper.html
- [42] J. Lorenzo κ.ά., 'CAPformer: Pedestrian Crossing Action Prediction Using Transformer', *Sensors*, τ. 21, τχ. 17, σελ. 5694, Ιανουαρίου 2021, doi: 10.3390/s21175694.
- [43] D. Yang, H. Zhang, E. Yurtsever, K. Redmill, και U. Ozguner, *Predicting Pedestrian Crossing Intention with Feature Fusion and Spatio-Temporal Attention*. 2021. doi: 10.48550/arXiv.2104.05485.
- [44] R. Gantier, Y. Qian, C. Wang, και M. YANG, 'Pedestrian Graph +: A Fast Pedestrian Crossing Prediction Model Based on Graph Convolutional Networks', *IEEE Trans. Intell. Transp. Syst.*, τ. PP, σελ. 1–12, Νοεμβρίου 2022, doi: 10.1109/TITS.2022.3173537.
- [45] J.-S. Ham, K. Bae, και J. Moon, 'MCIP: Multi-Stream Network for Pedestrian Crossing Intention Prediction', 2023, σελ. 663–679. doi: 10.1007/978-3-031-25056-9_42.
- [46] Y. Zhou, G. Tan, R. Zhong, Y. Li, και C. Gou, 'PIT: Progressive Interaction Transformer for Pedestrian Crossing Intention Prediction', *IEEE Trans. Intell. Transp. Syst.*, τ. PP, σελ. 1–13, Δεκεμβρίου 2023, doi: 10.1109/TITS.2023.3309309.
- [47] N. Sharma, C. Dhiman, και I. Sreedevi, 'Visual-Motion-Interaction Guided Pedestrian Intention Prediction Framework', *IEEE Sens. J.*, τ. PP, σελ. 1–1, Νοεμβρίου 2023, doi: 10.1109/JSEN.2023.3317426.